

Previsão de vazão dos rios na cidade de Manaus

Gabriela Scofield
Luiz Felipe Siqueira
Nathan Hazan
Oliver Hoerde

1. Introdução

1.1 Motivação

A Amazônia Legal é uma região de vital importância tanto para o equilíbrio climático global quanto para a biodiversidade, mas enfrenta desafios socioambientais críticos, como o desmatamento e eventos climáticos extremos. Dentre essas, as enchentes têm se tornado cada vez mais frequentes e intensas, impactando negativamente comunidades ribeirinhas, infraestruturas urbanas e a economia local.

O projeto surgiu então no contexto do tema “Amazonizar”. O conceito de “Amazonizar” propõe uma nova forma de desenvolvimento sustentável para a Amazônia, integrando saberes locais, tecnologia e preservação ambiental [PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO, 2023].

Em particular, este projeto busca desenvolver um modelo preditivo da vazão dos rios na cidade de Manaus, com base em dados hidrológicos, climáticos e de desmatamento. A escolha pela previsão de vazão, em vez da previsão direta de enchentes, decorre da maior disponibilidade e qualidade dos dados sobre esse indicador, que serve como sinal antecipado de eventos críticos. O objetivo é antecipar variações anormais nos níveis dos rios, contribuindo para a prevenção de desastres naturais, a proteção de comunidades vulneráveis e o planejamento de infraestruturas mais resilientes.

Essa iniciativa se insere no contexto de transição energética e resiliência climática da região amazônica, reconhecendo a urgência de promover soluções sustentáveis diante dos desafios ambientais e sociais locais. O Brasil é um dos países com maior participação de fontes renováveis em sua matriz energética, com cerca de 48% de energia proveniente de fontes renováveis, enquanto a média global é de apenas 15% [EPE, 2024]. A hidreletricidade ainda representa a maior parte dessa matriz, especialmente na Região Norte, onde rios como o Rio Negro e o Solimões são estratégicos para o abastecimento energético. A cidade de Manaus, embora geograficamente inserida nesse contexto de abundância hídrica, depende em grande parte de sistemas isolados e termelétricas movidas a combustíveis fósseis, o que impõe custos altos e maior impacto ambiental.

Nesse cenário, torna-se fundamental planejar uma transição energética sustentável e segura na Amazônia, valorizando fontes renováveis como a energia solar, a bioenergia e centrais hidrelétricas de menor impacto. No entanto, a intensificação de eventos climáticos extremos, como cheias históricas registradas em 2009, 2012 e 2021, revela a vulnerabilidade da

infraestrutura urbana e energética da região, reforçando a necessidade de sistemas de monitoramento e previsão ambiental.

Este projeto surge, portanto, da urgência em integrar a ciência de dados ao monitoramento hidrológico, visando prever com maior precisão a vazão dos rios de Manaus, o que pode fornecer subsídios essenciais para:

- Prevenir danos a comunidades e instalações energéticas;
- Apoiar o planejamento de infraestruturas mais resilientes;
- Garantir a continuidade e segurança na produção e distribuição de energia renovável.

Ao alinhar tecnologia, dados ambientais e a perspectiva da bioeconomia, o projeto contribui para a proposta de "Amazonizar" o desenvolvimento: um modelo baseado no respeito à floresta, à ciência e à vida das populações locais, promovendo soluções energéticas sustentáveis e adaptadas às realidades amazônicas.

1.2 Questão de Pesquisa

Como a previsão da vazão dos rios de Manaus pode contribuir para o planejamento mais eficaz da infraestrutura de energia renovável, ajudando a prevenir danos a instalações e orientar a expansão sustentável das fontes energéticas na região amazônica?

A região amazônica enfrenta desafios significativos relacionados às mudanças climáticas, como variações extremas nos níveis dos rios, que impactam diretamente a segurança hídrica, energética e social. Em especial, a cidade de Manaus sofre com eventos de cheia que afetam comunidades ribeirinhas, sistemas urbanos e a operação de infraestruturas críticas. Diante da dificuldade em obter dados rotulados e sistemáticos sobre enchentes, este projeto propõe um redirecionamento do foco analítico para a previsão da vazão dos rios, uma variável contínua e mensurável que serve como indicador antecipado de riscos de alagamento e instabilidade ambiental.

Integrar a previsão de vazão ao planejamento energético é essencial para proteger instalações de energia renovável, como centrais hidrelétricas e estruturas solares em áreas vulneráveis, além de otimizar sua expansão com base em critérios de sustentabilidade e resiliência. Ao empregar técnicas de ciência de dados e modelagem preditiva, o projeto busca apoiar decisões estratégicas que fortaleçam a bioeconomia regional, a conservação da floresta e a segurança das populações locais, reforçando a importância de dados ambientais na construção de políticas públicas e soluções sustentáveis para a Amazônia.

1.3 Cliente a Ser Atendido

O principal público-alvo do projeto inclui gestores públicos municipais e estaduais, pesquisadores da área ambiental, comunidades locais e organizações socioambientais atuantes na

região da Amazônia Legal. Esses agentes enfrentam desafios recorrentes relacionados à ocorrência de enchentes e à gestão de recursos hídricos, que impactam diretamente a segurança da população, a infraestrutura básica e o planejamento de iniciativas sustentáveis, como projetos de energia renovável.

De forma mais específica, o cliente final do projeto são os órgãos públicos de planejamento e defesa civil de Manaus, como a SEMMAS (Secretaria Municipal de Meio Ambiente e Sustentabilidade) e o CEMIG/Semdec (Centro de Monitoramento da Defesa Civil Municipal), que poderão utilizar diretamente os modelos preditivos para antecipar eventos críticos de cheia e ajustar planos de contingência, logística e prevenção de danos.

Além disso, instituições de pesquisa e universidades envolvidas com clima, hidrologia e bioeconomia na região também se beneficiam dos dados consolidados e metodologias desenvolvidas, podendo expandir ou replicar os modelos em outras áreas da Amazônia.

As comunidades locais, especialmente populações ribeirinhas e indígenas, se beneficiam indiretamente ao terem seus territórios mais protegidos frente a desastres naturais, graças ao suporte oferecido às políticas públicas fundamentadas em ciência de dados.

Por fim, o projeto também atende às demandas de organizações da sociedade civil engajadas na promoção de uma economia florestal sustentável, no monitoramento dos impactos das mudanças climáticas e na valorização dos saberes tradicionais amazônicos.

1.4 Objetivo

O objetivo é desenvolver um modelo de previsão de enchentes para municípios da Amazônia Legal. Esse modelo fará uso de dados ambientais, hidrológicos, climáticos e de desmatamento, com o intuito de apoiar o planejamento territorial, a prevenção de desastres e o fortalecimento de iniciativas sustentáveis, incluindo projetos de energia renovável e bioeconomia.

Objetivos específicos:

- Coletar, integrar e tratar dados públicos sobre precipitação, vazão dos rios, desmatamento e variáveis climáticas relevantes da região amazônica.
- Identificar padrões e correlações entre os fatores ambientais e a ocorrência de enchentes em diferentes municípios.
- Construir modelos preditivos baseados em ciência de dados capazes de antecipar eventos extremos com base em séries temporais e variáveis locais.
- Contribuir para o planejamento de infraestrutura resiliente e para o desenvolvimento de soluções energéticas renováveis compatíveis com a realidade amazônica.

Resultados esperados:

- Um modelo funcional de previsão de enchentes aplicável a diferentes municípios da Amazônia Legal.

- Informações que subsidiem políticas públicas mais eficazes no combate a desastres naturais.
- Apoio à expansão de projetos sustentáveis e de energia renovável na região, ao oferecer dados estratégicos sobre riscos hidrológicos.
- Fortalecimento da bioeconomia local por meio da proteção de áreas produtivas e da valorização da floresta.

1.5 Trabalhos Correlatos

O presente estudo dialoga com uma série de trabalhos acadêmicos e aplicações práticas que vêm utilizando técnicas de aprendizado de máquina para previsão de variáveis hidrológicas e meteorológicas, especialmente em contextos marcados por alta variabilidade climática e riscos de eventos extremos, como enchentes e inundações. A seguir, destacam-se três trabalhos que influenciaram diretamente as decisões metodológicas e justificam as escolhas adotadas neste projeto.

Os trabalhos identificados como correlatos ao presente estudo apresentam semelhanças fundamentais em termos de objetivo, abordagem e natureza dos dados utilizados. Assim como este projeto, que busca prever a vazão dos rios de Manaus como forma indireta de antecipar enchentes e mitigar seus impactos sobre a infraestrutura energética, os estudos selecionados também se concentram em modelagens baseadas em aprendizado de máquina aplicadas à previsão de eventos hidrológicos extremos. O artigo “*XGBoost-based method for flash flood risk assessment*” [2021], por exemplo, utiliza dados climáticos e ambientais para prever o risco de inundações repentinas por meio do algoritmo XGBoost, destacando-se pelo uso de variáveis contínuas, séries temporais e comportamento não linear (características igualmente presentes em nosso conjunto de dados). De forma semelhante, a revisão de Mosavi et al. [MOSAVI et al., 2018] mostra que os modelos mais bem-sucedidos na previsão de enchentes são justamente aqueles capazes de capturar padrões cíclicos e interações complexas entre variáveis como chuva, vazão, umidade do solo e uso da terra, justificando nossa escolha por modelos baseados em árvores de decisão, como XGBoost e Random Forest. Já o trabalho de Anusha et al. [ANUSHA et al., 2019], embora utilize uma técnica mais simples (regressão linear múltipla), reforça a ideia de que variáveis ambientais e temporais carregam um comportamento cíclico e sazonal que pode ser explorado na modelagem preditiva. Assim, todos esses trabalhos compartilham com o nosso projeto a premissa central de que eventos hidrológicos extremos podem ser antecipados com base em séries históricas de dados ambientais, e mostram que o uso de modelos supervisionados treinados com dados climáticos é uma estratégia eficaz e replicável em diferentes contextos geográficos, incluindo a região amazônica.

Dado que esses estudos apresentam objetivos e contextos semelhantes ao do nosso projeto, torna-se relevante analisar quais métodos e algoritmos preditivos foram utilizados por cada um, e de que forma essas abordagens influenciaram ou reforçaram as decisões metodológicas adotadas na nossa modelagem. A seguir, exploramos as técnicas aplicadas nesses

trabalhos e justificamos como elas embasaram a escolha dos modelos testados e selecionados ao longo deste estudo.

Um dos estudos mais relevantes é o artigo "XGBoost-based method for flash flood risk assessment" [JOURNAL OF HYDROLOGY, 2021], que propõe um modelo preditivo para avaliação de risco de inundações rápidas utilizando o algoritmo XGBoost. O trabalho destaca a capacidade do XGBoost de lidar com grandes volumes de dados ambientais, tratar não linearidades e entregar resultados robustos mesmo em cenários com variáveis ruidosas ou interdependentes, que são características típicas de ambientes tropicais como a Amazônia. A principal contribuição deste estudo está na eficácia do XGBoost em capturar padrões complexos entre variáveis meteorológicas e resposta hidrológica, o que influenciou diretamente sua escolha como modelo final neste projeto. Além disso, o artigo reforça a importância da análise de resíduos e da validação cruzada, técnicas também aplicadas no presente estudo para garantir estabilidade e confiabilidade das previsões.

Outro trabalho de referência é a revisão sistemática "Flood Prediction Using Machine Learning Models: Literature Review" [MOSAVI et al., 2018], que examina dezenas de estudos voltados à previsão de enchentes por meio de técnicas como Random Forest, redes neurais artificiais, SVM e regressões múltiplas. A revisão aponta que, embora diversos modelos tenham sido testados, os modelos baseados em árvores de decisão (como Random Forest e XGBoost) se destacam por sua precisão, interpretabilidade e capacidade de lidar com variáveis heterogêneas, como precipitação, umidade, uso do solo e vazão. O estudo também evidencia que o sucesso dos modelos depende fortemente da seleção criteriosa de atributos, do tratamento de dados ausentes e da adequação da janela temporal utilizada, elementos que foram cuidadosamente incorporados na metodologia do projeto atual.

Por fim, o artigo "Weather Prediction Using Multi Linear Regression Algorithm" [ANUSHA et al., 2019] apresenta uma abordagem mais simples e tradicional, baseada em regressão linear múltipla, aplicada à previsão de condições climáticas. Embora o modelo utilizado seja menos complexo que os algoritmos em árvore, o estudo é útil ao demonstrar a importância da escolha de variáveis preditoras relevantes e do pré-processamento dos dados, incluindo a padronização e a estruturação temporal das séries. A simplicidade do modelo também destaca, por contraste, as vantagens dos métodos baseados em aprendizado de máquina, especialmente quando se busca capturar padrões não lineares e interações entre múltiplos fatores ambientais, como ocorre no presente projeto ao se prever a vazão dos rios em função de variáveis climáticas e de desmatamento.

Em conjunto, esses trabalhos justificam as escolhas metodológicas do presente estudo, especialmente a adoção de algoritmos baseados em árvore de decisão (XGBoost e Random Forest), a construção de pipelines experimentais com diferentes combinações de pré-processamento e validação cruzada, e a análise crítica dos resíduos e desempenho dos modelos. Além disso, reforçam a relevância da modelagem preditiva como ferramenta estratégica para antecipar riscos hidrológicos, orientar políticas públicas e promover a resiliência de infraestruturas energéticas em regiões vulneráveis.

1.6 Metodologia a Ser Empregada

Para alcançar seus objetivos, o projeto adota uma abordagem baseada em ciência de dados e aprendizado supervisionado, estruturada conforme as etapas metodológicas recomendadas por autores como Bruce & Bruce [2017] e James et al. [2013], amplamente utilizadas em projetos de modelagem preditiva. A metodologia compreende as seguintes etapas:

- Coleta e integração dos dados: Reunião de séries temporais relacionadas à vazão dos rios, precipitação, temperatura, umidade do solo e taxas de desmatamento na cidade de Manaus, provenientes de bases públicas como ANA, INMET e MapBiomias.
- Pré-processamento dos dados: Aplicação de técnicas como interpolação de valores ausentes, normalização ou padronização (ex.: *MinMaxScaler*, *StandardScaler*), e codificação de variáveis categóricas, quando necessário. A uniformização das séries temporais e o alinhamento temporal das variáveis também são realizados nesta etapa.
- Seleção de atributos relevantes: Utilização de métodos como *SelectKBest* (baseado em correlação ou F-test), importância de variáveis derivada de modelos baseados em árvore (Random Forest e XGBoost) e análise de colinearidade e redundância, com o objetivo de reduzir dimensionalidade e melhorar a interpretabilidade do modelo.
- Plano de experimentação: Definição de um plano fatorial completo, cruzando diferentes combinações de técnicas de pré-processamento, algoritmos de regressão (Random Forest, XGBoost) e estratégias de validação (RepeatKFold 5x2, K-Fold com k=5 e k=10). O objetivo é identificar a configuração com melhor desempenho e maior estabilidade entre os folds.
- Treinamento e avaliação dos modelos: Aplicação dos modelos selecionados a cada *pipeline*, utilizando métricas como R^2 (coeficiente de determinação), RMSE (*Root Mean Squared Error*) e MAE (*Mean Absolute Error*). A avaliação é realizada com validação cruzada k-fold, para garantir maior confiabilidade dos resultados e minimizar o risco de *overfitting*.
- Análise dos resíduos: Verificação do comportamento dos erros de predição, com foco na identificação de tendências, *outliers* e heterocedasticidade, assegurando que o modelo não esteja sistematicamente errando para certos intervalos de vazão.
- Interpretação e comparação dos resultados: Com base nas métricas de desempenho e na análise dos resíduos, os modelos são comparados para selecionar aquele que apresenta o melhor equilíbrio entre precisão, estabilidade e interpretabilidade.

Dessa forma, a metodologia adotada neste projeto combina práticas consolidadas de ciência de dados e aprendizado supervisionado, aplicadas de forma sistemática para abordar a questão de pesquisa proposta. Através da coleta de dados ambientais e hidrológicos, do pré-processamento criterioso das séries temporais e da seleção orientada de atributos relevantes, busca-se construir modelos preditivos robustos e interpretáveis. A experimentação será conduzida por meio de um plano fatorial completo, que cruza diferentes técnicas de normalização,

algoritmos de regressão (com destaque para Random Forest e XGBoost) e estratégias de validação cruzada. A escolha final do modelo se dará com base em métricas estatísticas de desempenho (R^2 , RMSE, MAE) e na análise dos resíduos, assegurando não apenas precisão preditiva, mas também estabilidade e coerência estatística. Essa abordagem metodológica foi estruturada de forma a garantir rastreabilidade das decisões, reprodutibilidade dos resultados e alinhamento com boas práticas da literatura especializada, sendo adequada para alcançar os objetivos do projeto e oferecer respostas confiáveis à questão de pesquisa.

1.7 Expectativa de Resultados

Espera-se que este projeto resulte na construção de um modelo preditivo eficaz e estatisticamente confiável para antecipar variações na vazão dos rios da cidade de Manaus, com base em variáveis ambientais, climáticas e de desmatamento. Tal modelo poderá funcionar como uma ferramenta estratégica de apoio à tomada de decisão por parte de gestores públicos, operadores de infraestrutura e formuladores de políticas públicas voltadas à sustentabilidade e à resiliência climática.

Entre os principais insights esperados, destaca-se a identificação de padrões sazonais e hidrológicos fortemente associados a eventos extremos, como enchentes e secas severas. Isso pode contribuir para o mapeamento de áreas de maior vulnerabilidade hídrica, oferecendo suporte para ações preventivas e de adaptação. Espera-se também observar que a interação entre desmatamento, precipitação e vazão apresenta dinâmica própria em diferentes regiões, o que pode demonstrar a necessidade de modelos preditivos regionalizados, ajustados à realidade ecológica e climática de cada município amazônico.

Outro resultado esperado é a geração de subsídios técnicos para o planejamento e proteção de infraestruturas de energia renovável, como centrais hidrelétricas, usinas solares flutuantes e sistemas de bioenergia instalados em áreas sujeitas a variações extremas nos níveis dos rios. Ao prever alterações significativas na vazão com antecedência, será possível orientar decisões operacionais (como por exemplo desligamento de equipamentos, redirecionamento de energia, planejamento de manutenção preventiva), reduzindo perdas econômicas e riscos de falhas sistêmicas.

Além disso, o projeto deverá contribuir de forma significativa para o corpo de conhecimento na interseção entre ciência de dados, hidrologia e energia renovável, ao demonstrar na prática como técnicas de aprendizado de máquina podem ser aplicadas de forma eficaz à previsão de variáveis hidrológicas críticas. Espera-se que o estudo reforce o papel da modelagem preditiva como ferramenta viável, replicável e acessível para fortalecer a resiliência de sistemas energéticos sustentáveis em regiões com alta vulnerabilidade socioambiental, como a Amazônia Legal.

Finalmente, o projeto poderá abrir caminhos para novas abordagens interdisciplinares, mostrando como a integração entre dados climáticos, ambientais e territoriais pode apoiar estratégias de transição energética, gestão de riscos e adaptação às mudanças climáticas em contextos tropicais. Além disso, o projeto pode contribuir significativamente para o conhecimento na área de energia renovável ao demonstrar como ferramentas de *machine learning*

aplicadas à previsão de desastres naturais podem fortalecer a viabilidade e a segurança de iniciativas sustentáveis, como: centrais hidrelétricas, sistemas solares e bioenergia na Amazônia.

2. Metodologia e Plano de Experimentação

2.1 Tipo de Aprendizado de Máquina e Especificação da Tarefa

A modelagem proposta neste projeto se baseia em aprendizado supervisionado, uma abordagem que se mostra particularmente adequada ao problema de previsão da vazão dos rios de Manaus. Trata-se de uma tarefa em que o objetivo é prever valores contínuos (o volume de vazão) a partir de um conjunto de variáveis explicativas previamente observadas, como chuva, desmatamento, temperatura, umidade, entre outras. Este tipo de aprendizado é apropriado porque temos acesso a dados históricos rotulados, ou seja, registros em que as entradas (atributos ambientais) estão associadas a saídas conhecidas (valores de vazão).

No aprendizado supervisionado, o objetivo é ensinar o modelo a mapear uma função do tipo $f(x) \approx y$, onde:

- x representa um conjunto de atributos preditores (features),
- y é o valor alvo (target), que no nosso caso é uma variável contínua, como o nível do rio ou volume de água.

Nesse contexto, optou-se por tratar o problema como um tipo de aprendizado supervisionado porque o conjunto de dados disponível contém valores-alvo historicamente observados (targets) associados a variáveis explicativas (features). Por outro lado, a tarefa é de regressão dado que a variável de interesse (vazão) é contínua e quantitativa, exigindo um modelo capaz de prever valores numéricos ao longo de um intervalo.

A escolha pelo aprendizado supervisionado, e mais especificamente pela tarefa de regressão, é justificada por três razões principais:

1. A natureza do problema é quantitativa e preditiva: o projeto visa antecipar valores futuros de vazão, e não apenas classificar cenários como “com enchente” ou “sem enchente”. Prever a vazão de forma contínua permite uma compreensão mais fina do comportamento hidrológico, essencial para o planejamento energético e a tomada de decisão em situações de risco.
2. O histórico de dados ambientais está estruturado com pares entrada-saída conhecidos: cada linha da base representa um instante de tempo (diário), no qual são observadas as variáveis climáticas e a respectiva vazão. Isso torna viável o treinamento de modelos supervisionados, pois existe um “rótulo” numérico a ser previsto.

3. Flexibilidade para usos posteriores: ao prever a vazão em termos contínuos, é possível, em um segundo momento, aplicar um limiar (threshold) para classificar eventos como enchentes ou não. Isso amplia a utilidade do modelo, permitindo desde o acompanhamento diário da dinâmica dos rios até o acionamento de alertas em situações críticas.

Dessa forma, a decisão de formular o problema como uma regressão supervisionada não apenas se alinha à estrutura dos dados disponíveis, mas também atende de forma mais ampla aos objetivos estratégicos do projeto, que envolvem fornecer ferramentas técnicas para o monitoramento ambiental e o planejamento de infraestrutura energética sustentável na região amazônica. O modelo preditivo construído permitirá compreender e antecipar variações na vazão dos rios, o que é fundamental para reduzir riscos operacionais e apoiar políticas de adaptação climática em Manaus e, futuramente, em outras áreas da Amazônia Legal.

2.2 Técnicas/Algoritmos Utilizados

No contexto de um aprendizado supervisionado, podemos então estudar as possíveis escolhas de algoritmos de regressão. Diversos algoritmos de regressão poderiam ser aplicados neste contexto, cada um com suas características particulares. A Regressão Linear Múltipla, por exemplo, oferece uma abordagem simples e interpretável. No entanto, ela assume uma relação linear entre as variáveis independentes e a variável dependente, o que não é compatível com a natureza complexa e frequentemente não linear dos fenômenos hidrológicos. Como veremos nas análises posteriores, a relação entre as variáveis do nosso projeto possuem baixíssima correlação, demonstrando baixa (Gráfico 21) ou nula (Gráfico 19) relação linear. Além disso, esse modelo é sensível à multicolinearidade entre os atributos, o que comprometeria sua estabilidade e confiabilidade diante da correlação frequentemente observada entre variáveis ambientais nos gráficos anteriores.

Outra técnica viável seria a Regressão por Árvore de Decisão, que constrói uma estrutura hierárquica de decisões para estimar o valor de saída. Embora apresente boa capacidade de modelar relações não lineares e não exija pré-processamentos como normalização dos dados, sendo então mais fácil de aplicar, esse modelo apresenta portanto baixa estabilidade. Pequenas alterações nos dados de entrada podem gerar grandes variações na estrutura da árvore gerada. Ademais, árvores isoladas tendem ao *overfitting*, especialmente quando expostas a dados com ruído ou variações sazonais, como é comum em séries hidrológicas.

Nesse cenário, o Random Forest Regressor surge como uma alternativa mais robusta. Trata-se de um algoritmo de ensemble learning baseado em uma média de múltiplas árvores de decisão, treinadas de forma aleatória a partir de subconjuntos dos dados (*bagging*). Essa estratégia reduz a variância do modelo, aumenta sua estabilidade e minimiza o risco de *overfitting*.

Ele foi uma boa segunda escolha pois dado às análises anteriores, um dos seus destaques é que ele é capaz de lidar com variáveis altamente não lineares e com interações complexas entre

atributos, como observado nos padrões analisados na seção 3.4. Além disso, o Random Forest se adapta bem a conjuntos de dados com múltiplas variáveis correlacionadas e ruído moderado. Por essas razões, o algoritmo foi considerado como uma forte alternativa durante a fase de experimentação, especialmente diante da constatação empírica de que os padrões de vazão não seguem relações lineares simples com as variáveis climáticas e ambientais.

O Random Forest é especialmente adequado para este projeto por sua capacidade de:

- modelar relações não lineares complexas;
- operar bem com variáveis correlacionadas, como demonstrado nas análises de correlação entre chuva, desmatamento e clima;
- identificar interações entre atributos sem necessidade explícita de defini-las a priori;
- e lidar com grandes volumes de dados e múltiplas variáveis com diferentes escalas e distribuições.

Contudo, o Random Forest possui duas limitações relevantes neste contexto: seu custo computacional cresce com o número de árvores e variáveis envolvidas, e a interpretabilidade do modelo é limitada, dificultando a análise individual do efeito de cada atributo.

Portanto, embora o Random Forest tenha se mostrado uma segunda melhor opção viável, especialmente pela sua capacidade de lidar com relações não lineares e variáveis ambientais correlacionadas, o XGBoost Regressor foi escolhido como o modelo mais adequado ao problema, por aliar precisão, estabilidade e eficiência na previsão da vazão dos rios de Manaus.

O XGBoost é um algoritmo baseado em gradiente *boosting* de árvores de decisão, que constrói árvores de forma sequencial, ajustando cada nova árvore com base nos erros cometidos pelas anteriores. Essa característica permite capturar padrões residuais complexos, tornando-o particularmente eficaz em cenários onde a relação entre variáveis é não linear, defasada ou sutil, como ocorre em sistemas hidrológicos tropicais.

Sua aplicação neste projeto se justifica por diversas razões alinhadas ao perfil dos dados e aos desafios do problema:

1. Alta capacidade de modelar não linearidades complexas: as análises exploratórias revelaram que a relação entre variáveis como precipitação, desmatamento e vazão não segue padrões lineares simples (Seção 3.4). O XGBoost é especialmente eficaz nesse tipo de contexto, ao explorar interações entre variáveis e ajustar nuances nos dados.
2. Robustez a dados ruidosos e ausentes: séries ambientais e hidrológicas frequentemente apresentam falhas de medição, ruído e lacunas temporais. O XGBoost lida internamente com valores ausentes e é menos suscetível à degradação de performance mesmo em contextos com dados incompletos ou interpolados, como é o caso da variável areakm,

interpolada a partir de dados anuais.

3. Capacidade de trabalhar com variáveis correlacionadas: muitas variáveis climáticas e ambientais, como temperatura, umidade e pressão, apresentam interdependência estatística, o que compromete modelos mais sensíveis à multicolinearidade. O XGBoost, por utilizar uma estrutura baseada em árvores, não exige independência entre atributos, mantendo a estabilidade preditiva mesmo em cenários com alta correlação entre variáveis.
4. Regularização interna e controle de *overfitting*: o modelo implementa penalizações sobre a complexidade das árvores (parâmetros como *lambda* e *alpha*), o que permite maior controle sobre o sobreajuste aos dados de treinamento, um risco relevante em bases temporais, como as utilizadas neste projeto.
5. Eficiência computacional: embora baseado em *boosting*, o XGBoost é otimizado para execução paralela e possui suporte a estruturas esparsas, o que o torna mais rápido e escalável que outros métodos de *boosting* convencionais, e mais eficiente que o Random Forest em tarefas com múltiplos ciclos de avaliação (como validação cruzada).
6. Interpretação com ferramentas modernas: apesar de não ser diretamente interpretável como uma regressão linear, o XGBoost é compatível com técnicas avançadas de interpretação de modelos, como SHAP values (SHapley Additive exPlanations), permitindo avaliar a importância e o efeito de cada variável mesmo em contextos complexos.

Dessa forma, o XGBoost foi selecionado como modelo final do projeto por apresentar o melhor equilíbrio entre capacidade preditiva, robustez, generalização e eficiência computacional. Ele se mostrou o mais adequado para lidar com os desafios específicos de previsão de vazão fluvial na Amazônia, onde predominam padrões não lineares, variações sazonais, dados multivariados correlacionados e incertezas provenientes de interpolação e variáveis estruturais como o desmatamento.

2.3 Percentual da Base de Dados para Treinamento

Para a etapa de modelagem preditiva, a base de dados foi dividida em dois subconjuntos: 80% dos dados foram reservados para o treinamento do modelo de aprendizado de máquina e os 20% restantes para a validação de seu desempenho. A separação dos dados em 80% para treino e 20% para teste foi escolhida por ser uma prática comum e bem estabelecida na literatura de aprendizado de máquina. Nesta proporção, o modelo recebe quantidade suficiente de dados tanto para treino quanto para teste, evitando sobreajuste ou subavaliação do modelo [ZHANG, WANG, JI, 2021]. Além disso, essa divisão é especialmente adequada quando se dispõe de um volume razoável de dados, como é o caso deste trabalho, garantindo robustez estatística no ajuste e na avaliação do modelo.

A escolha dessa proporção está alinhada com as características do modelo XGBoost (Extreme Gradient Boosting), que é um algoritmo baseado em árvores de decisão e construído por meio de boosting de gradiente. O XGBoost apresenta grande capacidade de modelar padrões complexos, mas também pode ser sensível ao *overfitting*, especialmente quando há desequilíbrio ou escassez de dados no conjunto de validação. Utilizar uma divisão inferior (por exemplo, 90/10) reduziria substancialmente o tamanho da amostra de teste, comprometendo a avaliação do desempenho generalizável do modelo. Por outro lado, utilizar uma proporção maior de dados para validação (como 70/30 ou 60/40) poderia prejudicar a capacidade do modelo de aprender os padrões presentes na base, ao limitar o volume de dados disponível para treinamento, o que é especialmente relevante quando se busca capturar relações não lineares e interações entre atributos, como é o caso em XGBoost [CHEN; GUESTRIN, 2016].

Além disso, optou-se por não utilizar validação cruzada k-fold neste estágio, a fim de reduzir o custo computacional do processo de modelagem, dado que o XGBoost é consideravelmente mais custoso do que modelos lineares. No entanto, durante o ajuste de hiperparâmetros, técnicas como *cross-validation* interna poderão ser empregadas para garantir maior robustez na escolha dos parâmetros sem comprometer a estrutura de validação externa definida previamente.

Essa estratégia de divisão dos dados, portanto, visa assegurar uma avaliação confiável do modelo treinado, com boa capacidade de generalização, mantendo a eficiência computacional e a integridade estatística do processo de aprendizagem.

2.4 Pré-processamento

Em projetos de modelagem preditiva, o pré-processamento dos dados exerce influência direta sobre o desempenho dos modelos de aprendizado de máquina. A forma como os dados são tratados antes do treinamento, seja por meio da normalização, da remoção de outliers ou da seleção de atributos, pode impactar significativamente a capacidade de generalização, a robustez e a precisão do modelo final. Certas transformações podem ajudar o algoritmo a capturar padrões relevantes com mais clareza, enquanto outras podem introduzir ruído ou distorções, especialmente em conjuntos de dados com variabilidade ambiental e hidrológica, como os utilizados neste projeto.

Com isso em mente, o presente estudo adotou uma abordagem experimental, na qual diferentes técnicas de pré-processamento foram variadas sistematicamente ao longo de um plano fatorial, com o objetivo de identificar quais combinações maximizam o desempenho preditivo. Foram testadas variações de três tipos principais de transformação: remoção de *outliers*, normalização dos dados e seleção de atributos. A seguir, detalham-se os procedimentos adotados.

Foi testado, ao longo do plano de experimentação, o impacto da remoção de outliers com base no critério estatístico do Z-score, considerando como outliers os registros cujo valor absoluto excedia três desvios-padrão em relação à média da variável. Dois cenários foram

comparados: um com a manutenção integral dos dados, preservando os valores extremos, e outro com a exclusão desses registros considerados discrepantes. A motivação para essa variação está no fato de que *outliers*, embora possam distorcer o aprendizado do modelo, principalmente na presença de médias deslocadas ou dispersões infladas, também podem representar eventos críticos reais, como picos de cheia, cuja ocorrência é justamente o foco do monitoramento hidrológico. A comparação entre os dois cenários permitiu avaliar se a preservação desses eventos extremos contribui para uma maior sensibilidade do modelo ou se a sua remoção favorece a estabilidade e generalização do ajuste.

No mesmo espírito de análise controlada, foram testadas diferentes técnicas de escalonamento dos dados, ainda que os algoritmos utilizados (Random Forest e XGBoost) não sejam intrinsecamente sensíveis à escala das variáveis. Foram incluídos três métodos distintos: o MinMaxScaler, que transforma os dados para o intervalo $[0,1]$, o StandardScaler, que realiza a padronização com base em média zero e desvio-padrão um e o RobustScaler, que utiliza a mediana e o intervalo interquartil, sendo mais resistente à presença de outliers. A inclusão dessas técnicas no plano experimental se justifica pela possibilidade de que o escalonamento interfira indiretamente em etapas posteriores do pipeline, como a seleção de atributos e a análise dos resíduos, podendo impactar a performance final do modelo.

Também foi avaliado o efeito da seleção de atributos sobre o desempenho preditivo, por meio de dois métodos amplamente utilizados na literatura: o SelectKBest, que seleciona os K atributos mais relevantes com base em testes estatísticos simples, como correlação e F-test e o RFE (Recursive Feature Elimination), que realiza a eliminação progressiva das variáveis menos relevantes com base em um estimador interno, como regressão ou árvore de decisão. Essa variação teve como objetivo reduzir a dimensionalidade do problema, minimizar colinearidades e eliminar redundâncias, o que pode resultar em modelos mais interpretáveis, com menor tempo de treinamento e menor risco de sobreajuste, especialmente em um contexto de alta variabilidade climática como o da Amazônia.

2.5 Cross-Validation

Para avaliar de forma robusta o desempenho dos modelos de aprendizado de máquina, este projeto adotou diferentes estratégias de *cross-validation*, fundamentais para estimar a capacidade de generalização dos modelos em dados não vistos. A validação cruzada é especialmente importante em contextos com dados ambientais e hidrológicos, nos quais os padrões podem variar ao longo do tempo ou apresentar sazonalidade, e o risco de *overfitting* é elevado.

Foram testadas três abordagens distintas de validação cruzada: k-fold com $k=3$, k-fold com $k=10$, e Repeated K-Fold com 5 repetições de 2 folds (5x2). A escolha por utilizar múltiplos métodos foi motivada pela compreensão de que a forma como os dados são particionados em treino e teste pode impactar diretamente nas métricas de desempenho observadas. Ao variar a estratégia de validação, torna-se possível identificar quais modelos são mais estáveis e quais são sensíveis a pequenas mudanças na composição dos dados.

No método K-Fold de *cross-validation*, o conjunto de dados é dividido em k *folds* aproximadamente iguais. O modelo é treinado em $k-1$ partes e testado na parte restante, repetindo esse processo k vezes, de modo que cada fold seja usado uma vez como teste. No presente estudo, $k=3$ foi utilizado para simulações rápidas, com menos divisões, o que pode ser útil quando o volume de dados é limitado ou quando o tempo computacional é uma restrição. Por outro lado, o $k=10$ oferece uma avaliação mais detalhada e granular, já que aumenta o número de testes e fornece estimativas com menor variância, sendo uma prática comum na literatura.

Já a Repeated K-Fold 5x2 consiste em repetir o processo de validação cruzada com 2 *folds* (divisão 50/50 entre treino e teste), executado 5 vezes com diferentes partições aleatórias. Essa técnica permite avaliar não apenas a média do desempenho, mas também sua variabilidade entre repetições, sendo útil para testar a estabilidade dos modelos sob diferentes amostragens. Ela também simula situações em que o modelo precisa aprender com um subconjunto pequeno dos dados, o que ajuda a expor possíveis fragilidades.

Ao incluir essas diferentes estratégias no plano de experimentação, o projeto buscou não apenas identificar o modelo com melhor desempenho médio, mas também aquele com maior consistência entre diferentes cenários de validação. Essa abordagem aumentou a confiabilidade da escolha do modelo final, reduzindo o risco de conclusões enviesadas por particionamentos específicos do conjunto de dados.

2.6 Combinações de Parâmetros e Estratégias

Com o objetivo de identificar a melhor configuração preditiva para o problema de previsão da vazão dos rios de Manaus, foi conduzido um plano de experimentação sistemático e fatorial, testando diversas combinações de pré-processamentos, algoritmos, estratégias de validação e parâmetros de modelo. Essa abordagem visou garantir não apenas desempenho máximo, mas também estabilidade e interpretabilidade dos modelos.

Foram utilizadas duas técnicas distintas de modelagem preditiva: o Random Forest Regressor e o XGBoost Regressor, ambas baseadas em árvores de decisão, porém com diferenças importantes quanto à regularização e ao mecanismo de aprendizado. O XGBoost, por exemplo, realiza boosting iterativo com foco em minimizar o erro em cada rodada, enquanto o Random Forest usa *bagging* com árvores independentes. A escolha por esses dois algoritmos foi fundamentada em estudos anteriores destacados na Seção 1.5, como os trabalhos de Mosavi et al. [MOSAVI et al., 2018] e o estudo publicado no *Journal of Hydrology* (2021), que apontam as técnicas baseadas em árvores de decisão como particularmente eficazes na modelagem de problemas hidrológicos e na previsão de enchentes e vazão, devido à sua capacidade de lidar com dados não lineares, variáveis interdependentes e presença de outliers.

No que se refere à validação cruzada, foram testadas três variações: o método k-fold com $k=3$, o k-fold com $k=10$ e o Repeated K-Fold com 5 repetições de 2 folds (5x2). Essas variações permitiram avaliar o desempenho dos modelos sob diferentes formas de particionamento dos dados, testando tanto a sensibilidade à variação de amostras quanto a estabilidade entre diferentes rodadas.

A etapa de *feature selection* foi explorada com duas abordagens: SelectKBest, que seleciona variáveis com base em critérios estatísticos como F-test ou correlação e RFE, que elimina iterativamente as variáveis menos relevantes com base no desempenho de um estimador. O objetivo dessa variação foi reduzir a dimensionalidade, eliminar redundâncias e melhorar a capacidade do modelo de focar nas variáveis mais informativas.

Com relação ao pré-processamento, foram testadas combinações entre diferentes técnicas de normalização (StandardScaler, MinMaxScaler e RobustScaler) e remoção de *outliers* com base em Z-score (presente ou ausente). Isso permitiu avaliar como cada combinação influenciava a performance e a robustez dos modelos. Essas transformações foram aplicadas antes da modelagem, dentro de pipelines automatizados, e foram combinadas com diferentes seleções de atributos e validações cruzadas.

Adicionalmente, foram testados hiperparâmetros específicos para cada algoritmo. No caso do Random Forest, variaram-se o número de árvores (por exemplo, 50, 100) e o critério de divisão (como *squared error*). Já no XGBoost, testaram-se variações na profundidade máxima das árvores (3, 5) e na taxa de aprendizado (learning rate: 0.1, 0.3). Essas variações permitiram analisar o impacto de modelos mais complexos ou conservadores em relação ao *overfitting* e desempenho geral.

Todas essas combinações foram organizadas em cenários numéricos únicos, totalizando mais de 200 pipelines experimentais, com os resultados registrados em métricas de desempenho nos conjuntos de treino e teste, como R² (coeficiente de determinação), MAE (erro absoluto médio) e MSE (erro quadrático médio). Isso possibilitou não apenas a seleção do melhor modelo, mas também a análise comparativa entre diferentes abordagens e o entendimento mais aprofundado sobre os fatores que mais influenciam a qualidade da previsão de vazão em ambientes hidrológicos complexos como o de Manaus.

Abaixo, apresentamos uma imagem de pré-visualização do plano de experimentação aplicado ao modelo Random Forest Regressor, com as principais combinações testadas.

Cenário	Classificação	Pré-processamento					Feature Selection		Mineração	Cross Validation			Métricas de Desempenho		
		Standard	MinMax	Robust	RFE	Remoção de Outliers	RFE	SelectKBest		KFold k=3	KFold k=10	RepeatedKFold 5x2	MSE	MAE	R ²
1	2 classificações								50				626882.342	1354.350482	0.996314966
2	X		X			X			100				5753780.295	1294.639965	0.996526884
3	X			X		X			100				5984323.595	1292.469534	0.996536279
4	X	X				X			100				5790276.9	1300.483469	0.996511473
5	X		X			X			50				5962363.068	1301.642256	0.996479462
6	X			X		X			50				6014308.309	1335.032213	0.996467329
7	X	X				X			50				6026754.784	1334.159167	0.996459619
8	X		X			X			50				6012589.471	1338.034605	0.996445374
9	X			X		X			100				6042929.523	1288.447366	0.996444523
10	X			X		X			50				6296370.465	1308.050709	0.996325472
11		X				X			100				6265796.687	1300.076596	0.996316035
12		X		X		X			50				626682.342	1354.350482	0.996314966

Figura 1 – Plano de Experimentação do Random Forest Regressor

2.7 Quantidade de Cenários de Experimentação

Durante o plano de experimentação do projeto, foram testadas ao todo 648 combinações distintas de cenários preditivos. Especificamente, foram realizados 216 cenários com o modelo Random Forest Regressor e 432 cenários com o modelo XGBoost Regressor. Cada cenário representa uma combinação única de técnicas de pré-processamento, seleção de atributos, validação cruzada e configuração de hiperparâmetros. Essa abordagem fatorial permitiu explorar de forma sistemática os impactos individuais e combinados de cada decisão metodológica sobre o desempenho dos modelos, assegurando a robustez, rastreabilidade e profundidade da análise comparativa entre as alternativas testadas.

2.8 Métricas de Desempenho

Para avaliar a performance do modelo de regressão baseado na técnica XGBoost (Extreme Gradient Boosting), são utilizadas métricas específicas que quantificam a proximidade entre os valores previstos e os valores reais observados. Dentre as métricas mais relevantes para problemas de regressão, destacam-se o Erro Absoluto Médio (MAE), o Erro Quadrático Médio (MSE), a Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Determinação (R^2).

O MAE (*Mean Absolute Error*) representa a média das diferenças absolutas entre os valores previstos e os reais, sendo uma métrica intuitiva que expressa o erro médio em unidades da variável dependente. Já o MSE (*Mean Squared Error*) enfatiza erros maiores ao elevar ao quadrado as diferenças entre as previsões e os valores reais, penalizando fortemente previsões distantes da realidade. A RMSE (*Root Mean Squared Error*) é a raiz quadrada do MSE e mantém a unidade original da variável, facilitando a interpretação do erro médio esperado por previsão.

Entretanto, neste projeto, a métrica escolhida para comparar os diferentes modelos foi o R^2 (Coeficiente de Determinação). O R^2 mede a proporção da variabilidade da variável resposta que é explicada pelo modelo. Um valor de R^2 próximo de 1 indica que o modelo é altamente explicativo, enquanto valores próximos de 0 indicam baixa capacidade preditiva.

A escolha do R^2 como métrica principal se justifica por sua capacidade de resumir, de forma clara e comparável, a qualidade geral do ajuste do modelo.

Portanto, todas essas métricas foram analisadas, mas prioriza-se o R^2 como principal critério de desempenho para a validação do modelo implementado com XGBoost.

3. Obtenção e Tratamento dos Dados

3.1 Justificativa para a Escolha dos Dados/Atributos

As enchentes na Amazônia Legal são um fenômeno recorrente e complexo, causadas principalmente pela combinação entre chuvas intensas e prolongadas e alterações no uso do solo. A região é naturalmente propícia à ocorrência de inundações sazonais, especialmente nos períodos de cheia dos rios, entre os meses de fevereiro e maio. No entanto, estudos recentes

apontam que esses eventos estão se intensificando em frequência, duração e severidade, como consequência direta das mudanças climáticas e do desmatamento.

Em particular, a cidade de Manaus, situada entre os rios Negro e Solimões, é altamente vulnerável a esses eventos, especialmente durante os meses de cheia, entre fevereiro e maio. Nos últimos anos, a ocorrência de cheias severas, como as registradas em 2009, 2012 e 2021, tornou-se mais frequente e intensa, evidenciando os impactos das mudanças climáticas e da pressão antrópica sobre o ciclo hidrológico da região.

A cheia de 2021, por exemplo, foi a maior já registrada em mais de um século, com o Rio Negro atingindo 30 metros de altura em Manaus, afetando gravemente comunidades, infraestrutura urbana e operações logísticas [ANA, 2021]. Esse tipo de evento representa um risco direto não apenas para a população, mas também para o funcionamento e o planejamento de sistemas de energia, particularmente em uma cidade que ainda depende, em parte, de sistemas termelétricos caros e poluentes. A previsão de vazão dos rios, portanto, surge como uma ferramenta estratégica para antecipar situações críticas e viabilizar um modelo de expansão energética mais seguro, sustentável e resiliente.

Com base nesse cenário, os dados selecionados para o projeto foram escolhidos com o propósito específico de alimentar modelos de previsão da vazão dos rios de Manaus, visando fornecer subsídios técnicos para o planejamento da infraestrutura energética renovável, com menor risco de interrupções ou danos associados a eventos hidrológicos extremos.

Além dos fatores climáticos, o desmatamento altera o ciclo hidrológico, reduzindo a infiltração da água no solo, aumentando o escoamento superficial e, consequentemente, a vazão dos rios em períodos de chuva. Isso cria um cenário onde chuvas intensas, que antes seriam parcialmente absorvidas pelo solo e pela vegetação, passam a escoar rapidamente, provocando inundações súbitas e destrutivas.

Para explicar melhor a correlação entre os atributos e as enchentes, podemos citar o exemplo do ocorrido no Rio Grande do Sul, em setembro de 2023. Uma combinação de chuvas excepcionais e solo encharcado levou à pior enchente da história recente do estado. Segundo o INMET, em apenas 5 dias, algumas cidades registraram mais de 300 mm de chuva, o equivalente ao volume esperado para o mês inteiro [INMET, 2023]. Isso prova uma inevitável correlação entre chuvas e enchentes.

Com isso, os atributos escolhidos refletem os principais fatores que influenciam a dinâmica hidrológica da região.

Os dados selecionados incluem:

- Precipitação (ANA/INMET)
- Vazão dos rios (ANA)
- Temperatura

- Umidade relativa do ar
- Pressão atmosférica e radiação solar
- Dados de desmatamento (TerraBrasilis/MapBiomas)

Essas variáveis foram escolhidas por representarem os principais mecanismos que controlam o comportamento hidrológico da bacia e, portanto, são fundamentais para a previsão da vazão dos rios. A seguir, detalha-se a importância de cada uma delas no contexto do modelo preditivo:

A chuva é a principal força motriz da dinâmica de vazão. A intensidade e a distribuição temporal das precipitações determinam o volume de água que alimenta os rios. Eventos extremos de precipitação podem gerar aumento súbito de vazão, enquanto chuvas moderadas, mas persistentes, também afetam o nível dos rios. Para capturar esse efeito acumulativo, foram utilizadas variáveis derivadas como chuva acumulada em janelas de 3, 7 e 14 dias, que ajudam a modelar a defasagem temporal entre a chuva e a resposta do rio. Esses dados são indispensáveis para prever picos de vazão, identificar tendências sazonais e antecipar riscos de cheia.

A vazão representa a saída do sistema hidrológico e é o alvo direto da modelagem preditiva. Os dados de vazão são usados tanto como variável de saída do modelo. A análise da série histórica permite identificar padrões sazonais, eventos extremos, médias móveis e comportamentos cíclicos que alimentam algoritmos como XGBoost e Random Forest.

O desmatamento altera a resposta do solo à chuva, reduzindo sua capacidade de infiltração e aumentando o escoamento superficial. Isso significa que a mesma quantidade de chuva pode gerar uma vazão muito maior em áreas desmatadas, aumentando o risco de enchentes. Embora o desmatamento seja uma variável estática no curto prazo, ele funciona como indicador estrutural da sensibilidade da bacia, impactando a intensidade e a rapidez com que os rios reagem à precipitação. Seu uso no modelo permite capturar diferenças entre anos e áreas com diferentes graus de cobertura vegetal, oferecendo maior capacidade explicativa para o modelo. Além disso, é um fator crítico para avaliar o impacto humano no ecossistema. Segundo o MapBiomas, a Amazônia perdeu mais de 17% de sua cobertura original até 2022, o que impacta diretamente o equilíbrio do ciclo da água.

Essas variáveis não estão diretamente ligadas à vazão, mas funcionam como moduladores do sistema hidrológico. A temperatura e a radiação solar, por exemplo, afetam a evaporação da água e a umidade do solo, alterando a quantidade de água que efetivamente escorre para os rios. A pressão atmosférica pode indicar a chegada de sistemas meteorológicos, como frentes frias, que antecedem chuvas intensas. Já a umidade relativa do ar pode indicar se o solo está seco ou saturado. Em conjunto, essas variáveis aumentam a capacidade do modelo de capturar condições atmosféricas que antecedem eventos de chuva ou modulam sua intensidade, melhorando a previsão de vazão em termos de tempo e magnitude.

A escolha dessas variáveis está alinhada ao objetivo central do projeto, que é prever com precisão a vazão dos rios em Manaus para subsidiar estratégias de resiliência energética. Ao

antecipar variações críticas no fluxo dos rios, é possível evitar danos a infraestruturas renováveis como turbinas ou usinas flutuantes, planejar a distribuição de energia de forma mais eficiente e promover uma transição energética segura na região. As variáveis climáticas e hidrológicas permitem capturar a resposta imediata do sistema fluvial às chuvas, enquanto o desmatamento atua como modulador da vulnerabilidade da bacia, afetando a magnitude da vazão mesmo em chuvas de mesma intensidade. Essa integração entre fatores de curto e longo prazo é essencial para garantir que o modelo reflita a realidade local e ofereça suporte efetivo à tomada de decisão energética sustentável.

3.2 Fontes dos Dados

Os dados utilizados no projeto foram obtidos exclusivamente de fontes públicas, confiáveis e amplamente reconhecidas pela comunidade científica e por órgãos governamentais. A escolha dessas fontes visou garantir a qualidade, abrangência geográfica e a consistência temporal necessária para a construção de um modelo robusto de previsão de enchentes na Amazônia Legal.

As informações hidrológicas e pluviométricas, fundamentais para a análise da dinâmica das cheias, foram extraídas do sistema HidroWeb, mantido pela Agência Nacional de Águas e Saneamento Básico (ANA). Essa plataforma disponibiliza séries temporais diárias e mensais de vazão e precipitação de estações distribuídas por todo o território brasileiro, incluindo regiões remotas da Amazônia, que podem ser retiradas via API. Os dados da ANA são amplamente utilizados em estudos acadêmicos, planos de bacia e políticas públicas de gestão de recursos hídricos, sendo validados tecnicamente por especialistas da área, fazendo deles altamente confiáveis.

Os dados climáticos, como temperatura do ar, umidade relativa, pressão atmosférica, radiação solar e velocidade do vento, foram obtidos junto ao Instituto Nacional de Meteorologia (INMET), por meio do seu banco de dados meteorológicos (BDMEP). Essas informações são fornecidas por estações automáticas e convencionais espalhadas pelo país, com atualizações frequentes e cobertura de longa data, sendo essenciais para a caracterização do contexto atmosférico em que ocorrem os eventos extremos.

No que diz respeito ao desmatamento e uso da terra, foram utilizados dados do Projeto MapBiomas, em parceria com o sistema TerraBrasilis, desenvolvido pelo Instituto Nacional de Pesquisas Espaciais (INPE). Esses dados oferecem séries anuais de alta resolução sobre a cobertura vegetal e alterações no uso do solo desde 1985, permitindo o monitoramento preciso da degradação florestal em escala municipal. Por sua metodologia consolidada e transparência científica, o MapBiomas é uma das principais referências em estudos sobre a Amazônia e mudanças ambientais no Brasil.

3.3 Procedimentos de Limpeza/Transformação/Redução

Após a coleta dos dados brutos, foi necessário realizar uma série de etapas de pré-processamento para garantir a qualidade e a consistência dos dados utilizados no modelo de previsão de enchentes. Desta forma, é possível encontrar a extração dos dados via API da Hidroweb no repositório *modelo-previsao-enchente* [SCOFIELD, 2025]. No repositório de *modelo-previsao-enchentes* [SCOFIELD, 2025] é possível encontrar as funções de pré-processamento e extração. Por fim, no repositório *previsao-enchentes-amazonia* [HOERDE, SCOFIELD e SIQUEIRA, 2025] estão contidos todos os códigos e dados do projeto de forma localizada.

O primeiro processo consistiu no pré-processamento dos dados extraídos via API. A obtenção desses dados junto à plataforma HidroWeb da ANA exigiu uma série de etapas técnicas. Inicialmente, foi necessário realizar a autenticação por meio da geração de um token, utilizando credenciais fornecidas pela própria agência. Em seguida, realizou-se a busca pelos códigos das estações hidrológicas pertencentes aos estados que compõem a Amazônia Legal. Como o objetivo era obter informações de precipitação e vazão, foi preciso filtrar as estações conforme seu tipo (pluviométricas e fluviométricas).

A extração foi realizada para o período de 1991 a 2024, e cada requisição foi feita individualmente por código de estação e por município. Os dados retornados pela API apresentavam um formato não estruturado, com colunas separadas para cada dia do mês, totalizando até 31 colunas por registro mensal. Foi, portanto, necessário transformar esses dados para o formato “*long*”, no qual cada linha representa um único registro diário. Assim, tanto para os dados de chuva quanto de vazão, obteve-se um formato padronizado contendo três colunas: valor observado (chuva ou vazão), data da medição e código da estação.

Por fim, os *dataframes* gerados individualmente para cada código de estação foram concatenados, permitindo a formação de um dataframe único por estado, já pronto para etapas posteriores de limpeza e integração.

	data	vazao	estacao
0	2024-03-01	1871.33090	12650000
1	2024-03-02	2131.55300	12650000
2	2024-03-03	2227.32860	12650000
3	2024-03-04	2281.16430	12650000
4	2024-03-05	2190.41380	12650000
5	2024-03-06	1652.10630	12650000
6	2024-03-07	1298.46610	12650000
7	2024-03-08	1306.45630	12650000

Tabela 1 : Trecho do dataframe de dados de vazão extraídos via API Hidroweb

Como se pode ver por um trecho do *dataframe* final de vazão, ainda foi necessário seguir outras etapas de pré-processamento.

Para melhor facilitar a integração entre os outros *dataframes*, começamos separando a coluna de data em 3, uma para dia, mês e ano. Esse processo foi feito para todos os *dataframes* inclusos no projeto. Em seguida, precisamos entender a que esse código de estação corresponde. Assim, foi feito um *merge* com a tabela de códigos de estação, obtendo então uma nova coluna de município e UF. Essa tabela com os códigos de estação também foi extraída via API Hidroweb.

O que se diz a respeito do pré-processamento de todos os dados em geral, iniciamos com a padronização de nomes de colunas, formatos de data e tipos de dados. Diversas fontes apresentavam estruturas heterogêneas, exigindo a harmonização de variáveis e a conversão de dados para tipos adequados (por exemplo, conversão de strings para datetime ou float).

Em seguida, foram aplicados os tratamentos de valores ausentes nos dados de vazão, precipitação, desmatamento e variáveis climáticas. Como os dados trabalhados possuem granularidade diária, adotou-se uma estratégia hierárquica de preenchimento com base em médias agregadas. Inicialmente, os valores ausentes foram preenchidos utilizando a média da respectiva coluna para o mesmo mês e município. Caso não houvesse dados suficientes naquele mês para realizar a imputação, utilizou-se a média anual daquele município. Persistindo a ausência de dados representativos a nível municipal, o preenchimento foi realizado com base na média estadual.

Durante o processo de pré-processamento, diferentes estratégias foram aplicadas para tratar as particularidades de cada conjunto de dados. No caso do *dataframe* climático, as colunas referentes à hora da medição foram descartadas, por não serem relevantes para a granularidade desejada. Em seguida, os dados horários foram agrupados por média diária, resultando em um dataset climatológico diário por município, mais adequado à integração com os dados de vazão e precipitação.

Com relação aos dados de desmatamento, havia inicialmente dois *dataframes* distintos: um proveniente do TerraBrasilis (INPE) e outro da plataforma DataZoom. Após a união dos dados climáticos, pluviométricos e de vazão em um único *dataframe* consolidado por município e data, foi realizada a mesclagem dos dados de desmatamento. As colunas com dados ausentes no *dataframe* do TerraBrasilis foram preenchidas com as informações equivalentes do DataZoom, garantindo maior cobertura espacial. Como ambos os conjuntos apresentavam dados anuais, foi necessário realizar uma distribuição proporcional diária, convertendo os valores totais de desmatamento por ano em uma média diária uniforme ao longo do respectivo ano.

Além disso, para os casos em que dados de precipitação extraídos via API da HidroWeb estavam ausentes ou incompletos, foram utilizados dados complementares do INMET,

previamente tratados e organizados na mesma estrutura temporal. Isso garantiu maior robustez ao modelo e evitou perdas significativas de cobertura temporal ou espacial.

Durante a segunda sprint, uma das etapas complementares de limpeza dos dados envolveu a exclusão dos registros anteriores ao ano de 2000, após uma análise mais aprofundada das variáveis climáticas e hidrológicas desse período. Observou-se que, entre os anos de 1991 e 2000, havia uma ausência generalizada de dados, especialmente para variáveis meteorológicas como precipitação e temperatura. Para tentar contornar essa lacuna, havia sido inicialmente aplicada uma interpolação simples com base em médias mensais. No entanto, essa abordagem resultou em valores constantes ao longo de todos os dias dentro desse intervalo de anos, o que eliminava completamente a variabilidade natural esperada nesses fenômenos (como será evidenciado nos gráficos da Seção 4.6). Essa uniformidade artificial comprometeria a capacidade do modelo de aprendizado de máquina de identificar padrões reais e poderia introduzir viés na etapa de treinamento, uma vez que o modelo aprenderia com dados não representativos da realidade. Diante disso, optou-se pela remoção completa dos registros anteriores a 2000, preservando a integridade estatística do conjunto de dados e garantindo uma base mais fidedigna para a modelagem preditiva.

Todos esses procedimentos contribuíram para a construção de um dataset limpo, balanceado e apto a alimentar algoritmos de previsão baseados em aprendizado supervisionado, respeitando tanto a robustez estatística quanto a realidade socioambiental da Amazônia Legal.

3.4 Tamanho da Base Final

Inicialmente, a base de dados consolidada continha informações de todos os municípios da Amazônia Legal, totalizando centenas de milhares de registros. No entanto, após uma análise exploratória mais aprofundada, identificou-se uma alta variabilidade espacial nos padrões hidrológicos e climáticos entre os municípios, especialmente na relação entre chuva e vazão. Essa heterogeneidade geográfica comprometeria a eficácia de um modelo único e generalizado para toda a região.

Diante disso, optou-se por estruturar a análise por município, permitindo a construção de modelos individualizados que consideram as particularidades locais. Para essa etapa inicial, foram selecionados três municípios de estados distintos da Amazônia Legal, com o objetivo de avaliar se o modelo seria capaz de se adaptar corretamente a diferentes realidades geográficas e climáticas. Essa abordagem permitiu testar a robustez do modelo frente a diferentes combinações de variáveis ambientais.

Com a separação dos dados por município, a base final de cada um apresenta 24 colunas, incluindo variáveis como data, precipitação, vazão, desmatamento e atributos climáticos

derivados. O número de linhas varia de acordo com a série histórica disponível para cada localidade, podendo alcançar mais de 12.000 registros diários (equivalente a mais de 30 anos de dados). Por exemplo, a base de dados final para o município de Manaus possui 12022 linhas.

Essa estrutura modular possibilita a replicação do processo para qualquer município da Amazônia Legal, mantendo a flexibilidade analítica e respeitando as diferenças hidrológicas regionais.

3.5 Dicionário de Dados

Na tabela abaixo, pode-se ler um dicionário de dados, onde temos para cada variável o nome, o tipo de dado, uma descrição do significado e a unidade de medida, se aplicável.

Variável	Tipo	Descrição	Unidade de Medida
dia	inteiro	Dia do registro da observação	valor entre 1 e 31
mês	inteiro	Mês do registro da observação	valor entre 1 e 12
ano	inteiro	Ano do registro da observação	ano com quatro dígitos
município	texto	Nome do município ao qual pertencem os dados	—
uf	texto	Unidade federativa (estado) referente à origem geográfica original dos dados	—
areakm	float	Área desmatada no município no respectivo dia (média diária do valor anual)	km ²
vazao	float	Volume de água escoado no rio em determinado dia	m ³ /s (metros cúbicos por segundo)
chuva_final	float	Precipitação total registrada no dia	mm
chuva_acumulada_3d	float	Precipitação acumulada de 3 dias	mm
chuva_acumulada_7d	float	Precipitação acumulada de 7 dias	mm
chuva_acumulada_14d	float	Precipitação acumulada de 14 dias	mm

pressao_nivel_estacao_mb	float	Pressão atmosférica ao nível da estação	mbar (milibares)
pressao_max_ant_mb	float	Pressão máxima na hora anterior	mbar
pressao_min_ant_mb	float	Pressão mínima na hora anterior	mbar
radiacao_global_kj_m2	float	Radiação solar global acumulada no dia	kJ/m ²
temperatura_bulbo_seco_c	float	Temperatura do ar medida pelo bulbo seco	°C
temperatura_orvalho_c	float	Temperatura do ponto de orvalho	°C
temperatura_max_ant_c	float	Temperatura máxima registrada na hora anterior	°C
temperatura_min_ant_c	float	Temperatura mínima registrada na hora anterior	°C
orvalho_max_ant_c	float	Ponto de orvalho máximo na hora anterior	°C
orvalho_min_ant_c	float	Ponto de orvalho mínimo na hora anterior	°C
umidade_max_ant_pct	float	Umidade relativa do ar máxima na hora anterior	%
umidade_min_ant_pct	float	Umidade relativa do ar mínima na hora anterior	%
umidade_ar_pct	float	Umidade relativa do ar média no dia	%
vento_direcao_graus	float	Direção do vento	graus (0° a 360°)
vento_rajada_max_ms	float	Velocidade da rajada de vento mais forte registrada	m/s
vento_velocidade_ms	float	Velocidade média do vento	m/s

Tabela 2: Dicionário das variáveis presentes no dataset

4. Análise Exploratória dos Dados

4.1 Estatísticas Descritivas

Como o projeto trabalha com dados diários organizados por município, optamos por apresentar a análise estatística com base no município de Manaus, por ser uma das principais cidades da Amazônia Legal e por possuir boa disponibilidade de dados históricos. As tabelas a seguir apresentam os valores descritivos (média, mediana, mínimo, máximo, desvio padrão e quartis) para as variáveis mais relevantes do projeto.

	ano	mes	dia	chuva_final	vazao	areakm	pressao_nivel_estacao_mb	pressao_max_ant_mb	pressao_min_ant_mb	radiacao_global_kj_m2	temperatura_bulbo_seco_c
count	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000
mean	2007.013891	6.460988	15.728747	0.268014	126911.020746	0.124689	1004.139306	1004.572751	1003.840700	1210.765191	28.592236
std	9.590313	3.449050	8.800095	0.702046	40198.340769	0.335354	1.771716	1.813383	1.697107	420.955002	1.742863
min	1991.000000	1.000000	1.000000	0.000000	45847.793000	0.028104	990.825000	991.383333	989.608333	0.000000	21.091667
25%	1999.000000	3.000000	8.000000	0.000000	92636.350000	0.042103	1003.470105	1003.883333	1003.166667	908.793029	27.754167
50%	2007.000000	6.000000	16.000000	0.156492	124381.232000	0.069477	1004.287639	1004.707014	1004.023403	1291.296528	27.908333
75%	2015.000000	9.000000	23.000000	0.211944	157972.940000	0.088687	1004.708992	1005.130686	1004.415385	1478.250000	29.685133
max	2024.000000	12.000000	31.000000	40.800000	221909.250000	2.014484	1026.871429	1030.057143	1025.514286	3665.000000	35.542857
mediana	2007.000000	6.000000	16.000000	0.156492	124381.232000	0.069477	1004.287639	1004.707014	1004.023403	1291.296528	27.908333
variancia	91.974102	11.895949	77.441681	0.492868	1615906600.608900	0.112462	3.138978	3.288358	2.880173	177203.114105	3.037572
desvio_padrao	9.590313	3.449050	8.800095	0.702046	40198.340769	0.335354	1.771716	1.813383	1.697107	420.955002	1.742863

Tabela 3: Primeira parte da tabela descritiva de Manaus

	temperatura_orvalho_c	temperatura_max_ant_c	temperatura_min_ant_c	orvalho_max_ant_c	orvalho_min_ant_c	umidade_max_ant_pct	umidade_min_ant_pct	umidade_ar_pct	vento_direcao_graus	vento_rajada_max_ms	vento_velocidade_ms
count	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000
mean	23.000328	29.218165	27.871972	23.622469	22.410287	77.222288	69.942504	73.315830	135.383304	4.426441	1.565805
std	1.110339	1.759117	1.645269	1.061218	1.141696	9.008614	9.139540	9.320165	41.140586	0.791005	0.420210
min	14.383333	21.458333	20.825000	15.858333	12.983333	40.250000	33.333333	36.250000	23.400000	1.050000	0.150000
25%	22.472727	28.431111	27.057847	23.028637	21.905195	72.225694	64.760417	67.795139	105.000000	4.000000	1.310556
50%	23.425000	28.538462	27.200000	24.028869	22.875000	80.384615	73.083333	76.500000	148.666667	4.408750	1.408333
75%	23.679931	30.308970	28.955950	24.258333	23.040347	83.220139	74.943750	79.170139	149.581944	4.723077	1.800000
max	26.116667	36.300000	35.128571	27.200000	25.800000	100.000000	99.000000	99.600000	355.000000	16.850000	3.700000
mediana	23.425000	28.538462	27.200000	24.028869	22.875000	80.384615	73.083333	76.500000	148.666667	4.408750	1.408333
variancia	1.232852	3.094493	2.706910	1.126184	1.303470	81.155131	83.531184	86.865470	1692.547779	0.625689	0.176576
desvio_padrao	1.110339	1.759117	1.645269	1.061218	1.141696	9.008614	9.139540	9.320165	41.140586	0.791005	0.420210

Tabela 4: Segunda parte da tabela descritiva de Manaus

	ano	mes	dia	chuva_final	vazao	areakm
count	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000	12022.000000
mean	2007.013891	6.460988	15.728747	0.268014	126911.020746	0.124689
std	9.590313	3.449050	8.800095	0.702046	40198.340769	0.335354
min	1991.000000	1.000000	1.000000	0.000000	45847.793000	0.028104
25%	1999.000000	3.000000	8.000000	0.000000	92636.350000	0.042103
50%	2007.000000	6.000000	16.000000	0.156492	124381.232000	0.069477
75%	2015.000000	9.000000	23.000000	0.211944	157972.940000	0.088687
max	2024.000000	12.000000	31.000000	40.800000	221909.250000	2.014484
mediana	2007.000000	6.000000	16.000000	0.156492	124381.232000	0.069477
variancia	91.974102	11.895949	77.441681	0.492868	1615906600.608900	0.112462
desvio_padrao	9.590313	3.449050	8.800095	0.702046	40198.340769	0.335354

Tabela 5: Tabela descritiva das principais variáveis para o município de Manaus

A Tabela 5 apresenta estatísticas descritivas das principais variáveis utilizadas na modelagem preditiva da vazão dos rios, com foco no município de Manaus. Os dados abrangem o período de 1991 a 2024, totalizando 12.022 observações diárias. Entre as variáveis analisadas estão os componentes temporais (ano, mês e dia), a precipitação acumulada diária (chuva_final), a vazão dos rios (em m³/s) e a área desmatada por dia (areakm).

No que se refere à variável de precipitação (chuva_final), observa-se uma média diária de apenas 0,268 mm, com desvio padrão de 0,70 mm. Esse valor relativamente alto de dispersão em relação à média indica que a variável possui grande variabilidade, com muitos dias sem chuva (mínimo de 0 mm) e alguns episódios de precipitação intensa, cujo valor máximo atinge 40,8 mm. Essa característica reforça a presença de uma distribuição assimétrica à direita, típica de regiões tropicais como a Amazônia, onde a maior parte dos dias são secos ou com pouca chuva, intercalados por eventos extremos. Essa variável, portanto, é fundamental para o modelo, pois representa o principal fator direto de aumento da vazão e ocorrência de enchentes. Sua variabilidade e comportamento esparsos requerem cuidados no pré-processamento, como transformações de escala ou normalização.

A variável de vazão dos rios, que constitui o alvo (variável dependente) do modelo, apresenta média de 126.911 m³/s e desvio padrão elevado, em torno de 40.198 m³/s. A mediana (124.381 m³/s) é próxima da média, o que indica uma distribuição aproximadamente simétrica. No entanto, os valores extremos são bastante amplos, com um mínimo de 45.847 m³/s e um máximo de 221.909 m³/s. Esses números refletem a ocorrência de eventos sazonais extremos, como secas severas e cheias históricas, como a de 2021. A alta variância da variável de vazão exige que o modelo seja capaz de lidar com padrões não lineares e outliers, o que justifica a escolha de algoritmos como Random Forest e XGBoost. A análise estatística dessa variável também permite verificar a consistência dos dados e reforça sua adequação ao objetivo do estudo, que é antecipar variações significativas no comportamento fluvial.

No caso da variável “areakm”, que representa a área desmatada por dia em quilômetros quadrados, os valores mostram pouca variabilidade: a média é de 0,124 km²/dia, com desvio padrão de 0,335. O valor máximo registrado é de 2,014 km²/dia e o mínimo de 0,028. Essa pequena dispersão sugere que o desmatamento se comporta como uma variável praticamente estática na granularidade diária. Apesar disso, a variável foi mantida na base por sua relevância estrutural. O desmatamento impacta o ciclo hidrológico da região ao reduzir a capacidade de infiltração do solo e aumentar o escoamento superficial, alterando a resposta das bacias aos eventos de chuva. Dessa forma, mesmo com baixa variação no curto prazo, o desmatamento pode explicar padrões de vazão ao longo de meses ou anos, principalmente em regiões fortemente alteradas.

A análise das variáveis temporais (ano, mês e dia) reforça a amplitude e a completude da série histórica utilizada, cobrindo mais de três décadas. A média do ano dos registros é 2007, com distribuição relativamente uniforme entre meses e dias, o que assegura a validade das análises sazonais e permite modelar os efeitos de eventos recorrentes, como as cheias de início de ano. A presença dessas colunas também viabiliza o uso de transformações temporais, como a criação de variáveis derivadas (estações do ano, tendência anual, autocorrelação, etc.).

De modo geral, as estatísticas descritivas demonstram que as variáveis escolhidas são adequadas ao objetivo do projeto. Elas capturam os principais fatores que influenciam a dinâmica hídrica na região de Manaus, incluindo aspectos climáticos (chuva), hidrológicos (vazão) e ambientais (desmatamento). A escolha dessas variáveis em detrimento de outras se baseia em critérios como disponibilidade histórica, granularidade diária e relação direta com o fenômeno de interesse. A integração entre esses dados permite compreender melhor os padrões de comportamento dos rios amazônicos, oferecendo uma base sólida para o treinamento de modelos de aprendizado supervisionado voltados à previsão de vazão e, por consequência, à mitigação dos impactos das cheias na região.

No que se refere às variáveis climáticas (Tabela 3 e Tabela 4), a radiação solar global (kJ/m²) apresenta ampla variação, com média de 1.210,7, desvio padrão elevado (420,9) e valores extremos que vão de 0 até 3.665 kJ/m². Essa variabilidade está diretamente relacionada à cobertura de nuvens, à duração do dia e à estação do ano. Altos índices de radiação estão geralmente associados a dias secos, enquanto valores baixos podem indicar cobertura densa de nuvens, possivelmente antecedendo chuvas. Essa variável é relevante como um indicador complementar da condição atmosférica.

As temperaturas médias, máximas e mínimas mostram uma distribuição relativamente estável. A temperatura média do ar (bulbo seco) gira em torno de 28,6 °C, com máximo de 35,5 °C e desvio padrão de 1,74 °C. As temperaturas máximas e mínimas do dia anterior variam de forma semelhante, mantendo coerência com o clima equatorial da região, marcado por pouca oscilação térmica ao longo do ano. Já a temperatura de orvalho apresenta média de 23 °C, com desvio padrão baixo (1,1 °C), o que indica estabilidade na umidade atmosférica.

A umidade relativa do ar é bastante elevada, como esperado em regiões tropicais úmidas. A média diária da variável `umidade_ar_pct` é de aproximadamente 73%, com máximas

ultrapassando 99%. A baixa variância reforça a estabilidade desse parâmetro na região, ainda que eventos de menor umidade (por volta de 33%) também estejam registrados. Esses dados são importantes porque a umidade elevada favorece a saturação do solo e pode prolongar a permanência da água na superfície, contribuindo para enchentes.

Por fim, as variáveis relacionadas ao vento apresentam maior dispersão. A direção média do vento é de 135°, com grande variância (1692°), refletindo a natureza errática dos ventos de superfície em áreas florestais. A velocidade média do vento é de apenas 1,56 m/s, mas com rajadas máximas registradas acima de 16 m/s, indicando que, embora o regime de vento em Manaus seja brando, episódios pontuais de ventos fortes podem ocorrer. A influência do vento na modelagem de vazão é mais indireta, podendo auxiliar na identificação de tempestades ou frentes úmidas.

Em síntese, os dados climáticos disponíveis são ricos, variados e coerentes com as condições meteorológicas típicas da região amazônica. Embora algumas variáveis apresentem baixa variabilidade (como pressão e umidade), elas ainda fornecem contexto atmosférico valioso. Outras, como radiação solar e temperatura, apresentam maior variabilidade diária e potencial de contribuição para o modelo, especialmente em combinação com as variáveis de precipitação e desmatamento. A presença de registros meteorológicos de dias anteriores também permite a inclusão de lags e features temporais derivadas, o que pode melhorar a performance preditiva do modelo de aprendizado supervisionado proposto.

4.2 Visualizações de Distribuição

Por haverem muitos atributos no conjunto de dados, apresentamos a seguir as visualizações das principais variáveis para a análise hidrológica e ambiental, sendo elas: chuva, vazão e área de desmatamento de Manaus.




Gráfico 1 : Distribuição de frequência dos dados de vazão em Manaus

O Gráfico 1 apresenta a distribuição de frequência dos valores de vazão diária dos rios em Manaus, após o pré-processamento dos dados. Trata-se de um histograma com sobreposição de uma curva de densidade estimada (KDE), que permite visualizar o formato da distribuição dos dados ao longo do tempo.

Observa-se que a distribuição da variável vazão não é perfeitamente simétrica, mas também não apresenta uma assimetria muito acentuada. A curva de densidade é relativamente suave, com um leve achatamento no centro e cauda à direita, indicando que, embora os valores mais comuns estejam entre aproximadamente 80.000 m³/s e 160.000 m³/s, ainda há ocorrência de valores extremos na parte superior da distribuição, isto é, eventos de cheia.

O pico de frequência ocorre em torno de 85.000 a 95.000 m³/s, indicando que essa faixa concentra a maior parte dos dias observados. No entanto, a distribuição é relativamente dispersa, com frequências significativas também em faixas superiores, o que confirma os achados das estatísticas descritivas, especialmente o alto desvio padrão da variável (aproximadamente 40.198 m³/s). Isso reforça a necessidade de que o modelo preditivo seja capaz de capturar eventos fora do comportamento médio, como períodos de cheia ou seca severa.

Além disso, o gráfico não apresenta picos abruptos nem lacunas, o que sugere que os dados são bem distribuídos ao longo do intervalo observado, sem a presença de valores ausentes ou agrupamentos artificiais. A cauda da distribuição, visível à direita (acima de 180.000 m³/s), representa eventos hidrológicos extremos que, embora menos frequentes, têm alto impacto ambiental e social, sendo críticos para a proposta do modelo de previsão.

Em resumo, o histograma evidencia que a variável de vazão possui variabilidade natural elevada, mas com concentração em torno de valores intermediários. Isso valida a escolha de algoritmos capazes de lidar com dados contínuos, não normalizados e com possíveis outliers, como Random Forest e XGBoost. A análise gráfica também complementa a análise estatística, ao demonstrar visualmente a dispersão e a densidade dos dados, permitindo avaliar se a modelagem exigirá técnicas adicionais de transformação ou tratamento de valores extremos.




Gráfico 2 : Distribuição de frequência dos dados de chuva em Manaus

O Gráfico 2 apresenta a distribuição de frequência da variável “chuva_final”, representando os valores diários de precipitação registrados em Manaus ao longo do período analisado. A visualização mostra de forma clara o comportamento altamente assimétrico da variável de chuva, típico de regiões com regime tropical úmido.

Observa-se que a maior parte dos registros está concentrada à esquerda do gráfico, especialmente entre 0 e 1,5 mm, com uma frequência extremamente alta de dias com pouca ou nenhuma chuva. O valor mais frequente é zero, o que indica que há um grande número de dias secos ou com precipitação residual, o que é coerente com o regime amazônico de chuvas concentradas em períodos específicos do ano. Conforme a precipitação aumenta, a frequência cai de forma exponencial, gerando uma cauda longa à direita, típica de uma distribuição fortemente assimétrica.

Esse comportamento confirma as estatísticas descritivas apresentadas anteriormente, em que a média da variável é de 0,268 mm e o desvio padrão é relativamente alto (0,70 mm), mesmo com muitos valores baixos.

A forma da distribuição reforça a necessidade de tratamentos específicos na etapa de pré-processamento, como transformações logarítmicas, normalizações robustas ou uso de modelos que lidem bem com variáveis com distribuição assimétrica e valores zero. Além disso, a frequência elevada de zeros ou valores próximos de zero pode motivar abordagens específicas, como a criação de variáveis derivadas, sendo elas janelas móveis acumuladas (chuva dos últimos 3 ou 7 dias), que captam melhor os efeitos acumulativos sobre a vazão.

Em termos de modelagem preditiva, essa variável é essencial por representar a principal entrada causal direta de alterações no nível dos rios. O gráfico evidencia que o modelo deverá ser capaz de detectar padrões não apenas em valores absolutos de chuva, mas também nas mudanças

bruscas e nos eventos raros, que são os mais relevantes para o contexto de gestão de riscos ambientais e planejamento urbano.




Gráfico 3 : Distribuição de frequência dos dados de área de desmatamento em Manaus

O Gráfico 3 representa a distribuição de frequência da variável “areakm”, que corresponde à área de desmatamento expressa em quilômetros quadrados por dia. A análise revela uma distribuição altamente assimétrica à direita, com a imensa maioria dos valores concentrados em uma faixa muito estreita próxima de zero. Essa concentração ocorre entre 0,02 e 0,15 km²/dia, onde estão localizados mais de 10.000 dos 12.022 registros totais.

A forma da curva de densidade (KDE) confirma essa concentração, apontando que há uma frequência massiva de dias com baixíssimos níveis de desmatamento, sugerindo que, na maior parte do tempo, as taxas diárias de desmatamento são praticamente constantes e muito pequenas. Isso ocorre porque os dados originais de desmatamento eram anuais e foram convertidos para valores diários por distribuição proporcional. Ou seja, mesmo grandes áreas desmatadas ao longo do ano se transformam, ao serem divididas por 365 dias, em pequenas frações diárias, o que explica essa homogeneidade.

Há também uma cauda longa e estreita à direita, com poucos registros acima de 0,5 km²/dia e raríssimos eventos em torno de 2,0 km²/dia. Esses valores extremos são outliers gerados possivelmente por municípios que apresentaram maiores áreas desmatadas acumuladas no ano. Ainda assim, sua ocorrência diária é rara.

Essa característica sugere que a variável “areakm” apresenta baixa variabilidade temporal na escala diária, e se comporta como uma variável quase estática no curto prazo. Embora isso

possa diminuir seu impacto direto em modelos de previsão diária de vazão, o desmatamento é um importante fator estrutural de alteração do ciclo hidrológico da bacia amazônica, influenciando o escoamento superficial, a infiltração da água no solo e a resposta dos rios a eventos de chuva.

Em síntese, o gráfico reforça a ideia de que a área desmatada deve ser tratada como uma variável de longo prazo, com potencial explicativo indireto e complementar na previsão de vazão dos rios, principalmente em contextos de degradação ambiental persistente

A análise conjunta dos Gráficos 1, 2 e 3 permite compreender a dinâmica e o comportamento estatístico das três principais variáveis envolvidas na modelagem de previsão de vazão dos rios em Manaus: vazão, chuva e área desmatada.

De forma integrada, os gráficos mostram que o conjunto de dados utilizado combina variáveis com comportamentos estatísticos distintos, o que reforça a importância de uma abordagem de modelagem robusta, capaz de lidar com distribuições assimétricas, outliers e diferentes escalas de variação. Essa diversidade de padrões é coerente com a complexidade do sistema hidrológico amazônico e reforça a adequação das variáveis escolhidas ao objetivo de prever com maior precisão os episódios de vazão elevada nos rios da região.

4.3 Análise de Correlação

Para investigar relações entre as variáveis numéricas do conjunto de dados, foram construídas matrizes de correlação utilizando o coeficiente de Spearman, uma medida não paramétrica apropriada para detectar relações, mesmo que não lineares. Os resultados foram visualizados por meio de heatmaps (ou então Matriz de Correlação), que destacam tanto a força quanto a direção das correlações.




Gráfico 4: Matriz de correlação entre todos os atributos de Manaus

O Gráfico 4 apresenta a matriz de correlação de Spearman entre todos os atributos do conjunto de dados de Manaus, após o pré-processamento. Essa matriz permite identificar relações monotônicas entre variáveis, independentemente de sua linearidade, sendo particularmente útil em contextos com variáveis não normalmente distribuídas ou com presença de outliers, como é o caso de dados ambientais e hidrológicos.

A análise mostra que a variável vazão apresenta correlação moderada com algumas variáveis, embora nenhuma delas tenha correlação forte (acima de 0,5). Os maiores coeficientes de correlação com vazão são observados com:

- `pressao_min_ant_mb` ($\rho \approx 0.34$),
- `pressao_max_ant_mb` ($\rho \approx 0.33$),
- `pressao_nivel_estacao_mb` ($\rho \approx 0.33$).

Nota-se também que algumas variáveis apresentam correlação elevada entre si, como:

- `pressao_max_ant_mb`, `pressao_min_ant_mb` e `pressao_nivel_estacao_mb` (com $\rho > 0.95$),
- `temperatura_max_ant_c`, `temperatura_min_ant_c` e `temperatura_bulbo_seco_c` (também com ρ elevada),
- `umidade_max_ant_pct`, `umidade_min_ant_pct` e `umidade_ar_pct`.

Essa alta colinearidade entre variáveis pode prejudicar modelos lineares e distorcer a importância de atributos. Por isso, é importante aplicar técnicas de seleção de atributos, como RFE ou SelectKBest, além de considerar a redução de dimensionalidade ou agregação de variáveis com forte redundância.




Gráfico 5: Matriz de correlação entre as variáveis de área de desmatamento, chuva acumulada de 3 dias e vazão de Manaus

O Gráfico 5 apresenta uma matriz de correlação de Spearman entre três variáveis de interesse no estudo: área de desmatamento (`areakm`), chuva acumulada em 3 dias (`chuva_acumulada_3d`) e vazão dos rios de Manaus. O objetivo principal desta análise foi verificar se a utilização de uma janela temporal de chuva acumulada, neste caso, uma soma dos volumes pluviométricos dos últimos três dias, poderia aumentar a correlação com a vazão, servindo como um indicativo mais robusto da resposta hidrológica da bacia em comparação ao uso da chuva diária isolada.

No entanto, os resultados indicam que a janela de 3 dias de chuva acumulada não gerou correlação significativa com a variável vazão, apresentando um coeficiente de apenas -0,05. Esse valor é próximo de zero e indica ausência de relação monotônica direta entre a variável derivada e a variável-alvo. De forma semelhante, a correlação entre areakm (área de desmatamento) e vazão também foi muito baixa (-0,07), indicando que o modelo estatístico simples de correlação não capturou nenhum padrão relevante entre essas variáveis.

A baixa correlação da chuva acumulada em 3 dias pode ser explicada por diversos fatores. Primeiramente, é possível que o impacto da precipitação sobre a vazão dos rios ocorra com defasagens maiores que três dias, variando conforme as características físicas da bacia, como tipo de solo, cobertura vegetal, relevo e nível de saturação. Assim, o uso de janelas mais longas (como 7 ou 14 dias) poderá ser mais eficaz em capturar esse efeito acumulativo. Além disso, a relação entre chuva e vazão pode não ser estritamente monotônica, o que reduz a capacidade da correlação de Spearman de detectar esse tipo de padrão.

No caso do desmatamento, vale lembrar que os dados foram originalmente anuais e interpolados para granularidade diária, o que resulta em baixa variabilidade estatística dentro do ano. O desmatamento afeta o regime hídrico principalmente por meio de mudanças estruturais no uso do solo, evapotranspiração e capacidade de infiltração, sendo seu impacto mais perceptível em escalas temporais mais amplas ou por meio de interações com outras variáveis, como intensidade da chuva ou declividade.

Portanto, embora esperasse-se que o uso de chuva acumulada pudesse aumentar a correlação com a vazão, os resultados desta análise indicam que, isoladamente, a janela de 3 dias não foi suficiente para revelar essa associação. Esses achados reforçam a necessidade de utilizar modelos preditivos mais complexos, como os baseados em aprendizado de máquina, que consigam capturar interações não lineares, efeitos defasados e variáveis latentes, muitas vezes invisíveis em análises estatísticas simples. Além disso, sugerem que futuras análises deverão considerar outras janelas de agregação temporal, como 7 ou 14 dias, para explorar melhor o potencial informativo das variáveis pluviométricas sobre o comportamento da vazão em Manaus.




Gráfico 6: Matriz de correlação entre as variáveis de área de desmatamento, chuva acumulada de 14 dias e vazão de Manaus

A nova matriz de correlação apresentada mostra as relações entre três variáveis: areakm (área de desmatamento), chuva_acumulada_14d (chuva acumulada em 14 dias) e vazão, com coeficientes de Spearman utilizados para detectar associações monotônicas entre elas. O objetivo desta análise é verificar se ampliar a janela de agregação da chuva de 3 para 14 dias resulta em maior correlação com a vazão, o que indicaria uma maior capacidade da variável derivada de representar o comportamento hidrológico da bacia.

Os resultados, no entanto, mostram que a chuva acumulada em 14 dias apresenta uma correlação ainda mais fraca com a vazão do que a janela de 3 dias, com coeficiente de apenas -0,02. Esse valor indica uma praticamente inexistente relação monotônica entre a chuva acumulada em 14 dias e os valores de vazão registrados no mesmo período. De forma semelhante, a correlação entre areakm e vazão permanece em -0,07, exatamente como na matriz anterior, reforçando a estabilidade da ausência de correlação direta entre desmatamento e comportamento imediato da vazão.

Esse resultado sugere que, no intervalo de tempo considerado, a ampliação da janela de chuva acumulada não foi suficiente para revelar uma associação estatisticamente mais significativa com a variável de interesse. A ausência de correlação pode estar relacionada a vários fatores. Em primeiro lugar, é possível que o efeito da chuva sobre a vazão não se manifeste de maneira uniforme ou linear ao longo de 14 dias, sendo dependente de outros elementos do sistema, como nível prévio de saturação do solo, tipo de cobertura vegetal, capacidade de escoamento superficial e condições climáticas subsequentes. Em segundo lugar, a resposta hidrológica da bacia urbana de Manaus pode não ser sensível a médias simples de chuva acumulada, sendo mais influenciada por picos de intensidade ou chuvas concentradas em curto prazo.

Além disso, como destacado na análise da janela de 3 dias, o uso da correlação de Spearman por si só pode não ser capaz de capturar padrões não lineares ou interações complexas entre variáveis, principalmente em um sistema climático e hidrológico de alta complexidade como o da região amazônica.

Portanto, a análise com a janela de 14 dias, assim como a de 3 dias, não revelou evidência de relação direta entre chuva acumulada e vazão. Esses resultados reforçam a necessidade do uso de modelos preditivos baseados em aprendizado de máquina, capazes de incorporar defasagens temporais, variáveis combinadas e relações não lineares, oferecendo maior sensibilidade a padrões que não são captados por métodos de correlação simples. A comparação entre diferentes janelas temporais, embora não tenha mostrado impacto estatístico relevante neste momento, continua sendo uma abordagem válida dentro da engenharia de atributos e deverá ser expandida futuramente com variações na agregação, defasagem e cruzamento com outras variáveis.

4.4 Gráficos de Dispersão

Gráficos de dispersão foram utilizados para examinar as relações entre pares de variáveis fundamentais para o comportamento hidrológico: chuva diária, chuva acumulada em janelas de 3 e 14 dias, área de desmatamento (areakm) e vazão. Esse tipo de visualização é essencial para identificar padrões, tendências e outliers, além de avaliar a forma da relação entre variáveis, se linear, curvilínea ou inexistente.




Gráfico 7: Gráfico de distribuição dos dados de desmatamento e chuva acumulada de 14 dias em Manaus

O Gráfico 7 apresentado ilustra a relação entre a chuva acumulada nos últimos 14 dias (chuva_acumulada_14d) e a área desmatada média diária (areakm) ao longo do período analisado para o município de Manaus. A distribuição dos pontos no plano cartesiano revela uma dispersão ampla, sem indícios visuais de uma tendência linear clara entre as variáveis. Esse comportamento sugere uma fraca correlação direta, o que é coerente com os resultados encontrados nas análises de correlação de Spearman, cujos coeficientes são próximos de zero.

A variável chuva_acumulada_14d apresenta uma ampla variabilidade vertical, com registros que variam desde valores próximos a zero até picos superiores a 20 mm acumulados, independentemente do nível de desmatamento observado. Esse padrão indica que eventos de

chuva intensa ocorrem tanto em áreas com baixa alteração antrópica quanto em áreas com níveis mais elevados de desmatamento, não sendo possível, a partir da visualização, estabelecer uma dependência direta entre as variáveis.

No eixo horizontal, observa-se uma concentração da variável areakm entre 0,03 km² e 0,11 km², com grupos de pontos densamente dispostos em faixas verticais bem definidas. Esse comportamento reforça a natureza discretizada do dado de desmatamento, que, por ser originalmente anual, foi interpolado para valores diários. Como consequência, muitos registros repetem os mesmos valores de área ao longo do tempo, gerando o padrão de colunas verticais no gráfico de dispersão.

Em síntese, a análise visual confirma que não há relação linear aparente entre a área desmatada e a chuva acumulada em janelas de 14 dias. No entanto, isso não implica a irrelevância da variável areakm na modelagem hidrológica. Ao contrário, sua contribuição pode ser indireta e estrutural, modulando a forma como a bacia responde à precipitação. Ou seja, embora a quantidade de chuva não varie em função direta da área desmatada, a forma como essa água se transforma em escoamento superficial e, portanto, afeta a vazão dos rios, pode ser significativamente influenciada pela cobertura vegetal da região.




Gráfico 8: Gráfico de distribuição dos dados de vazão e desmatamento em Manaus

O Gráfico 8 apresenta a distribuição conjunta dos valores de vazão fluvial e da área desmatada ao longo do tempo, com base nos dados do município de Manaus. Assim como observado na análise anterior, a variável “areakm” (área desmatada) mostra-se discretizada e pouco variável, refletindo sua origem em dados anuais interpolados para uma resolução temporal diária. Essa característica gera o padrão de agrupamentos verticais ao longo do eixo das abscissas, indicando que em diversos períodos o valor diário da área desmatada permanece constante.

Em relação à variável de vazão, observa-se uma ampla dispersão vertical dos valores, variando entre aproximadamente 50.000 m³/s e 225.000 m³/s para praticamente todos os níveis de desmatamento. A ausência de uma tendência clara ou de agrupamentos inclinados no gráfico reforça a inexistência de uma relação linear direta entre área desmatada e vazão imediata. Essa conclusão é coerente com o resultado da matriz de correlação de Spearman, na qual o coeficiente entre essas duas variáveis é baixo, sugerindo que a influência do desmatamento sobre a vazão não se manifesta de forma direta ou isolada.

No entanto, é importante destacar que, embora a área desmatada não explique diretamente a variação instantânea da vazão, ela exerce um papel indireto relevante sobre a dinâmica hidrológica local. Áreas mais desmatadas tendem a apresentar maior escoamento superficial e menor capacidade de infiltração, o que pode amplificar o impacto das chuvas sobre o sistema fluvial. Ou seja, a mesma intensidade de precipitação pode gerar respostas de vazão diferentes dependendo do grau de cobertura vegetal da bacia hidrográfica.




Gráfico 9: Gráfico de distribuição dos dados de vazão e chuva em Manaus

O Gráfico 9 apresenta a relação entre a vazão fluvial e a chuva diária (chuva_final) registrada no município de Manaus. A análise do gráfico revela uma forte assimetria na distribuição da variável chuva_final, com grande concentração de pontos próximos a zero, refletindo o elevado número de dias com pouca ou nenhuma precipitação, um padrão esperado para regiões tropicais com regime de chuvas intermitente. Apesar disso, mesmo sob baixa precipitação diária, observa-se uma ampla faixa de valores de vazão, variando de aproximadamente 50.000 m³/s até mais de 200.000 m³/s.

Esse comportamento indica que a chuva do próprio dia não é, isoladamente, um bom preditor da vazão instantânea. A dispersão dos pontos não revela uma relação linear evidente, e os maiores valores de vazão ocorrem tanto em dias secos quanto em dias com precipitação significativa. Isso sugere a existência de defasagem temporal entre o evento de chuva e sua influência sobre o volume de água nos rios, o que é típico de grandes bacias hidrográficas, nas quais o escoamento superficial e a contribuição fluvial de regiões a montante demoram alguns dias para refletir na vazão local.

Além disso, o padrão disperso reforça a importância de considerar janelas acumuladas de precipitação, como chuva acumulada em 3, 7 ou 14 dias, que tendem a capturar melhor a influência hidrológica da água infiltrada ou escoada ao longo do tempo. A persistência de valores elevados de vazão em dias secos também pode estar associada à inércia hídrica do sistema, ou à influência de chuvas passadas em regiões adjacentes, especialmente em bacias extensas como as que compõem o entorno de Manaus.




Gráfico 10: Gráfico de distribuição dos dados de vazão e chuva acumulada de 3 dias em Manaus

O Gráfico 10 ilustra a distribuição dos dados de vazão fluvial em função da chuva acumulada em uma janela de três dias, com o objetivo de investigar a possível influência da precipitação recente sobre o comportamento dos rios em Manaus. Observa-se novamente uma alta concentração de pontos no intervalo entre 0 e 2 mm de chuva acumulada, o que reflete o regime pluviométrico característico da região, com muitos períodos secos ou de baixa precipitação distribuídos ao longo do tempo.

Apesar da predominância de registros com baixa precipitação, nota-se que, à medida que os valores de chuva_acumulada_3d aumentam, os valores de vazão tendem a se manter elevados, embora com ampla dispersão vertical. Ou seja, há uma tendência difusa de aumento da vazão em contextos de maior volume acumulado de chuva recente, o que sugere uma relação positiva, ainda que não linear nem fortemente correlacionada. Esse padrão é típico de sistemas hidrológicos com alta complexidade e múltiplas variáveis envolvidas, nos quais a resposta fluvial a eventos de chuva depende também de fatores como saturação do solo, desmatamento, relevo e defasagem temporal do escoamento.

É importante ressaltar que, diferentemente da chuva do próprio dia (analisada no Gráfico 9), a variável chuva_acumulada_3d capta de maneira mais eficaz o efeito da persistência de eventos de chuva sobre a bacia hidrográfica. Isso permite que o modelo estatístico identifique com mais clareza a contribuição do volume de água que se acumula ao longo de um curto intervalo de tempo, refletindo de maneira mais realista os mecanismos de geração de vazão superficial e subterrânea.

Apesar da dispersão dos pontos, o uso dessa variável acumulada é justificado pela capacidade de capturar efeitos hidrológicos defasados e pela melhoria que pode proporcionar ao desempenho dos modelos preditivos quando combinada com outras variáveis (como temperatura, umidade, desmatamento e lags de vazão).

Em resumo, o gráfico evidencia que a chuva acumulada em três dias possui uma contribuição relevante, porém não isolada, para explicar a variação da vazão dos rios em Manaus. Sua inclusão em modelos de aprendizado supervisionado é apropriada, especialmente quando utilizada em conjunto com outras janelas temporais e variáveis ambientais.




Gráfico 11: Gráfico de distribuição dos dados de vazão e chuva acumulada de 14 dias em Manaus

O Gráfico 11 explora a distribuição conjunta entre a variável dependente vazão e a variável explicativa “chuva_acumulada_14d”, com o objetivo de avaliar como o volume de precipitação acumulado ao longo de duas semanas pode influenciar a resposta hidrológica da bacia em Manaus. Diferentemente dos gráficos anteriores (que consideram chuva diária ou acumulada em três dias), este mostra uma distribuição mais ampla de valores ao longo do eixo horizontal, com maior presença de registros entre 0 e 20 mm acumulados, indicando maior variabilidade da variável “chuva_acumulada_14d”.

Visualmente, a dispersão dos pontos sugere uma correlação mais perceptível entre as variáveis, embora ainda fraca e não linear. Observa-se que, à medida que a chuva acumulada aumenta, há uma tendência de os valores de vazão permanecerem em níveis mais elevados, o que indica uma resposta hidrológica consistente ao acúmulo de água no solo e ao aumento do escoamento superficial. Ao mesmo tempo, a dispersão vertical para qualquer valor fixo de chuva acumulada permanece alta, reforçando que a vazão é influenciada por múltiplos fatores além da precipitação, como desmatamento, umidade do solo, tempo de resposta da bacia e vazões defasadas.

Esse comportamento é coerente com a natureza dos grandes sistemas fluviais amazônicos, nos quais o tempo de concentração da água nas bacias é mais longo, e os efeitos de chuvas sucessivas são mais bem captados por variáveis acumuladas em janelas temporais mais extensas. A “variável chuva_acumulada_14d”, portanto, consegue captar melhor o efeito da persistência de eventos de chuva sobre o sistema hídrico, em comparação com a chuva diária ou de curto prazo.

A análise comparativa dos gráficos de dispersão entre a variável dependente vazão e as variáveis de precipitação (“chuva_final”, “chuva_acumulada_3d” e “chuva_acumulada_14d”) revela diferenças importantes no comportamento hidrológico da bacia de Manaus frente ao volume e à persistência da chuva.

Em síntese, quanto maior a janela temporal considerada para o acúmulo de precipitação, mais evidente se torna a conexão com os níveis de vazão, destacando a importância da memória hidrológica do sistema. Portanto, variáveis acumuladas em janelas móveis (especialmente 14 dias) são mais informativas e robustas para fins de modelagem preditiva da vazão, devendo ser priorizadas em algoritmos de aprendizado supervisionado.

4.5 Análise de Dados Categóricos

O conjunto de dados utilizado neste projeto é composto exclusivamente por variáveis numéricas contínuas, como precipitação (chuva_final), vazão (vazao), variáveis climáticas e medidas de desmatamento (areakm). Dessa forma, não há presença de variáveis categóricas que justifique a construção de tabelas de frequência ou gráficos de barras.

Consequentemente, não se faz necessária a aplicação de técnicas de balanceamento de classes, como *oversampling* ou *undersampling*, comumente empregadas para tratar desbalanceamentos em variáveis discretas ou categóricas. A análise e modelagem seguem, portanto, focadas em variáveis quantitativas e suas transformações temporais e espaciais.

4.6 Análise Temporal

A análise temporal dos dados visa compreender como as variáveis hidrológicas e ambientais se comportaram ao longo do tempo, possibilitando a identificação de tendências, sazonalidades e rupturas que possam influenciar a modelagem preditiva.




Gráfico 12: Série temporal de chuva em Manaus

O Gráfico 12 apresenta a série temporal da precipitação média mensal (chuva_final) em Manaus após o pré-processamento dos dados. A curva mostra o comportamento da média da chuva diária agregada por mês ao longo de um intervalo de mais de três décadas, entre 1991 e 2024.

Observa-se que, nos primeiros anos (1991 a cerca de 2000), os valores permanecem praticamente constantes, em torno de 0,25 mm. Esse comportamento uniforme não reflete a variabilidade esperada da precipitação em Manaus e se deve ao fato de que, nesse período, não havia dados observados de chuva disponíveis. Como alternativa, foi aplicada uma imputação por média, utilizando o valor médio mensal dos anos posteriores para preencher essas lacunas. No entanto, o resultado evidencia que essa estratégia de imputação não foi eficaz para preservar a variabilidade climática real, resultando em uma série artificialmente estática nesse intervalo. Dado esse efeito, é recomendável que esses registros sejam excluídos das etapas de modelagem preditiva, a fim de evitar o comprometimento do desempenho dos algoritmos e garantir maior confiabilidade dos padrões aprendidos.

A partir do início dos anos 2000, nota-se uma mudança de padrão, com maior dispersão nos valores de precipitação mensal e variações mais condizentes com o comportamento climático da região amazônica. Esse trecho mais recente reflete com maior fidelidade a realidade pluviométrica de Manaus, caracterizada por períodos sazonais de chuvas intensas seguidos de intervalos secos.

É importante destacar um pico anômalo em torno do ano de 2003, com valor superior a 1,9 mm na média mensal, destoando fortemente do restante da série. Esse ponto pode representar um evento extremo real de chuva intensa, mas também pode ser um outlier residual que escapou do filtro de remoção de valores atípicos. Recomenda-se, portanto, revisar esse ponto específico nos dados originais.

Nos anos mais recentes (2010 a 2024), a série apresenta comportamento mais consistente e variável, com ciclos de aumento e redução na precipitação média mensal, reforçando a presença de padrões sazonais e eventos significativos de precipitação ao longo do tempo.

Em síntese, o gráfico revela três aspectos importantes:

1. Período inicial possivelmente artificial (1991–2000), com dados quase constantes;
2. Transição e estabilização na qualidade da série a partir de 2001;
3. Comportamento coerente com o regime tropical úmido nos anos recentes, com flutuações típicas e períodos com eventos extremos.

Para fins de modelagem preditiva, especialmente de vazão, é recomendável utilizar preferencialmente os dados a partir de 2001, onde o comportamento da série se mostra mais confiável e representativo das condições climáticas reais.




Gráfico 13: Série temporal de vazão em Manaus

O Gráfico 13 mostra a evolução da variável vazão ao longo do tempo, agregada por médias mensais, para o município de Manaus. A série cobre um período extenso, de 1991 a 2024.

A característica mais evidente do gráfico é a forte ciclicidade, com oscilações regulares entre valores mínimos e máximos de vazão em praticamente todos os anos. Essa variação periódica reflete o comportamento sazonal dos rios amazônicos, influenciado principalmente pelo regime de chuvas da região, que apresenta uma estação chuvosa bem definida entre os meses de dezembro e maio. Durante esses períodos, a vazão tende a aumentar de forma significativa devido à elevação do nível dos rios, enquanto nos meses mais secos, os valores recuam, formando os vales entre os picos da curva.

Além da sazonalidade bem marcada, também é possível observar que, ao longo das décadas, houve uma ligeira tendência de aumento nos valores máximos de vazão, especialmente a partir de meados dos anos 2000. Picos mais pronunciados e frequentes após 2009 sugerem a ocorrência de eventos hidrológicos extremos com maior intensidade, como as grandes cheias registradas nos anos de 2009, 2012 e 2021, esta última considerada a maior da história de Manaus até então. Esses aumentos podem estar associados a fatores como mudanças climáticas, aumento da precipitação acumulada e alterações no uso do solo, como o avanço do desmatamento.

A amplitude entre os valores mínimo e máximo também se mantém significativa ao longo do tempo, o que demonstra que o sistema fluvial da região é altamente sensível às variações ambientais. A presença de outliers aparentes, reforça a importância de que o modelo preditivo a ser desenvolvido consiga lidar com valores extremos e flutuações não lineares, sendo necessário considerar algoritmos robustos e métricas de avaliação adequadas.

Em síntese, a série temporal de vazão evidencia um comportamento altamente periódico, com forte sazonalidade e picos crescentes em frequência e magnitude nas últimas duas décadas. Esses aspectos são centrais para a modelagem preditiva, pois apontam para a necessidade de capturar tanto os ciclos naturais quanto os desvios atípicos, a fim de fornecer previsões confiáveis e úteis para o planejamento de infraestruturas resilientes e estratégias de mitigação de enchentes.




Gráfico 14: Série temporal de área desmatada em Manaus

O Gráfico 14 mostra a evolução da área média diária de desmatamento (areakm) em Manaus, agregada por mês, no período de 1991 a 2024. A primeira observação importante é que a série apresenta baixa variabilidade ao longo de todo o período, com valores concentrados entre 0,02 e 0,15 km² por dia. Isso já era esperado, dado que os dados de desmatamento utilizados no projeto foram originalmente obtidos em resolução anual e, posteriormente, distribuídos proporcionalmente ao longo dos dias do ano, resultando em uma série quase constante no curto prazo.

No entanto, destaca-se a presença de um pico abrupto e isolado entre 2007 e 2008, em que os valores ultrapassam os 2,0 km² por dia. Este valor destoa completamente do restante da série e caracteriza um outlier claro, possivelmente causado por erro na interpolação, inconsistência na base original ou uma falha no pré-processamento. Esse ponto fora da curva pode impactar negativamente a modelagem preditiva, distorcendo a relação entre desmatamento e outras variáveis (como vazão e precipitação), e portanto deve ser investigado e possivelmente removido ou suavizado.

Fora essa anomalia pontual, a série é marcada por pequenas flutuações que refletem mudanças lentas na taxa anual de desmatamento, o que confirma que a variável “areakm”, quando observada com granularidade diária ou mensal, não carrega forte variabilidade informativa no curto prazo. Ainda assim, seu uso é justificado por sua importância estrutural no ciclo hidrológico da região, já que o desmatamento afeta diretamente a infiltração da água no solo, a evapotranspiração e o escoamento superficial, fatores que, no médio e longo prazo, influenciam a dinâmica de vazão dos rios.

Em resumo, o gráfico evidencia que:

- A variável apresenta baixa variabilidade e caráter quase estático ao longo do tempo;
- Há um outlier extremo em 2007/2008 que deve ser tratado;

- O uso da variável deve focar efeitos acumulativos ou estruturais e não relações diretas de curto prazo.

Em conjunto, os três gráficos destacam a importância de diferenciar o papel de cada variável na modelagem, reconhecendo que enquanto chuva e vazão são fortemente sazonais e informativas no curto prazo, o desmatamento atua como um fator estrutural. Ajustes como a exclusão de trechos artificiais e o tratamento de outliers são essenciais para garantir que o modelo aprenda padrões reais e úteis para previsão hidrológica.

4.7 Análise Geoespacial

Foi realizada uma análise geoespacial das variáveis “chuva_final”, “vazao” e “areakm”, com base em mapas temáticos elaborados para os municípios da Amazônia Legal. Essa análise teve como objetivo identificar padrões espaciais relevantes e avaliar a importância das características geográficas no comportamento hidrológico da região.

Contudo, não foi possível realizar a análise geoespacial com granularidade intraurbana no município de Manaus, uma vez que os dados de vazão disponíveis estão vinculados a códigos de estação hidrológica e de município fornecidos pela base HIDRO da ANA, os quais não seguem a codificação oficial do IBGE. Essa discrepância de identificadores dificultou a correspondência direta entre as estações de medição e suas localizações geográficas exatas dentro do município.

Além disso, a própria base HIDRO não disponibiliza coordenadas precisas por bairro ou sub-região urbana para cada ponto de medição, limitando a associação entre as séries temporais de vazão e as divisões territoriais internas de Manaus. Por esse motivo, a análise geoespacial foi conduzida exclusivamente no nível de município, possibilitando comparações entre diferentes localidades da Amazônia Legal, mas sem a resolução espacial necessária para diferenciações dentro de Manaus.

Ainda assim, os mapas produzidos oferecem um panorama útil sobre a distribuição regional das variáveis climáticas e ambientais, permitindo observar como a precipitação, o desmatamento e a vazão se comportam entre municípios, e fornecendo uma base para futuras integrações com dados geográficos mais detalhados.




Gráfico 15: Distribuição geoespacial dos dados de vazão

O Gráfico 15 apresenta a distribuição geoespacial dos valores médios de vazão nos municípios da Amazônia Legal, representando os dados em tons de cor que variam do claro (menor vazão) ao escuro (maior vazão). Esse tipo de visualização permite identificar padrões regionais no comportamento hidrológico e oferece insights relevantes para o planejamento hídrico e energético.

Observa-se que alguns municípios concentram valores significativamente mais elevados de vazão, como é o caso de áreas no entorno de grandes rios, notadamente em regiões do Amazonas, Acre e Rondônia, onde os principais afluentes dos rios Solimões, Negro e Madeira passam. Esses municípios, representados pelas tonalidades mais escuras, se destacam como zonas de maior escoamento fluvial, indicando presença de bacias hidrográficas mais extensas ou maior volume acumulado de chuva na região.

Por outro lado, há uma ampla quantidade de municípios com baixos valores médios de vazão, evidenciados pelas colorações mais claras. Isso pode indicar tanto a ausência de grandes rios quanto limitações na cobertura de estações fluviométricas nesses territórios. Cabe ressaltar que em alguns casos, a baixa vazão pode estar relacionada à escassez de medições e não necessariamente a uma realidade hidrológica de pouco fluxo, um fator a ser considerado com cautela na interpretação dos dados.

A análise também demonstra que a distribuição de vazão não é homogênea entre os municípios, reforçando a importância de utilizar modelos regionais personalizados e não generalistas para prever o comportamento dos rios em diferentes localidades. Essa variabilidade espacial é crítica, sobretudo para políticas públicas voltadas à prevenção de enchentes e ao planejamento de infraestrutura energética, como centrais hidrelétricas ou sistemas de captação.

Por fim, é importante destacar que os valores apresentados correspondem à média municipal, já que os dados disponíveis de vazão estão vinculados a estações hidrológicas que não permitem discriminar variações intraurbanas. Portanto, o mapa oferece uma visão agregada por município, útil para o planejamento regional, mas limitada em sua capacidade de detalhar diferenças locais dentro de cidades maiores, como Manaus.




Gráfico 16: Distribuição geoespacial dos dados de chuva

O Gráfico 16 apresenta a distribuição geoespacial dos dados de precipitação média diária (chuva_final) nos municípios da Amazônia Legal, utilizando uma escala de cores que varia do amarelo (baixa precipitação) ao azul escuro (alta precipitação). Essa visualização permite identificar regiões com maior ou menor incidência de chuvas ao longo do período analisado.

De maneira geral, a maior parte dos municípios apresenta índices médios de precipitação entre 1 e 2 mm por dia, sendo que os maiores volumes médios diários estão concentrados em pontos do norte do Amazonas, leste do Pará, litoral do Maranhão e extremo sul da região. Esses municípios aparecem em tons azul-escuro, indicando uma média de precipitação superior a 3 mm/dia. Por outro lado, uma grande quantidade de municípios apresenta valores mais baixos de precipitação média, representados pelas áreas em tons claros/amarelados.

No caso específico de Manaus, não é possível identificá-lo com precisão no mapa, uma vez que a sobreposição das geometrias e a ausência de nomes dos municípios dificultam a localização exata. No entanto, a região onde Manaus está inserido aparenta estar representada por uma coloração clara, o que sugere uma precipitação média diária mais baixa em comparação a

outros municípios da Amazônia Legal. Esse resultado está em linha com a análise estatística feita anteriormente, que apontou valores medianos de precipitação relativamente baixos para Manaus, ainda que sujeitos a eventos extremos pontuais de chuva intensa.

Essa observação reforça a importância de utilizar variáveis derivadas, como a chuva acumulada em janelas móveis (3, 7 ou 14 dias), que são mais representativas da influência hidrológica sobre a vazão dos rios. Além disso, destaca-se novamente a limitação da análise geoespacial municipal, que não permite capturar com precisão as variações climáticas internas de grandes municípios como Manaus, especialmente por conta da agregação dos dados e da falta de identificação detalhada das estações pluviométricas no território urbano.




Gráfico 17: Distribuição geoespacial dos dados de área desmatada

O Gráfico 17 apresenta a distribuição geoespacial dos dados de área desmatada (areakm) nos municípios da Amazônia Legal. A escala de cor varia do branco (menor área desmatada) ao verde escuro (maior área desmatada), permitindo identificar regiões com diferentes níveis de pressão antrópica sobre a cobertura vegetal original.

A análise revela que o desmatamento está concentrado em determinados municípios, especialmente ao longo do chamado "Arco do Desmatamento", que se estende pelos estados do sul do Amazonas, Rondônia, Mato Grosso, Pará e Maranhão. Esses municípios, representados pelas tonalidades mais escuras no mapa, apresentam áreas desmatadas significativamente maiores em comparação ao restante da região. Esse padrão está alinhado com estudos anteriores e com os dados do MapBiomas, que indicam que essas regiões têm sido historicamente impactadas por atividades como expansão agropecuária, exploração madeireira e ocupação desordenada do solo.

Por outro lado, grande parte dos municípios da região central e norte da Amazônia Legal apresenta níveis baixos de desmatamento acumulado, como sugerem as tonalidades claras predominantes. Essa diferença pode estar relacionada tanto à distância de frentes de ocupação

econômica quanto à presença de unidades de conservação ou terras indígenas, que contribuem para a proteção da floresta.

No caso específico de Manaus, não é possível localizá-lo com precisão absoluta no mapa, porém, a área correspondente à sua localização aparenta estar entre as regiões de tonalidade intermediária, o que sugere um nível moderado de desmatamento acumulado em comparação com os extremos observados na região. Isso é coerente com o fato de Manaus ser uma capital com áreas urbanizadas, mas ainda cercada por grandes reservas naturais e vegetação preservada, como a Reserva de Desenvolvimento Sustentável do Tupé.

A análise da variável “areakm” é essencial para o projeto, pois o desmatamento tem impacto direto sobre o ciclo hidrológico: ao reduzir a cobertura vegetal, aumenta-se o escoamento superficial da água da chuva, diminui-se a infiltração no solo e, consequentemente, altera-se o padrão de vazão dos rios. Portanto, compreender a distribuição espacial do desmatamento contribui para a melhoria da previsão de vazão e para a elaboração de estratégias sustentáveis de desenvolvimento energético, que considerem os impactos ambientais e a resiliência dos ecossistemas fluviais da região.

A análise dos três gráficos geoespaciais, referentes à distribuição da vazão média, da precipitação média (chuva_final) e da área desmatada (areakm), revela a forte heterogeneidade espacial dos fatores hidrológicos na Amazônia Legal. Cada um desses atributos, por si só, já apresenta comportamentos distintos entre os municípios, o que indica que a dinâmica hídrica da região não é homogênea e depende de um conjunto complexo de variáveis ambientais e territoriais.

No entanto, uma limitação importante do projeto está no fato de que os dados utilizados para treinar o modelo foram agregados somente no nível municipal de Manaus, sem incorporar informações hidrológicas ou ambientais das regiões vizinhas. Isso representa uma barreira metodológica significativa, pois o comportamento da vazão em um município como Manaus, situado na confluência de grandes rios e cercado por bacias hidrográficas intermunicipais, é fortemente influenciado por fenômenos extraterritoriais. Em outras palavras, chuvas intensas, desmatamento ou alterações climáticas ocorridas a montante (em municípios vizinhos) podem impactar diretamente o nível dos rios em Manaus, mesmo que tais eventos não estejam registrados dentro dos seus próprios limites geográficos.

Portanto, os três gráficos ressaltam a necessidade de considerar o contexto regional e a interdependência entre municípios no planejamento de modelos mais robustos de previsão de vazão. Para futuros aprimoramentos, seria ideal integrar variáveis de regiões adjacentes, especialmente dados de precipitação e desmatamento de bacias hidrográficas vizinhas, além de investir em dados hidrológicos com coordenadas geográficas explícitas, possibilitando uma modelagem espacial mais realista e eficaz.

4.8 Insights Importantes

A análise exploratória dos dados revelou uma série de padrões estatísticos e espaciais fundamentais para a construção e interpretação dos modelos preditivos utilizados neste projeto. Ao longo das etapas gráficas e estatísticas, foram identificados comportamentos distintos entre as variáveis principais (vazão, chuva e desmatamento), o que exige uma abordagem de modelagem robusta, capaz de lidar com assimetrias, outliers, defasagens temporais e escalas variadas.

As variáveis hidrológicas e climáticas, em particular a “vazao” e a “chuva_final”, apresentaram forte componente sazonal, com ciclos anuais bem definidos, sobretudo no município de Manaus. Essa sazonalidade ficou evidente nas séries temporais mensais, em que picos regulares de chuva e, posteriormente, de vazão se repetem ao longo dos anos. Observou-se também uma defasagem temporal entre precipitação e aumento da vazão, o que confirma a presença de uma memória hidrológica do sistema fluvial. Essa característica justifica o uso de variáveis derivadas por meio de acúmulo de chuva em janelas móveis, como chuva acumulada em 3 e 14 dias, que se mostraram mais eficazes na modelagem preditiva. Por exemplo, os gráficos de dispersão revelam que, enquanto a correlação direta entre chuva_final e vazao foi muito baixa ($\rho \approx 0,06$), o uso da variável “chuva_acumulada_14d” resultou em uma estrutura mais clara de associação, evidenciando a importância dessas janelas temporais para capturar o efeito acumulado da chuva na dinâmica fluvial.

Em contrapartida, a variável “areakm”, que representa a área desmatada acumulada, apresentou um comportamento quase estático ao longo do tempo, com valores praticamente constantes para o município de Manaus em torno de 0,065 km² por dia, devido à natureza dos dados, que originalmente são anuais e foram interpolados para granularidade diária. Essa baixa variabilidade limita sua utilidade em relações de curto prazo, mas reforça seu papel como variável estrutural no modelo. O gráfico temporal dessa variável revelou ainda a presença de um outlier extremo nos anos de 2007/2008, com valores que ultrapassam 2 km² por dia, destoando fortemente da média histórica. Esse trecho deve ser tratado ou removido, uma vez que pode comprometer a estabilidade e a aprendizagem do modelo. Portanto, o uso da variável “areakm” deve estar focado em seu efeito acumulativo e contextual sobre o sistema hídrico, e não como preditor direto de variações diárias na vazão.

Em conjunto, os gráficos exploratórios mostraram que chuva e vazão são variáveis altamente sazonais, com resposta dinâmica de curto e médio prazo, enquanto o desmatamento representa um fator estrutural, de longo prazo, que altera a capacidade de infiltração e o padrão de escoamento da bacia. Essa diferenciação é essencial para a construção de um modelo interpretável e coerente com a realidade ambiental. Além disso, destaca-se a necessidade de tratamento de dados artificiais ou pouco confiáveis, como o trecho de chuvas constantes em 1991–2000 (com valor fixo de 0,25 mm), que foram imputadas devido à ausência de registros originais, e que devem ser excluídas ou tratadas como exceções.

A análise estatística conjunta dos gráficos 1, 2 e 3 confirmou a natureza assimétrica das distribuições das três principais variáveis envolvidas: “vazao”, “chuva_final” e “areakm”. Enquanto “chuva_final” apresentou assimetria positiva, com muitos dias secos intercalados por eventos intensos de chuva (com desvio padrão de 0,70), a “vazao” mostrou alta variabilidade,

mas com distribuição mais simétrica. Já o “areakm” manteve-se estável, com mínimas oscilações, salvo os picos mencionados. Essa diversidade de comportamentos reforça a importância de uma abordagem de modelagem capaz de lidar com múltiplas escalas e distribuições, algo que justifica a escolha por modelos baseados em árvores, como XGBoost.

A análise dos dados climáticos complementares também demonstrou que, embora algumas variáveis como pressão atmosférica e umidade relativa apresentem baixa variabilidade ao longo do tempo, elas fornecem contexto atmosférico importante. Já variáveis como radiação solar e temperatura apresentaram maior variabilidade diária e são promissoras como componentes auxiliares, especialmente quando combinadas com precipitação e desmatamento. A presença de registros meteorológicos diários também permite a criação de variáveis derivadas com defasagens (lags), o que amplia a capacidade do modelo de capturar efeitos cumulativos e tendências temporais.

Por fim, a análise espacial reforçou uma limitação importante do projeto: o modelo de previsão foi treinado apenas com dados do município de Manaus, sem considerar informações das regiões vizinhas, que compartilham as mesmas bacias hidrográficas. Como as estações hidrológicas da ANA não estão georreferenciadas com coordenadas exatas, e utilizam códigos incompatíveis com os códigos do IBGE, não foi possível integrar dados externos com precisão espacial. Isso restringe a capacidade do modelo de considerar chuvas ou desmatamentos a montante, que impactam diretamente a vazão local.

Assim, os insights obtidos ao longo da análise reforçam a necessidade de tratar os dados com rigor técnico, priorizando variáveis derivadas, removendo inconsistências históricas, diferenciando fatores sazonais e estruturais, e reconhecendo os limites da granularidade espacial disponível. Essa abordagem oferece uma base sólida para o desenvolvimento de modelos mais realistas e eficazes para previsão de vazão, apoiando a tomada de decisão em infraestrutura energética e gestão ambiental na cidade de Manaus.

5. Resultados

5.1 Desempenho dos Algoritmos

Os resultados apresentados nesta seção foram obtidos a partir da execução do plano de experimentação dos algoritmos XGBoost Regressor e Random Forest Regressor. Para garantir uma avaliação justa e comparável entre os modelos, foram calculadas as médias das principais métricas de desempenho ao longo de todos os cenários testados.

As métricas utilizadas foram: Erro Absoluto Médio (MAE), Erro Quadrático Médio (MSE), Raiz do Erro Quadrático Médio (RMSE) e Coeficiente de Determinação (R^2). São amplamente empregadas na avaliação de modelos de regressão e foram aplicadas sobre os conjuntos de teste, de forma a verificar a capacidade de generalização dos algoritmos diante de dados não vistos durante o treinamento.

A Tabela 6 apresenta os valores médios obtidos para cada métrica, permitindo uma comparação direta entre os dois algoritmos considerados.

Métrica	XGBoost Regressor	Random Forest Regressor
MAE (Mean Absolute Error)	13453.42	13529.84
MSE (Mean Squared Error)	355196300	392068400
R ² (Coeficiente de Determinação)	0.7919	0.7708
RMSE (Root Mean Squared Error)	17691.42	18997.68

Tabela 6 : Comparação das métricas médias de desempenho dos modelos

De forma geral, os resultados indicam que o XGBoost teve desempenho superior em todas as métricas, ainda que as diferenças sejam relativamente pequenas. A seguir, destacam-se os principais pontos da análise:

- MAE (Erro Absoluto Médio): O XGBoost apresentou erro médio de aproximadamente 13.453,42 m³/s, ligeiramente menor que o Random Forest (13.529,84 m³/s), o que indica maior precisão média nas previsões.
- MSE (Erro Quadrático Médio): A diferença é mais expressiva no MSE, com o XGBoost apresentando 35.519.630 contra 39.206.840 do Random Forest. Como o MSE penaliza erros grandes com mais intensidade, esse resultado indica que o XGBoost foi mais eficiente em evitar desvios extremos.
- RMSE (Raiz do Erro Quadrático Médio): De forma coerente com o MSE, o XGBoost também teve menor RMSE (17.691,42 contra 18.997,68), sugerindo melhor desempenho em termos de estabilidade e variação do erro.
- R² (Coeficiente de Determinação): O XGBoost explica 79,19% da variabilidade da vazão, valor superior ao Random Forest (77,08%). Embora ambos os modelos tenham bom ajuste, o XGBoost demonstra maior capacidade explicativa.




Gráfico 18: Comparação das Métricas Médias por Algoritmo – XGBoost vs Random Forest

O Gráfico 18 oferece uma visualização direta e comparativa dos desempenhos médios dos dois modelos de regressão testados. Enquanto a Tabela 6 apresenta os valores numéricos de forma detalhada, este gráfico facilita a identificação visual das diferenças entre os algoritmos com base em quatro métricas principais: R^2 (Coeficiente de Determinação), MAE (Erro Absoluto Médio), MSE (Erro Quadrático Médio) e RMSE (Raiz do Erro Quadrático Médio).

A análise do gráfico evidencia que o XGBoost Regressor superou o Random Forest Regressor em todas as métricas avaliadas. O valor médio de R^2 do XGBoost foi ligeiramente superior, indicando que o modelo consegue explicar uma fração maior da variabilidade dos dados de vazão dos rios. Além disso, os valores médios de MAE, MSE e RMSE foram consistentemente menores para o XGBoost, o que reforça sua capacidade de fazer previsões mais próximas dos valores reais e com menor incidência de erros extremos.

Essas diferenças, embora sutis em algumas métricas, são mais evidentes no MSE e RMSE, que penalizam fortemente desvios grandes. O XGBoost, ao apresentar valores menores nessas métricas, mostra-se mais eficaz em evitar grandes erros de previsão, o que é especialmente relevante em contextos hidrológicos onde desvios elevados podem representar eventos críticos de enchentes ou estiagens.

Em síntese, o gráfico confirma visualmente a superioridade do XGBoost em termos de acurácia e estabilidade, destacando-o como a melhor escolha para o modelo preditivo de vazão em Manaus. O Random Forest, embora com desempenho levemente inferior, ainda se mostra competitivo, sendo uma opção alternativa válida em cenários com diferentes prioridades computacionais ou interpretativas.

Métrica	XGBoost Regressor	Random Forest Regressor
MAE (Mean Absolute Error)	2346,84385139298	1280,20474626695
MSE (Mean Squared Error)	10949145,3560508	5538040,79058979
R ² (Coeficiente de Determinação)	0,993564578956329	0,996740164460434
RMSE (Root Mean Squared Error)	3307,45	2352,24

Tabela 7 : Comparação das métricas de desempenho dos modelos das melhores pipelines

A Tabela 7 apresenta os resultados das melhores configurações encontradas para os modelos XGBoost Regressor e Random Forest Regressor, segundo o plano de experimentação.

O Random Forest obteve um MAE significativamente menor que o XGBoost, o que indica que, em média, seus erros absolutos nas previsões de vazão foram menores. Isso sugere que o modelo Random Forest, na comparação dessas melhores pipelines em específico, é mais preciso em capturar valores próximos da realidade, com menor desvio médio.

O MSE reforça o comportamento observado no MAE, penalizando ainda mais os erros grandes. O Random Forest apresenta novamente melhor desempenho, com um valor quase metade do obtido pelo XGBoost. Isso evidencia que o Random Forest não apenas comete erros menores, mas também evita grandes desvios.

Ambos os modelos apresentam altíssimos valores de R², o que demonstra uma excelente capacidade de explicar a variabilidade dos dados. Contudo, o Random Forest ainda supera levemente o XGBoost, reforçando sua superioridade nessa comparação específica.

O RMSE, ao considerar a raiz dos erros quadráticos médios, confirma que o Random Forest tem menor tendência a erros extremos do que o XGBoost, sendo novamente o modelo mais estável nesse cenário.

Nesta comparação específica, considerando as melhores pipelines de cada algoritmo, o Random Forest Regressor demonstrou desempenho superior em todas as métricas analisadas, apresentando menores erros médios (MAE, MSE, RMSE) e maior poder explicativo (R²).

Embora o XGBoost tenha se mostrado mais consistente ao longo da média de todas as execuções no plano de experimentação, a melhor combinação de pré-processamento e

parametrização para o Random Forest resultou em desempenho superior quando comparada diretamente à melhor configuração do XGBoost. Isso evidencia que, mesmo modelos geralmente mais simples como o Random Forest, podem superar técnicas mais complexas se forem bem otimizados.

Entretanto, é importante considerar que as diferenças entre os modelos não são tão expressivas em termos práticos, e que a consistência geral do XGBoost ao longo de diferentes cenários o torna uma escolha mais robusta. Como não temos garantia de que os dados futuros terão o mesmo comportamento estatístico da base atual, optamos por adotar o XGBoost como modelo final, priorizando sua estabilidade e desempenho regular em diferentes pipelines ao longo do plano de experimentação.

Dessa forma, embora o Random Forest tenha alcançado os melhores resultados em uma pipeline específica, o XGBoost foi escolhido como modelo final por oferecer maior previsibilidade e confiabilidade frente à variabilidade de dados no mundo real, o que é crucial para aplicações como previsão de vazão fluvial em contextos ambientais sensíveis.

5.2 Análise das Variáveis

A análise de importância das variáveis fornecida pelo modelo XGBoost permite identificar quais atributos mais contribuíram para a previsão da vazão dos rios nos municípios analisados. A Figura abaixo apresenta um gráfico com a importância relativa de cada variável segundo o algoritmo.




Gráfico 19: Feature importance XGBoost em avaliação de resultados parciais

A variável “mês” foi disparadamente a mais influente para o desempenho do modelo, o que reforça o caráter sazonal do regime hidrológico na Amazônia Legal. A forte influência do mês indica que a vazão dos rios segue padrões cíclicos anuais, sendo fortemente impactada pelas estações de cheia e seca típicas da região, especialmente nos primeiros meses do ano.

Em seguida, destacam-se as variáveis “pressao_min_ant_mb”, “pressao_max_ant_mb” e “pressao_nivel_estacao_mb”, relacionadas à pressão atmosférica. Essas variáveis foram mais relevantes que a própria chuva diária ou acumulada, o que sugere que o modelo identificou correlações indiretas entre padrões atmosféricos e variações de vazão, possivelmente antecipando a ocorrência de frentes frias, zonas de convergência ou outros fenômenos meteorológicos associados a períodos de cheia.

A variável “temperatura_bulbo_seco_c”, assim como outras relacionadas à temperatura e umidade, também apresentou importância significativa. Essas variáveis refletem o estado térmico e de umidade do ar, que pode impactar tanto o regime de chuvas quanto a evapotranspiração, influenciando o escoamento superficial e, por consequência, a vazão.

A variável “areakm”, que representa a área desmatada, também teve papel relevante. Isso reforça a hipótese discutida na análise exploratória: maiores áreas de desmatamento estão associadas a maior escoamento superficial e, conseqüentemente, a picos de vazão mais intensos. A presença do desmatamento entre as variáveis importantes indica que fatores antrópicos exercem influência direta sobre a dinâmica hidrológica da região.

Variáveis que intuitivamente seriam centrais para a previsão, como chuva_final e chuva_7d, aparecem com menor importância relativa. Isso reforça o padrão já identificado na análise de correlação: a resposta da bacia às chuvas não é imediata, e depende de um conjunto mais complexo de variáveis meteorológicas e geofísicas.




Gráfico 20: Feature importance Random Forest em avaliação de resultados parciais

O Gráfico 20 apresenta os resultados preliminares da análise de importância das variáveis realizadas a partir do modelo Random Forest Regressor, aplicado à tarefa de previsão de vazão. Observa-se, de forma clara, que a variável “mes” assumiu um papel preponderante no processo de decisão do modelo, apresentando um valor de importância significativamente superior às demais, com destaque absoluto. Essa dominância sugere que o modelo identificou um forte padrão de sazonalidade mensal na variável-alvo, o que é coerente com o comportamento típico do regime hidrológico da região amazônica, caracterizado por ciclos sazonais bem definidos entre os períodos de cheia e de seca, assim como foi apontado no gráfico anterior (Gráfico 19).

Além da variável “mes”, outras variáveis temporais como ano e dia também aparecem com importância moderada, indicando que o modelo pode estar capturando variações interanuais ou padrões específicos dentro do ciclo anual. A variável “areakm”, que possivelmente se refere à área da bacia hidrográfica considerada, também apresenta alguma relevância, embora em proporção muito inferior à da variável sazonal principal.

Em contrapartida, todas as demais variáveis ambientais e meteorológicas, como precipitação, umidade relativa do ar, temperatura (mínima, máxima e do ponto de orvalho), pressão atmosférica e velocidade do vento, apresentam valores de importância extremamente baixos, tendendo a zero. Essa baixa relevância atribuída pelo modelo pode estar associada a diversos fatores. Em primeiro lugar, é possível que exista colinearidade entre essas variáveis ambientais, diluindo sua contribuição individual na previsão. Em segundo lugar, a forte correlação da vazão com a sazonalidade pode ter ofuscado o papel das variáveis contínuas, levando o modelo a priorizar os marcadores temporais simples. Por fim, é importante considerar que esta avaliação corresponde a um estágio parcial do plano de experimentação, e que a performance dessas variáveis pode ser sensível à forma como são construídas, por exemplo,

variáveis derivadas como chuva acumulada em 7 ou 14 dias ou médias móveis podem expressar melhor a dinâmica hidrológica do sistema do que os valores instantâneos utilizados nesta análise.

Portanto, embora o modelo tenha apresentado forte dependência de variáveis temporais, este resultado sugere a necessidade de um refinamento na engenharia de atributos e na seleção de variáveis mais representativas do processo físico de geração da vazão. Tais ajustes são fundamentais para evitar que o modelo se torne excessivamente dependente de padrões cíclicos e perca a capacidade de generalização em cenários fora do comportamento histórico, como anos atípicos ou eventos extremos não sazonais.

Ao comparar a análise de importância das variáveis produzida pelo Random Forest Regressor com os resultados do modelo XGBoost Regressor, é possível observar diferenças relevantes tanto na distribuição da importância quanto na diversidade de variáveis consideradas relevantes por cada algoritmo.

Enquanto no Random Forest a variável “mes” apresenta domínio absoluto, com valor de importância superior a 0,85 e as demais variáveis virtualmente desprezadas, o XGBoost distribui a importância de forma mais balanceada entre um conjunto maior de variáveis. Embora “mes” ainda apareça como a variável de maior impacto, o XGBoost também atribui elevada relevância a variáveis meteorológicas, como “pressao_min_ant_mb”, “pressao_max_ant_mb”, “pressao_nivel_estacao_mb” e “temperatura_bulbo_seco_c”. Isso demonstra que o modelo de *boosting* foi capaz de capturar relações mais sutis e combinadas entre os fatores ambientais e a vazão, ao contrário do Random Forest, que priorizou marcadores temporais mais simples.

Essa diferença pode ser explicada pelas características intrínsecas dos dois algoritmos. O Random Forest utiliza a estratégia de *bagging*, construindo várias árvores de forma paralela e combinando seus resultados por média. Esse método tende a ser mais conservador e pode se tornar excessivamente dependente de variáveis com forte poder explicativo isolado, como é o caso do “mes” neste contexto, que captura o padrão sazonal da região. Já o XGBoost aplica a técnica de *boosting* sequencial, em que cada árvore é ajustada para corrigir os erros cometidos pelas anteriores. Esse processo iterativo tende a ser mais sensível a padrões complexos e interações entre variáveis, o que explica a maior diversidade de atributos relevantes identificados no modelo.

Além disso, o fato de o XGBoost atribuir importância a variáveis como “vento_rajada_max_ms”, “chuva_final”, “radiação solar” e diferentes medidas de temperatura, indica que esse modelo conseguiu capturar sinais meteorológicos diretamente associados ao comportamento da vazão, oferecendo maior potencial de generalização, especialmente em cenários fora do padrão histórico.

Em síntese, enquanto o Random Forest revelou forte dependência de padrões sazonais fixos, o XGBoost demonstrou maior sensibilidade às variáveis ambientais dinâmicas, o que pode torná-lo mais eficaz na antecipação de eventos hidrológicos atípicos e, consequentemente, mais promissor para aplicações práticas de previsão e gestão de risco em infraestrutura de energia renovável. Esses resultados representam um primeiro indicativo de que o XGBoost poderá se

consolidar como o modelo mais adequado para o problema em questão, hipótese que será investigada com maior profundidade nas análises comparativas das etapas seguintes.

5.3 Avaliação de Modelos e Pré-processamento

Com o objetivo de compreender o impacto das diferentes estratégias de pré-processamento no desempenho dos modelos, realizamos uma análise comparativa entre o Random Forest Regressor e o XGBoost Regressor. Para isso, agrupamos os cenários do plano de experimentação com base em três aspectos principais: tipo de normalização aplicada, presença ou não de remoção de outliers, e método de seleção de atributos utilizado.

A avaliação foi realizada por meio de gráficos que apresentam o coeficiente de determinação médio (R^2 médio) alcançado por cada modelo em cada grupo. Optamos por utilizar o R^2 como métrica principal, pois foi a métrica definida na Seção 4.7.

Esses gráficos nos permitiram identificar, de maneira visual e quantitativa, quais combinações de técnicas de pré-processamento mais favoreceram o desempenho preditivo de cada algoritmo.




Gráfico 21: Desempenho por Tipo de Normalização

O Gráfico 21 apresentado fornece uma comparação do desempenho médio dos algoritmos XGBoost e Random Forest em função dos diferentes tipos de normalização utilizados no pré-processamento dos dados: MinMaxScaler, RobustScaler e StandardScaler. A métrica

adotada para a avaliação foi o coeficiente de determinação (R^2), que mede a proporção da variância explicada pelo modelo.

De modo geral, observa-se que o algoritmo XGBoost obteve desempenho superior ao Random Forest em todos os tipos de normalização aplicados, com valores de R^2 ligeiramente mais elevados. Apesar de as diferenças absolutas entre os modelos não serem expressivas, a consistência do XGBoost em manter o melhor desempenho médio em todas as configurações testadas evidencia sua robustez frente às transformações nos dados. Esse comportamento sugere que o XGBoost é mais estável e menos sensível às variações no tipo de escalonamento, enquanto o Random Forest apresentou maior variabilidade de desempenho, conforme ilustrado pelas barras de erro mais amplas.

Outro ponto relevante é que os dois algoritmos apresentaram desempenho bastante semelhante entre os três métodos de normalização. Essa estabilidade indica que, no contexto analisado, a escolha do tipo de escalonamento não exerce impacto significativo sobre os resultados, principalmente para o Random Forest, que por construção não depende da escala dos atributos. No entanto, o fato de o XGBoost ter mantido um padrão de desempenho ligeiramente superior com menor desvio reforça sua adequação como modelo final para o problema de previsão da vazão em Manaus.

Em síntese, a análise visual reforça que, embora ambos os modelos sejam viáveis, o XGBoost demonstrou maior consistência e eficácia diante das transformações de pré-processamento, o que o torna uma escolha mais confiável para aplicação em contextos com dados heterogêneos e pré-processamentos variados.




Gráfico 22: Desempenho com e sem Remoção de Outliers

O Gráfico 22 apresentado ilustra o desempenho médio, medido pelo coeficiente de determinação (R^2), dos algoritmos XGBoost e Random Forest sob duas condições distintas de pré-processamento: com e sem a remoção de outliers. Essa comparação permite avaliar a sensibilidade dos modelos à presença de valores extremos nos dados e a efetividade do tratamento de outliers na melhoria da performance preditiva.

De maneira geral, observa-se que o XGBoost manteve um desempenho superior ao Random Forest em ambas as situações, demonstrando maior robustez frente à presença de outliers. Os valores de R^2 para o XGBoost permanecem elevados e estáveis independentemente da remoção, com variações mínimas entre as duas configurações. Esse comportamento confirma a natureza resiliente do algoritmo, que por sua estrutura interna de boosting e regularização consegue lidar eficientemente com ruídos nos dados.

Já o Random Forest apresentou uma leve melhora em R^2 após a remoção de outliers, o que indica que esse modelo é mais sensível à presença de valores extremos. Isso é compatível com a lógica das árvores de decisão, que podem ser impactadas por pontos atípicos ao definir seus critérios de divisão. Apesar da melhora com a remoção, o desempenho médio do Random Forest ainda se manteve abaixo do XGBoost, reforçando que o XGBoost não apenas tem melhor desempenho absoluto, como também apresenta maior estabilidade diante de variações na qualidade do conjunto de dados.

Além disso, vale destacar que as barras de erro para ambos os modelos são consideráveis, o que sugere alguma variabilidade entre os diferentes cenários do plano de experimentação. Ainda assim, o XGBoost demonstrou menor variação, o que favorece sua escolha como modelo mais confiável e consistente para o problema em estudo.

Em síntese, a remoção de outliers tende a beneficiar especialmente o Random Forest, mas o XGBoost permanece como o algoritmo mais robusto e eficiente, tanto em contextos com dados limpos quanto em situações com ruído ou variabilidade.

Desempenho por Método de Seleção de Atributos




Gráfico 23: Desempenho por Método de Seleção de Atributos

O Gráfico 23 apresenta uma comparação do desempenho médio (R^2) dos algoritmos Random Forest e XGBoost sob diferentes métodos de seleção de atributos: RFE (Recursive Feature Elimination), SelectKBest e a ausência de qualquer técnica de seleção ("Sem Seleção"). Essa análise permite avaliar como a escolha do método de seleção de variáveis influencia a capacidade preditiva dos modelos testados.

Observa-se que o XGBoost obteve desempenho estável e ligeiramente superior em todos os cenários, com destaque para o caso "Sem Seleção", onde apresentou o maior valor médio de R^2 . Isso indica que o algoritmo foi capaz de extrair valor preditivo de todas as variáveis disponíveis, mesmo sem filtragem prévia. Isso está alinhado com a característica do XGBoost de lidar eficientemente com redundância e multicolinearidade, graças à sua capacidade interna de atribuir importância diferenciada a cada atributo.

O Random Forest, por outro lado, apresentou resultados mais variáveis. Quando utilizado em conjunto com o método RFE, seu desempenho foi inferior ao do XGBoost, mas manteve estabilidade em relação aos demais métodos. O uso do SelectKBest resultou na menor média de R^2 para ambos os algoritmos, o que pode indicar que essa técnica eliminou variáveis relevantes ou manteve um subconjunto menos representativo para a tarefa de previsão de vazão.

De maneira geral, os dados indicam que a aplicação de técnicas de seleção de atributos não foi decisiva para melhorar o desempenho dos modelos testados, especialmente no caso do XGBoost, que obteve seu melhor desempenho justamente quando todas as variáveis foram mantidas. Esse resultado sugere que, no contexto analisado, a complexidade do problema e a natureza complementar das variáveis justificam a manutenção de todos os atributos disponíveis, ao menos como etapa inicial de modelagem. Ainda assim, o uso de técnicas de seleção pode ser útil em contextos com maior dimensionalidade ou com atributos altamente redundantes.

5.4 Cross-Validation

A validação cruzada é uma técnica fundamental para avaliar a capacidade de generalização de modelos de machine learning. Neste trabalho, foram empregadas três estratégias distintas de validação cruzada: K-Fold com $k=3$, K-Fold com $k=10$ e Repeated K-Fold 5x2.

Na estratégia K-Fold, o conjunto de dados é dividido em k subconjuntos (ou “folds”) aproximadamente do mesmo tamanho. O modelo é treinado k vezes, a cada vez usando $k-1$ partes para treino e 1 parte diferente para teste. Isso permite que cada instância do conjunto de dados seja usada tanto para treino quanto para teste, em diferentes rodadas. A diferença entre $k=3$ e $k=10$ está no número de divisões: com $k=3$, cada fold contém um terço dos dados, o que pode tornar a avaliação mais instável; já com $k=10$, os folds são menores, proporcionando uma avaliação mais refinada e geralmente mais estável.

Por outro lado, a estratégia Repeated K-Fold 5x2 executa o processo de K-Fold com $k=2$ (ou seja, divide os dados em duas metades: treino e teste) repetido cinco vezes, cada uma com uma divisão aleatória diferente. Isso gera um total de 10 avaliações independentes. A repetição aleatória múltipla aumenta a robustez da validação, pois o modelo é testado em diversos cenários diferentes, reduzindo o viés de uma divisão específica dos dados.

No presente estudo, foram avaliados dois modelos: XGBoost e Random Forest Regressor. Para ambos, a estratégia que apresentou o melhor desempenho foi o RepeatedKFold 5x2.




Gráfico 24: Desempenho Médio do XGBoost Regressor sob Diferentes Estratégias de Validação Cruzada (R^2)

A análise do gráfico gerado (Gráfico 24), que apresenta o desempenho médio do modelo XGBoost Regressor sob diferentes estratégias de validação cruzada, revela variações significativas na métrica R^2 , bem como nos respectivos desvios padrão.

Observa-se que a estratégia RepeatedKFold 5x2 apresenta o melhor desempenho médio, com valor de R^2 próximo de 0,93, além de uma variação mais controlada em comparação às demais abordagens. Isso indica que, ao repetir o processo de validação múltiplas vezes, a estimativa do desempenho do modelo se torna mais robusta e estável, o que contribui para uma generalização mais confiável.

Em contraste, tanto o KFold $k=3$ quanto o KFold $k=10$ apresentaram desempenhos médios mais baixos, em torno de 0,71 a 0,74, com desvios padrão também consideráveis. Embora o KFold com mais divisões ($k=10$) tenha um leve desempenho superior ao KFold com menos divisões ($k=3$), ambos são superados pela estratégia repetida, possivelmente devido à menor variabilidade dos conjuntos de teste nas repetições e à maior representatividade estatística.

Esses resultados sugerem que, para o conjunto de dados utilizado, o uso do RepeatedKFold 5x2 não apenas melhora a performance do modelo, como também proporciona maior confiança na avaliação de seu desempenho, sendo a estratégia de validação cruzada mais recomendada entre as analisadas. Essa escolha pode ser especialmente benéfica em cenários com variação significativa entre partições de dados ou em amostras com tamanho reduzido.




Gráfico 25: Desempenho Médio do Random Forest sob Diferentes Estratégias de Validação Cruzada (R^2)

O gráfico (Gráfico 25) compara o desempenho do modelo Random Forest Regressor utilizando três estratégias distintas de validação cruzada: KFold com $k=10$, KFold com $k=3$ e RepeatedKFold 5x2. A métrica utilizada para avaliação é o coeficiente de determinação R^2 , acompanhada do desvio padrão, que indica a variação dos resultados entre os folds.

A estratégia RepeatedKFold 5x2 novamente se destaca, apresentando o maior R^2 médio, indicando melhor desempenho do modelo na generalização dos dados. Apesar do desvio padrão mais elevado nessa estratégia, o ganho de desempenho justifica seu uso, principalmente em cenários onde a robustez da estimativa é mais importante que a estabilidade absoluta.

Por outro lado, o KFold com $k=10$ obteve desempenho intermediário, superior ao KFold com $k=3$, mas ainda inferior ao RepeatedKFold. A estratégia KFold $k=3$ apresentou o menor valor de R^2 médio, sugerindo que uma divisão com poucos folds pode resultar em estimativas menos confiáveis para esse modelo, além de maior sensibilidade à distribuição dos dados em cada partição.

Esses resultados indicam que, assim como no caso do XGBoost, a estratégia RepeatedKFold 5x2 também é a mais recomendada para o modelo Random Forest Regressor no conjunto de dados analisado, por proporcionar um melhor balanço entre desempenho e variabilidade.




Gráfico 26: Desempenho Comparativo dos Algoritmos Random Forest e XGBoost sob Diferentes Estratégias de Validação Cruzada

O gráfico acima compara o desempenho dos algoritmos XGBoost Regressor e Random Forest Regressor com base na métrica R^2 médio, avaliado sob três diferentes estratégias de validação cruzada: KFold com $k=10$, KFold com $k=3$ e RepeatedKFold 5x2. As barras de erro indicam o desvio padrão associado a cada média, permitindo avaliar a estabilidade de cada modelo em relação à divisão dos dados.

Observa-se que, em todos os cenários, o XGBoost apresentou desempenho superior ou quase equivalente ao Random Forest. A diferença mais expressiva ocorre sob a validação KFold com $k=3$, onde o XGBoost obteve um R^2 médio visivelmente mais elevado. Já sob a estratégia RepeatedKFold 5x2, ambos os algoritmos atingiram seus melhores desempenhos, com valores de R^2 próximos a 0.93, demonstrando que essa técnica de validação proporciona estimativas mais robustas e generalizáveis do desempenho dos modelos.

Outro ponto importante é a estabilidade dos algoritmos frente à divisão dos dados. O desvio padrão é relativamente baixo nas validações KFold simples, mas aumenta significativamente em RepeatedKFold 5x2, o que pode ser atribuído à maior variabilidade introduzida pelas múltiplas repetições e sorteios diferentes de dados.

A partir dessa análise, conclui-se que o XGBoost é mais consistente e robusto frente a variações nos dados de treinamento, especialmente quando combinado com validações cruzadas mais exigentes. A estratégia RepeatedKFold 5x2 mostrou-se a mais eficaz para estimar o desempenho real dos modelos, sendo recomendada para experimentos futuros. Portanto, para aplicações que exigem maior confiabilidade na predição, recomenda-se o uso do XGBoost aliado a validações repetidas.

5.5 Análise de Cenários

O plano de experimentação foi concebido com o objetivo de avaliar sistematicamente o impacto das decisões de pré-processamento, seleção de atributos e estratégias de validação cruzada sobre o desempenho de dois modelos de regressão supervisionada: Random Forest Regressor e XGBoost Regressor. A proposta visa não apenas identificar o melhor desempenho absoluto, mas compreender como diferentes combinações de técnicas afetam a estabilidade e a generalização dos modelos.

A variação dos métodos de pré-processamento foi incorporada ao experimento para testar como diferentes formas de normalização dos dados influenciam a performance dos algoritmos, especialmente porque ambos os modelos, apesar de serem baseados em árvores e não exigirem normalização por definição, podem responder de forma distinta à escala das variáveis em função da estrutura dos dados e da presença de outliers. Por esse motivo, foram testadas três técnicas: StandardScaler (normalização para média zero e desvio padrão unitário), MinMaxScaler (reescala os dados entre 0 e 1) e RobustScaler (baseado em estatísticas robustas à presença de valores extremos). A remoção de outliers também foi considerada como fator de variação, pois valores extremos podem distorcer o comportamento de variáveis preditoras e influenciar negativamente o processo de aprendizagem.

A seleção de atributos, por sua vez, foi avaliada com os métodos RFE (Recursive Feature Elimination) e SelectKBest. A intenção ao testar diferentes estratégias de redução de dimensionalidade é verificar se a eliminação de variáveis redundantes ou irrelevantes contribui para modelos mais simples, com menor risco de *overfitting* e melhor capacidade preditiva. Cada técnica de seleção se baseia em critérios diferentes para determinar a importância das variáveis, o que pode impactar de maneira significativa o desempenho final.

Quanto às estratégias de validação, a escolha de múltiplas configurações de KFold (com $k=3$ e $k=10$) e RepeatedKFold (com 5 repetições de 2 folds) foi feita para garantir uma estimativa mais confiável da generalização do modelo. O uso de diferentes valores de k e a repetição dos folds permitem capturar a variabilidade dos resultados em diferentes partições dos dados, reduzindo o viés associado a uma única divisão entre treino e teste.

Em conjunto, essas variações foram planejadas para compor um cenário robusto de avaliação empírica. O objetivo final do plano de experimentação é, portanto, não apenas determinar qual modelo tem melhor desempenho, mas identificar quais condições operacionais (pré-processamento, seleção de atributos e validação) favorecem cada modelo, promovendo uma escolha informada e adequada ao contexto dos dados.

Para o Random Forest foram gerados 217 cenários e para o XGBoost foi um total de 432 cenários, resultando em um conjunto expressivo de cenários que capturam as interações entre pré-processamento, seleção de atributos, configuração dos hiperparâmetros e validação. No caso do Random Forest, foram ajustados principalmente o número de árvores e o critério de erro (*squared_error*), enquanto no XGBoost variaram-se parâmetros como a profundidade máxima das árvores e a taxa de aprendizado.

Embora o RMSE tenha sido priorizado na etapa final de avaliação do modelo devido à sua sensibilidade a grandes erros (Seção 4.7), devido ao aspecto crítico em aplicações de risco hidrológico, a análise de cenários do plano de experimentação foi conduzida com base no coeficiente de determinação (R^2). Isso se deve ao fato de que o R^2 mede a proporção da variância explicada pela regressão, sendo uma métrica mais adequada para comparar a capacidade explicativa relativa entre diferentes combinações de pré-processamento, seleção de atributos e estratégias de validação. Por não depender da escala dos dados e permitir avaliar diretamente a qualidade do ajuste, o R^2 se mostrou mais informativo para a seleção do melhor cenário durante os testes experimentais.

Os dois gráficos a seguir representam o desempenho dos modelos XGBoost (Gráfico 27) e Random Forest (Gráfico 28) ao longo de diversos cenários de experimentação. O eixo vertical exibe o coeficiente de determinação R^2 , que mede a qualidade do ajuste do modelo, quanto mais próximo de 1, melhor a capacidade do modelo em explicar a variabilidade dos dados.




Gráfico 27: Desempenho do Modelo XGBoost por Cenário (R^2)

No Gráfico 27, observa-se que o modelo XGBoost apresenta uma distribuição de desempenho mais concentrada em faixas elevadas de R^2 , com a maioria dos cenários superando a marca de 0,7 e diversos casos ultrapassando 0,9. Esse comportamento evidencia a robustez do XGBoost, cuja capacidade de generalização se mantém estável mesmo diante de alterações nos parâmetros e transformações aplicadas aos dados. A baixa dispersão dos valores sugere que o algoritmo consegue manter desempenho consistente independentemente das variações nas configurações testadas.




Gráfico 28: Desempenho do Modelo Random Forest por Cenário (R^2)

Por outro lado, o Gráfico 28, referente ao modelo Random Forest, revela maior variabilidade no desempenho entre os cenários. Embora também existam casos em que o R^2 se aproxima de 1, a presença de cenários com valores consideravelmente mais baixos, por vezes abaixo de 0,65, indica maior sensibilidade às condições do experimento. Esse padrão pode estar relacionado à maneira como o Random Forest lida com ruídos nos dados ou com a escolha dos atributos utilizados na construção das árvores de decisão. A maior dispersão observada sugere que o modelo requer maior cautela na definição do pipeline de pré-processamento e validação.

De modo geral, a análise comparativa entre os Gráficos 27 e 28 aponta para uma vantagem do XGBoost no que diz respeito à estabilidade e ao desempenho médio dos modelos gerados. No entanto, ambos os algoritmos demonstraram capacidade de alcançar altos valores de R^2 em determinados cenários, o que reforça a importância da seleção cuidadosa de combinações entre técnicas de transformação de dados e métodos de validação. Assim, a escolha do modelo ideal deve considerar não apenas o valor de R^2 , mas também aspectos como tempo de treinamento, interpretabilidade e adequação ao contexto da aplicação.

5.6 Intervalos de Confiança

A análise dos intervalos de confiança das métricas de desempenho fornece uma estimativa da variabilidade dos resultados dos modelos, permitindo avaliar a robustez e a confiabilidade das predições. Para este estudo, foram calculados os intervalos de confiança a 95% para o coeficiente de determinação (R^2) dos modelos XGBoost e Random Forest com base nos diferentes cenários de validação cruzada.

	R ² Médio	IC Inferior (95%)	IC Superior (95%)
XGBoost	0.791870	0.781703	0.802037
Random Forest Regressor	0.770817	0.753649	0.787984

Tabela 8: Intervalos de confiança de 95% em relação à métrica de desempenho R²

O modelo XGBoost apresentou um valor médio de R² igual a 0,792, com um intervalo de confiança entre 0,782 e 0,802. Já o modelo Random Forest obteve um R² médio de 0,771, com intervalo de confiança variando entre 0,754 e 0,788. Esses intervalos foram calculados utilizando a distribuição normal padrão, considerando a média, o desvio padrão amostral e o número de repetições para cada modelo.

A interpretação desses intervalos é fundamental para compreender a estabilidade do desempenho dos modelos. O intervalo mais estreito e centrado em um valor elevado de R² indica maior precisão e consistência nas previsões. Nesse sentido, o XGBoost não apenas apresenta um desempenho médio superior, como também demonstra menor incerteza associada aos seus resultados, o que reforça sua confiabilidade.

No caso do modelo Random Forest, embora o intervalo de confiança também seja relativamente estreito, ele está centrado em um valor de R² inferior ao do XGBoost, o que sugere um desempenho globalmente mais modesto. No entanto, a consistência dos valores dentro do intervalo indica que o Random Forest ainda mantém um bom grau de estabilidade e previsibilidade, sendo uma alternativa viável dependendo do contexto de aplicação e da sensibilidade a pequenas perdas de desempenho.

Por fim, a ausência de sobreposição significativa entre os extremos superiores e inferiores dos intervalos sugere que as diferenças observadas entre os modelos não são fruto do acaso, mas refletem um comportamento estatisticamente consistente. Assim, os intervalos de confiança confirmam que, embora ambos os modelos sejam estáveis, o XGBoost se destaca como a opção mais robusta e confiável nos experimentos realizados.

Embora a principal métrica de interesse nesta análise seja o coeficiente de determinação (R²), é igualmente relevante avaliar o comportamento dos modelos em relação às métricas de erro absoluto e quadrático, como o MAE (Mean Absolute Error). A Tabela 9 apresenta os intervalos de confiança de 95% para o MAE dos modelos XGBoost e Random Forest.

	MAE Médio	IC Inferior (95%)	IC Superior (95%)
XGBoost	13453.421951	12986.287557	13920.556345
Random Forest Regressor	13529.842731	12679.571131	14380.114331

Tabela 9: Intervalos de confiança de 95% em relação à métrica de desempenho MAE

O XGBoost apresentou um MAE médio de aproximadamente 13.453, com intervalo de confiança entre 12.986 e 13.920. Já o Random Forest obteve um MAE médio de 13.530, com um intervalo um pouco mais amplo, variando entre 12.680 e 14.380. Apesar da proximidade entre os valores centrais, o intervalo mais estreito e inferior do XGBoost reforça sua vantagem em termos de estabilidade e precisão nas predições.

Portanto, mesmo sob a ótica do erro absoluto, os resultados corroboram a conclusão já evidenciada pelo R^2 : o modelo XGBoost demonstra desempenho mais robusto e confiável em comparação ao Random Forest neste conjunto de experimentos.

	MSE Médio	IC Inferior (95%)	IC Superior (95%)
XGBoost	3.551963e+08	3.376132e+08	3.727795e+08
Random Forest Regressor	3.920684e+08	3.623922e+08	4.217445e+08

Tabela 10: Intervalos de confiança de 95% em relação à métrica de desempenho MSE

A Tabela 10 apresenta os intervalos de confiança de 95% para a métrica de desempenho MSE (Mean Squared Error), complementando a análise realizada anteriormente com o R^2 e o MAE. Embora o MSE não seja a métrica principal deste estudo, sua consideração é importante por penalizar de forma mais acentuada os erros maiores, oferecendo uma perspectiva adicional sobre a performance dos modelos.

O modelo XGBoost obteve um MSE médio de aproximadamente $3,55 \times 10^8$, com intervalo de confiança entre $3,38 \times 10^8$ e $3,73 \times 10^8$. Por outro lado, o modelo Random Forest apresentou um MSE médio superior, em torno de $3,92 \times 10^8$, com intervalo de confiança mais amplo, entre $3,62 \times 10^8$ e $4,22 \times 10^8$.

Assim como observado nas métricas anteriores, o XGBoost não apenas apresenta menor erro médio, como também um intervalo mais estreito, o que indica maior estabilidade do modelo em diferentes execuções. Já o Random Forest, além de exibir um erro mais elevado, mostra maior variabilidade, o que pode comprometer a confiabilidade de suas previsões em contextos mais sensíveis.

Portanto, mesmo considerando a métrica MSE, os resultados reforçam a conclusão geral de que o XGBoost é o modelo mais robusto e consistente entre os avaliados.

5.7 Testes de Hipóteses

Os testes de hipóteses são procedimentos estatísticos utilizados para avaliar, com base em dados amostrais, se há evidência suficiente para rejeitar uma suposição inicial (hipótese nula) sobre um parâmetro populacional. Em outras palavras, trata-se de uma ferramenta fundamental para a tomada de decisões inferenciais, permitindo verificar se as diferenças observadas entre grupos, como o desempenho de modelos preditivos, são estatisticamente significativas ou se podem ser atribuídas ao acaso.

No contexto deste estudo, os testes de hipóteses foram empregados para comparar o desempenho dos modelos XGBoost e Random Forest quanto às métricas de avaliação MSE (Mean Squared Error), MAE (Mean Absolute Error) e R^2 (coeficiente de determinação). Para cada métrica, foram formuladas as seguintes hipóteses:

- Hipótese nula (H_0): não existe diferença significativa entre os desempenhos médios dos dois modelos;
- Hipótese alternativa (H_1): existe diferença significativa entre os desempenhos médios dos dois modelos.

Como os valores das métricas foram obtidos a partir de diferentes execuções (cenários de validação cruzada), adotou-se o teste t de Student para amostras independentes com variâncias não necessariamente iguais (teste Welch). Esse teste calcula uma estatística t e um p-valor correspondente, que quantifica a probabilidade de observar uma diferença igual ou maior do que a obtida caso a hipótese nula fosse verdadeira.

Métrica	Estatística t	p-valor
MSE	-2.095081	0.036844
MAE	-0.154392	0.877390
R2	2.068101	0.039326

Tabela 11: Estatísticas t e p-valores para Avaliação da Diferença de Desempenho entre os Modelos

Com base nos resultados dos testes de hipóteses aplicados às métricas de desempenho dos modelos XGBoost e Random Forest, é possível avaliar se as diferenças observadas são estatisticamente significativas a um nível de significância de 5% ($\alpha = 0,05$).

Para a métrica MSE (Mean Squared Error), o teste de Welch resultou em um valor de p igual a 0,0368. Como esse valor é inferior ao nível de significância adotado, rejeita-se a hipótese nula de igualdade de desempenho entre os modelos. Isso indica que há evidência estatística de que o erro quadrático médio apresentado pelos modelos difere significativamente, sendo o XGBoost o modelo com menor MSE. Dessa forma, conclui-se que o XGBoost apresenta desempenho estatisticamente superior nesta métrica, por oferecer previsões com menor variação em relação aos valores reais.

No caso da métrica MAE (Mean Absolute Error), o valor de p obtido foi 0,8774, consideravelmente superior ao nível de significância. Diante disso, não se rejeita a hipótese nula, o que significa que não há evidência suficiente para afirmar que os modelos diferem significativamente em relação ao erro absoluto médio. Assim, mesmo que o XGBoost tenha obtido um MAE ligeiramente menor, essa diferença pode ser atribuída à variabilidade amostral e não é estatisticamente relevante.

Por fim, quanto à métrica R^2 (coeficiente de determinação), o p-valor foi de 0,0393, também inferior a 0,05. Portanto, rejeita-se a hipótese nula e conclui-se que há diferença estatisticamente significativa entre os modelos quanto à capacidade de explicação da variabilidade dos dados. O XGBoost, por apresentar maior R^2 médio, demonstra melhor adequação ao conjunto de dados avaliado.

De modo geral, os testes de hipóteses corroboram os resultados da análise exploratória: o modelo XGBoost apresenta desempenho significativamente superior nas métricas MSE e R^2 , sendo mais preciso e explicativo que o Random Forest. A única métrica em que não se observou diferença estatística significativa foi o MAE, o que não compromete a conclusão de que o XGBoost é, de forma geral, o modelo mais robusto e confiável para o problema em questão.

5.8 Interpretação dos Resultados

Este plano de experimentação teve como objetivo encontrar os melhores modelos candidatos para estimar a vazão dos rios no município de Manaus, como estratégia indireta para antecipar episódios de enchentes na região. Diante da ausência de dados históricos estruturados sobre ocorrências de enchentes, optou-se por prever diretamente os valores de vazão, considerando que este é um dos principais indicadores hidrológicos associados a alagamentos.

Como analisado na Seção 5.6, o XGBoost demonstrou desempenho superior e mais estável em todas as métricas (R^2 , MAE, MSE). Ele não apenas teve valores médios melhores, mas também intervalos de confiança mais estreitos, indicando que é um modelo mais preciso e confiável em suas previsões.

A baixa correlação linear entre variáveis de chuva e a vazão sugere que a resposta hidrológica da bacia pode estar associada a efeitos cumulativos e atrasados, não capturados pelas variáveis utilizadas, mas simulados na criação de janelas de tempo, como chuva média nos últimos 7 dias. Além disso, essa baixa correlação muito provavelmente está relacionada à influência de dados climáticos provenientes de regiões vizinhas e até de efeitos globais, que afetam a bacia hidrográfica de Manaus de forma direta ou indireta. Considerando a formação demográfica e geográfica da região, onde diversos rios convergem de áreas externas ao município, como os rios que descem do alto Rio Negro e afluentes vindos do estado do Amazonas e da região de São Gabriel da Cachoeira, é possível que precipitações significativas ocorridas em localidades distantes impactem a vazão em Manaus com atraso, sem que essas chuvas estejam representadas nos dados meteorológicos locais. Fatores como defasagem temporal, saturação do solo, ocupação urbana e ausência de variáveis geográficas também podem ter contribuído para os desvios observados.

As implicações desses achados são relevantes: embora os modelos não sejam suficientes para prever diretamente a ocorrência de enchentes, eles e, principalmente, o XGBoost, fornecem uma estimativa razoável da vazão que pode ser utilizada como base para monitoramento hidrológico, gestão de recursos hídricos e emissão de alertas antecipados, sobretudo se integrado a outros dados e ferramentas de apoio à decisão. Assim, os modelos representam um avanço importante e podem servir como ferramenta preliminar para sistemas de alerta e suporte à tomada de decisão em gestão de riscos hídricos na região.

5.9 Visualização dos Resultados

Nesta seção, são apresentadas visualizações gráficas com o objetivo de facilitar a interpretação dos resultados obtidos tanto pelo Random Forest, quanto pelo XGBoost. Por meio de gráficos de dispersão, histogramas de erro e matriz de correlação, é possível avaliar a qualidade das previsões, identificar padrões de erro, verificar a relação entre variáveis e compreender o comportamento geral dos modelos. Essas representações visuais complementam as métricas numéricas e oferecem insights valiosos sobre o desempenho e as limitações dos modelos aplicados à previsão de vazão no município de Manaus.




Gráfico 29: Comparação de Resíduos e Valores Previstos do Random Forest

Este gráfico apresenta a dispersão dos resíduos em relação aos valores previstos pelo modelo Random Forest Regressor. Ele é fundamental para verificar a adequação do modelo, especialmente no que diz respeito à linearidade, heterocedasticidade e presença de *outliers*.

O Gráfico 29 mostra que o modelo Random Forest está se comportando bem. Os resíduos são relativamente aleatórios e simétricos, com pequena variação maior nos extremos. Isso sugere adequação e não há sinais fortes de erro sistemático.

Observa-se que os resíduos estão relativamente bem distribuídos em torno da linha zero (em vermelho), o que é um indicativo positivo. Isso sugere que o modelo não apresenta viés sistemático e que os erros de previsão são, em média, próximos de zero ao longo da faixa de valores previstos.

No entanto, nota-se uma leve dispersão maior dos resíduos nas extremidades (valores muito altos ou muito baixos de vazão), o que pode indicar heterocedasticidade, ou seja, a variância dos erros não é constante. Isso é comum em dados hidrológicos, onde eventos extremos (altas ou baixas vazões) tendem a ser mais difíceis de prever com precisão.

Também é possível identificar *outliers*, ou seja, pontos muito distantes da linha de resíduos igual a zero, especialmente no intervalo entre 125.000 e 175.000 m³/s. Esses valores extremos podem estar relacionados a eventos atípicos de cheia ou falhas na entrada dos dados, e devem ser analisados com mais atenção.

Em resumo, o gráfico mostra um desempenho razoável do modelo, com erros distribuídos aleatoriamente e sem padrões estruturais evidentes. Ainda assim, há indícios de heterocedasticidade e presença de *outliers*, o que reforça a necessidade de técnicas robustas de modelagem e validação. Essa análise corrobora os resultados numéricos anteriormente observados, indicando que o modelo é eficaz, embora existam oportunidades para aperfeiçoamento em faixas específicas da distribuição de vazão.




Gráfico 30: Distribuição dos Resíduos do Random Forest

O Gráfico 30 apresenta a distribuição dos resíduos do modelo Random Forest, com o objetivo de verificar se os erros de predição seguem uma distribuição aproximadamente normal, o que é uma suposição desejável para muitos métodos estatísticos e de validação.

Acima, é possível notar que a distribuição dos resíduos é aproximadamente normal e centrada em 0, indicando que a maioria dos erros são pequenos e distribuídos de forma equilibrada. Entretanto, o gráfico possui, também, distribuição leptocúrtica, com caudas mais pesadas que o ideal, podendo indicar a presença de outliers ou observações mais difíceis de prever. Para o Random Forest, este comportamento é relativamente comum devido ao fato do modelo suavizar previsões em regiões com poucos dados, embora não seja um cenário ideal.

Observa-se também que a curva de densidade (linha azul) se aproxima da forma de uma curva normal, sugerindo que os resíduos se distribuem de maneira aproximadamente gaussiana.

Entretanto, também é possível notar a presença de caudas mais alongadas, especialmente à direita, o que pode indicar uma leve assimetria positiva ou a existência de outliers positivos (superestimativas da vazão). Ainda assim, o número desses casos é pequeno em comparação com a massa central da distribuição, o que reforça a robustez geral do modelo.

Em resumo, a distribuição dos resíduos sugere um bom ajuste do Random Forest à tarefa de regressão. O comportamento próximo do normal reforça a validade do modelo e indica que ele está capturando bem a estrutura dos dados, com erros majoritariamente pequenos e sem grandes vieses sistemáticos. Ainda assim, é prudente investigar casos extremos para entender possíveis limitações em eventos atípicos.




Gráfico 31: QQ-Plot dos Resíduos do Random Forest

O Gráfico 31 apresenta o QQ-Plot dos resíduos do modelo Random Forest, uma ferramenta estatística utilizada para avaliar visualmente o quão próxima a distribuição dos resíduos está de uma distribuição normal teórica. Um QQ-Plot (Quantile-Quantile Plot) compara os quantis da distribuição dos resíduos observados com os quantis de uma distribuição teórica, geralmente a normal padrão $N(0,1)$. Resumidamente, se os resíduos seguem uma distribuição normal, os pontos azuis devem estar tão próximos quanto possível da linha vermelha. Pelo gráfico, é notável que os resíduos são aproximadamente normais no centro, mas com desvios significativos nas caudas, comportamento já sugerido pelo histograma. A distribuição não é perfeitamente normal, mas isso não é um problema crítico para modelos como Random Forest, que não exigem normalidade nos resíduos e são paramétricos e robustos a outliers.

Podemos observar que a figura mostra desvios significativos da linha reta nos extremos da distribuição, especialmente nas caudas inferior e superior. Esse comportamento indica a presença de resíduos extremos (*outliers*) e violação da normalidade nas caudas. No centro da distribuição, os pontos se aproximam mais da linha, o que é esperado: a maioria dos resíduos está próxima de zero e se distribui de maneira relativamente simétrica.

Esse padrão sugere que, embora o modelo produza erros geralmente pequenos e bem distribuídos, ele não segue uma distribuição normal exata, especialmente nos casos extremos. Essa constatação não compromete necessariamente a validade do modelo, mas indica que os testes estatísticos que assumem normalidade dos resíduos devem ser utilizados com cautela. A presença de outliers reforça também a importância de estratégias de tratamento de valores extremos e validação robusta do modelo.

Em suma, o QQ-Plot confirma que os resíduos do Random Forest estão razoavelmente centrados, mas com caudas mais pesadas do que o ideal normal, o que é comum em séries temporais ambientais e modelos aplicados a fenômenos hidrológicos.




Gráfico 32: Comparação de Valores Preditos e Valores Observados do Random Forest

O Gráfico 32 exibe a comparação entre os valores preditos e os valores observados do modelo Random Forest, sendo uma ferramenta essencial para avaliar a acurácia e o grau de ajuste do modelo. No gráfico, cada ponto representa uma previsão individual, posicionada em relação ao valor real correspondente. A linha tracejada vermelha representa a linha de identidade, ou seja, o local onde os valores preditos seriam exatamente iguais aos observados (linha 45°).

O gráfico 32 mostra um alinhamento forte com a linha ideal, em vermelho, exibindo pontos próximos à ela em toda sua extensão, além de poucos desvios significativos sem padrão aparente, fazendo deles desvios não sistemáticos. Nota-se, também, que o modelo não possui tendência a subestimar ou superestimar os valores de forma consistente, o que é ideal.

A distribuição dos pontos próximos à linha vermelha indica que o modelo apresenta alto poder de previsão, com um alinhamento bastante consistente entre as estimativas e os dados reais. Essa forte aderência à linha de identidade confirma a alta correlação entre as variáveis predita e observada, já sugerida anteriormente pelo valor elevado do coeficiente de determinação ($R^2 \approx 0.79$, na média, e até 0.99 na melhor *pipeline*).

Pequenas dispersões ao redor da linha são esperadas em qualquer modelo realista, especialmente para valores extremos de vazão, onde a variabilidade natural é maior e os erros de previsão tendem a aumentar. Ainda assim, não há indícios de tendência sistemática de superestimação ou subestimação, o que reforça a imparcialidade e robustez do modelo Random Forest na tarefa de previsão da vazão dos rios.

Em resumo, este gráfico evidencia visualmente que o modelo Random Forest apresenta bom desempenho geral e boa generalização, sendo capaz de prever os níveis de vazão com elevada precisão e estabilidade.




Gráfico 33: Importância das Features para o Random Forest

O Gráfico 33 apresenta a importância relativa das variáveis (*features*) utilizadas pelo modelo Random Forest na tarefa de previsão da vazão em Manaus. A métrica de importância reflete o quanto cada variável contribui para a tomada de decisão nas árvores do modelo, ou seja, quanto maior a importância, mais a variável ajuda a reduzir o erro de predição.

Apenas as cinco *features* mais importantes foram incluídas nos gráficos buscando uma melhor interpretabilidade. É possível notar que variáveis relativas à passagem do tempo, como “mes”, “ano” e “dia” possuem grande importância, com “mes” tendo um destaque extremo. Por ser um problema de vazão de rios, faz sentido “chuva_final” ser a segunda *feature* mais importante, uma vez que ambos os conceitos estão relacionados pelo ciclo hidrológico local.

O destaque absoluto vai para a variável “mês”, que representa o componente sazonal do tempo. Com importância superior a 0,85, o mês do ano é disparadamente a feature mais relevante, indicando que a sazonalidade anual é o fator mais determinante na variação da vazão dos rios. Isso é coerente com os resultados das análises temporais anteriores, que evidenciaram fortes padrões cíclicos de cheia e vazante ao longo dos anos.

Outras variáveis, como “chuva_final” e “ano”, possuem contribuições bem menores, porém não desprezíveis. A variável chuva_final aparece em segundo lugar, o que corrobora sua relevância na explicação de variações mais imediatas da vazão, ainda que sua influência seja ofuscada pela forte regularidade sazonal.

As variáveis “dia” e “areakm” (área desmatada), por outro lado, apresentaram importância quase nula para o modelo. Isso pode ser explicado, respectivamente, pela

granularidade dos dados (a previsão é mensal, tornando o dia pouco informativo) e pelo comportamento estrutural e pouco variável da variável de desmatamento, conforme observado nas análises exploratórias.

Em resumo, o gráfico reforça a importância da variável temporal "mês" como principal determinante da previsão de vazão.




Gráfico 34: Curva de Aprendizado do Random Forest

O Gráfico 34 apresenta a Curva de Aprendizado do modelo Random Forest com base na métrica de erro RMSE (Root Mean Squared Error), em função do número de amostras de treino utilizadas. Essa análise é fundamental para entender a capacidade de generalização do modelo, além de fornecer insights sobre possíveis problemas de viés ou variância.

A linha azul representa o erro de treinamento, que permanece consistentemente baixo e praticamente estável à medida que o número de amostras aumenta. Isso indica que o modelo é altamente capaz de se ajustar aos dados de treino, o que é esperado em algoritmos como o Random Forest, que tendem a ter baixa tendência (viés). A curva em azul, por ser quase plana e muito baixa, mostra que o modelo aprende muito bem com os dados de treino, de forma a quase categorizar *overfitting*. A curva em laranja, por sua vez, demonstra um erro no treino significativamente maior e com variância, representada pela região laranja, que aumenta com a quantidade de dados. Ambos estes fatores, quando combinados, podem evidenciar um *overfitting* leve a moderado, ou seja, o modelo se ajusta muito bem aos dados de treino, mas não generaliza tão bem para novos dados, sendo necessário retrabalhá-lo caso fosse selecionado como modelo final.

A diferença acentuada entre as curvas de treino e validação sugere que o modelo pode estar sofrendo de *overfitting*, ou seja, ele aprende muito bem os dados de treino, mas não

generaliza tão bem para novos dados. Esse cenário é comum em problemas com dados ruidosos ou quando o modelo é muito complexo em relação ao número de exemplos disponíveis.

Além disso, observa-se que a adição de mais amostras de treino não está reduzindo significativamente o erro de validação, o que indica que o modelo talvez já tenha atingido seu limite de aprendizado com os dados disponíveis. Nesse contexto, a melhoria do desempenho pode depender mais da engenharia de atributos ou de ajustes nos hiperparâmetros do que do simples aumento da base de dados.

Em resumo, o gráfico evidencia que o modelo Random Forest apresenta baixa tendência, mas sofre com variância e *overfitting*, o que reforça a importância de validações robustas e da busca por técnicas que ajudem a aumentar sua capacidade de generalização.




Gráfico 35: Comparação de Resíduos e Valores Previstos do XGBoost

O Gráfico 35 apresenta a dispersão dos resíduos em relação aos valores previstos pelo modelo XGBoost, um passo essencial para avaliar a qualidade do ajuste em modelos de regressão. A análise desse gráfico permite verificar a presença de padrões sistemáticos, heterocedasticidade ou *outliers* que podem comprometer a robustez da modelagem.

Pelo Gráfico 35, nota-se que os resíduos estão bem distribuídos em torno do eixo x (resíduo nulo), indicando baixo viés sistemático, e que não há um padrão visível como curvaturas ou tendências, o que mostra que o modelo está captando bem as relações nos dados. Além disso, a dispersão é simétrica e razoavelmente uniforme com heterocedasticidade pouco evidente.

Além disso, a dispersão dos resíduos ao longo do eixo dos valores previstos se mantém relativamente constante, sem um aumento claro da variância conforme os valores previstos aumentam. Isso indica que o modelo XGBoost não sofre significativamente de heterocedasticidade, o que é um bom sinal em termos de estabilidade preditiva.

Apesar disso, é possível identificar a presença de alguns valores residuais extremos (*outliers*), tanto positivos quanto negativos, que ultrapassam os 20.000 m³/s em magnitude. Embora esses casos sejam pontuais, eles indicam que o modelo pode ainda ter dificuldades em prever com precisão os extremos, algo comum em séries hidrológicas.

Em resumo, o gráfico evidencia um bom comportamento geral dos resíduos do modelo XGBoost, sem padrões sistemáticos nem evidência clara de variância não constante. A distribuição simétrica e a concentração ao redor do zero indicam que o modelo está bem ajustado à maior parte dos dados, ainda que pontos extremos possam demandar atenção especial em aplicações futuras.




Gráfico 36: Distribuição dos Resíduos do XGBoost

O Gráfico 36 exibe a distribuição dos resíduos do modelo XGBoost, permitindo uma análise sobre a normalidade e simetria dos erros cometidos pelo modelo. Trata-se de uma representação crucial para avaliar a adequação estatística do ajuste e a validade de suposições associadas à regressão.

Pelo gráfico, o modelo XGBoost aparenta ter resíduos com distribuição aproximadamente normal, simétrica e centrada em zero, o que é um forte indicativo de que o modelo comete erros pequenos e equilibrados na maioria das previsões. Esse comportamento sugere que o XGBoost não apresenta viés sistemático e que os resíduos têm distribuição razoavelmente normal, um pressuposto desejável para a aplicação de diversos testes estatísticos e intervalos de confiança. Além do mais, pode-se dizer que tem baixa ocorrência de outliers pelo fato das caudas serem suaves e curtas com poucos resíduos situando-se em regiões extremas (acima de ± 10.000 m³/s). Isso é um forte indicativo de que os erros do modelo são estáveis, previsíveis e bem comportados, ideal para aplicações de regressão. Em comparação ao Random Forest, isto reforça a robustez do modelo contra outliers, cuja distribuição era mais assimétrica e dispersa.

Em síntese, este gráfico confirma que os resíduos do modelo XGBoost estão bem comportados estatisticamente, próximos a uma distribuição normal centrada em zero, o que reforça a qualidade do ajuste obtido e a confiabilidade das previsões, especialmente em situações típicas (não-extremas).




Gráfico 37: QQ-Plot dos Resíduos do XGBoost

O Gráfico 37 apresenta o QQ-Plot (Quantile-Quantile Plot) dos resíduos do modelo XGBoost, com o objetivo de avaliar a aderência dos resíduos a uma distribuição normal. Esse tipo de gráfico compara os quantis teóricos da distribuição normal com os quantis empíricos dos resíduos, permitindo identificar desvios em relação à normalidade.

O Gráfico 37 mostra que o XGBoost segue razoavelmente bem uma distribuição normal, com pequenos desvios nos valores mais extremos da reta, mas alinhamento forte no centro. Isso reforça que os erros do modelo são estatisticamente bem comportados, e que o modelo possui boa capacidade preditiva com baixa distorção.

Visualmente, observa-se que a maior parte dos pontos está alinhada com a linha vermelha de referência, especialmente entre os quantis teóricos de aproximadamente -2 e +2, indicando que a maioria dos resíduos segue uma distribuição aproximadamente normal nesse intervalo. Nesses quantis, os resíduos variam de cerca de -6.000 a +6.000 m³/s, com boa aderência à linha teórica.

Entretanto, nos extremos da distribuição, ou seja, para quantis teóricos menores que -2 e maiores que +2, nota-se um leve afastamento dos pontos em relação à linha, revelando presença de caudas mais pesadas do que o esperado sob normalidade perfeita. Por exemplo, resíduos abaixo de -10.000 m³/s e acima de +10.000 m³/s aparecem como *outliers* leves, mas ainda com frequência bastante reduzida.

Apesar dessas pequenas divergências nos extremos, o comportamento geral do QQ-Plot é

satisfatório. Ele reforça a conclusão de que os resíduos do modelo XGBoost estão razoavelmente próximos de uma distribuição normal, com simetria adequada e ausência de viés sistemático, o que é desejável para garantir robustez e confiabilidade estatística nas previsões e análises subsequentes.




Gráfico 38: Comparação de Valores Preditos e Valores Observados do XGBoost

O Gráfico 38 apresenta a comparação entre os valores previstos e os valores observados pelo modelo XGBoost, com o objetivo de avaliar visualmente a precisão das previsões. Cada ponto azul representa um par (valor observado, valor previsto), e a linha vermelha tracejada indica a linha ideal de referência onde os valores previstos seriam exatamente iguais aos observados (linha de identidade: $y = x$).

O Gráfico 38 demonstra uma forte correlação linear e excelente aderência à linha ideal, indicando que as previsões são altamente precisas e consistentes com os valores reais. Nota-se que uma particularidade: os dados seguem um padrão quase linear, com pequenas dispersões em torno da linha, especialmente nas extremidades, o que é comum em problemas de regressão com dados reais. O XGBoost mostra-se eficaz, apresentando pouca dispersão dos pontos e grande fidelidade ao comportamento dos dados reais.

Além disso, não há indícios de viés sistemático: os desvios parecem aleatórios ao longo de toda a faixa de valores, o que reforça a capacidade do modelo de generalizar bem sobre diferentes magnitudes de vazão, tanto em valores baixos (próximos a 50.000 m³/s) quanto elevados (acima de 200.000 m³/s).

Em resumo, o gráfico reforça a robustez e a precisão do XGBoost na tarefa de prever a vazão dos rios, evidenciando sua adequação como modelo preditivo no contexto estudado.




Gráfico 39: Importância das Features para o XGBoost

O Gráfico 39 apresenta a importância relativa das variáveis (features) utilizadas pelo modelo XGBoost na tarefa de previsão da vazão dos rios em Manaus. A métrica de importância utilizada reflete a contribuição de cada atributo na construção das árvores do modelo, ou seja, sua capacidade de reduzir o erro ao longo das divisões.

Como esperado, as variáveis mais importantes são relacionadas à chuva e à passagem do tempo, alinhando-se com o fato dos dados serem Séries Temporais sobre a vazão do rio Negro. Além disso, por “mes” ser tão mais importante que “ano” e “dia”, pode-se concluir que os padrões climáticos são realmente atribuídos à época do ano, e não tanto ao ano em si, e a fenômenos que causam efeitos pouco perceptíveis de um dia para o outro, mas cumulativos e de longo prazo.

A variável mais relevante com ampla vantagem é o mês, com importância superior a 0,75, o que indica que o modelo aprende padrões sazonais marcantes ao longo do ano, coerente com a natureza cíclica do regime de vazão na Amazônia, em que há épocas bem definidas de cheia e seca.

A segunda variável mais importante é “chuva_final”, com importância em torno de 0,12, reforçando o papel da precipitação recente na previsão da vazão. Isso está alinhado com análises anteriores que mostram uma relação significativa entre chuvas acumuladas e o aumento no volume dos rios, embora com certa defasagem temporal.

As demais variáveis “ano”, “dia” e “areakm” apresentam importância muito reduzida, inferior a 0,1, sugerindo que têm contribuição marginal na capacidade preditiva do modelo. O baixo impacto de “areakm” pode ser explicado por sua baixa variabilidade ao longo do tempo (já que foi interpolada a partir de dados anuais), o que dificulta que o modelo aprenda padrões significativos a partir dela.

Em resumo, o gráfico evidencia que o XGBoost baseia fortemente suas previsões em

padrões temporais sazonais (mês) assim como o Random Forest e, em menor escala, nas informações recentes de chuva. Isso destaca a importância de incluir variáveis derivadas do tempo e de precipitação na modelagem hidrológica da região.




Gráfico 40: Curva de Aprendizado do XGBoost

O Gráfico 40 apresenta a curva de aprendizado do modelo XGBoost, comparando o erro quadrático médio (RMSE) em função do número de amostras de treino, tanto para o conjunto de treinamento (linha azul) quanto para o conjunto de validação (linha laranja, com faixa de desvio).

A curva de aprendizado demonstra um erro no treino baixo mas crescente, juntamente de um erro de validação consideravelmente maior, indicando um possível *overfitting*. A região sombreada em laranja mostra a variância ou intervalo de confiança que aumenta conforme o número de dados, sugerindo flutuação na performance do modelo nos dados de validação.

Observa-se que o erro no conjunto de treinamento permanece consistentemente baixo ao longo de todo o crescimento do conjunto de dados, variando entre aproximadamente 500 e 2000, o que indica que o modelo consegue se ajustar bem aos dados que já viu. No entanto, a curva de validação apresenta um comportamento mais estável e elevado, com valores de RMSE entre 18000 e 26000, e uma faixa de variação (sombreamento) considerável, indicando instabilidade na generalização para dados não vistos.

A distância significativa entre as curvas de treino e validação sugere *overfitting*, ou seja, o modelo aprende muito bem os padrões específicos dos dados de treino, mas não generaliza com a mesma eficiência para novos dados. Esse comportamento é típico de modelos com alta complexidade, como o XGBoost, especialmente em conjuntos de dados com ruído, variabilidade temporal ou volume limitado.

Além disso, o aumento no número de amostras de treino não resultou em uma queda acentuada no erro de validação, o que indica que o modelo já está próximo de sua capacidade máxima de aprendizado com os dados disponíveis, ou que há espaço para melhorias no pré-processamento, engenharia de atributos ou ajuste de hiperparâmetros.

Em resumo, o gráfico mostra que o modelo XGBoost tem alto poder de ajuste, mas sofre com generalização, reforçando a necessidade de técnicas de regularização, validação cruzada mais robusta ou até mesmo seleção de atributos mais criteriosa.




Gráfico 41: Matriz de Correlação

A matriz de correlação (Gráfico 41) revela a intensidade das relações lineares entre todas as variáveis numéricas do conjunto de dados. A maioria das correlações está concentrada em torno de valores baixos a moderados, com algumas exceções de correlação forte, principalmente entre variáveis do mesmo grupo temático (chuva, temperatura, umidade).

O heatmap de correlação revela que há fortes intercorrelações dentro de grupos de variáveis semelhantes, como chuva, temperatura e umidade. Ele indica também que a variável

“vazao” (target) não tem correlação linear forte com nenhuma variável isolada, indicando a necessidade de modelagem não linear. Além do mais, a presença de variáveis altamente redundantes pode justificar redução de dimensionalidade ou seleção de atributos para simplificar o modelo. Por fim, algumas variáveis, como vento e ano, parecem ter baixa relevância direta, mas ainda podem ser úteis em modelos não lineares dependendo das interações.

5.10 Modelo Final Selecionado

Ao comparar os resultados do Random Forest e do XGBoost a partir das diferentes visualizações diagnósticas do tópico 5.9, foi possível encontrar algumas diferenças cruciais entre os dois modelos. A análise das curvas de aprendizado revelou que ambos apresentam curvas de validação similares, com o erro estabilizando conforme o número de amostras de treino aumenta. No entanto, uma diferença significativa foi observada nas curvas de treino: enquanto o Random Forest mantém um erro de treino extremamente baixo e praticamente constante, o XGBoost apresenta uma leve elevação do erro de treino à medida que o número de amostras cresce. Esse comportamento sugere que o XGBoost realiza uma regularização mais eficaz, reduzindo o risco de *overfitting* e promovendo uma generalização mais robusta.

Os gráficos de resíduos em função dos valores previstos evidenciaram que o XGBoost apresenta uma dispersão mais homogênea e concentrada em torno de zero, com menor variabilidade e menos outliers em comparação ao Random Forest. Este, por sua vez, exibiu maior amplitude dos resíduos e sinais de heterocedasticidade, principalmente em valores previstos mais altos. Essa diferença indica que o XGBoost é mais eficaz em manter a estabilidade dos erros ao longo da faixa de predições.

A distribuição dos resíduos, avaliada por meio dos histogramas, reforçou esses achados. O modelo XGBoost apresentou uma distribuição aproximadamente normal, simétrica e centrada em zero, o que é desejável em problemas de regressão. O Random Forest, embora com distribuição semelhante, apresentou caudas mais pesadas e maior dispersão dos resíduos. Essa diferença foi corroborada pelos gráficos QQ-Plot, onde o do XGBoost mostrou alinhamento forte com a distribuição normal nos quantis centrais e desvios suaves apenas nas extremidades, enquanto o Random Forest apresentou desvios mais acentuados nas caudas, indicando maior presença de erros extremos.

Por fim, o gráfico de valores preditos versus observados revelou que ambos os modelos se alinham bem à linha ideal (onde previsto = observado), mas o XGBoost mostrou uma dispersão ainda menor dos pontos em torno dessa linha. Isso indica maior precisão nas predições e menor erro geral.

Dessa forma, com base na análise conjunta das curvas de aprendizado, distribuição e comportamento dos resíduos, e precisão preditiva, conclui-se que o modelo XGBoost apresentou desempenho superior ao Random Forest. O XGBoost demonstrou maior capacidade de generalização, melhor controle de variância, e predições mais estáveis e consistentes, sendo, portanto, o modelo mais adequado para o problema em questão.

6. Conclusões e Desafios Enfrentados

6.1 Principais Descobertas

A análise dos resultados experimentais permitiu identificar descobertas fundamentais para a construção de um modelo preditivo robusto e confiável para previsão da vazão dos rios em Manaus, contribuindo diretamente para o objetivo central deste projeto. Os gráficos apresentados na seção anterior forneceram informações cruciais sobre o comportamento dos modelos testados, destacando aspectos de desempenho, estabilidade, padrão dos erros e capacidade de generalização.

Inicialmente, a comparação entre os modelos Random Forest e XGBoost evidenciou que ambos apresentaram alta correlação entre valores preditos e observados, conforme mostrado nos gráficos de dispersão (Gráficos 32 e 38). Esse alinhamento próximo à linha de identidade (linha vermelha) indica que os modelos foram eficazes em capturar a relação entre as variáveis meteorológicas, hidrológicas e a vazão dos rios, validando a abordagem de modelagem adotada.

Contudo, ao aprofundar a análise, observou-se que o modelo XGBoost apresentou desempenho superior, tanto em termos de erro quanto em qualidade dos resíduos. As curvas de aprendizado (Gráficos 34 e 40) revelaram que, embora ambos os modelos mostrem sinais de *overfitting*, o XGBoost manteve menores valores de erro de validação (RMSE) ao longo de todas as amostras de treino, com menor variação entre os folds. Isso indica maior capacidade de generalização, o que é essencial para aplicações em cenários reais, onde os dados de entrada variam ao longo do tempo.

A análise residual foi determinante para compreender a qualidade do ajuste dos modelos. Os gráficos de distribuição dos resíduos (Gráficos 30 e 36) mostram que, no caso do XGBoost, os resíduos estão mais concentrados em torno de zero e se distribuem de forma aproximadamente simétrica, característica desejável em modelos preditivos. O QQ-Plot (Gráfico 37) reforça esse achado ao demonstrar que os resíduos do XGBoost se alinham melhor com a distribuição normal teórica, indicando ausência de viés sistemático. Já o Random Forest apresentou maiores desvios nos quantis extremos (Gráfico 31), sugerindo menor aderência estatística.

Outro aspecto relevante foi a análise dos resíduos em função dos valores previstos (Gráficos 29 e 35). No modelo XGBoost, os resíduos estão distribuídos aleatoriamente ao redor do zero, com ausência de padrões ou heterocedasticidade, o que indica que o modelo não comete erros sistemáticos em nenhuma faixa da variável predita, um indicativo de consistência e robustez.

Esses resultados orientaram diretamente a escolha do modelo preditivo final. A partir dos insights obtidos:

- Pôde-se confirmar que o XGBoost era o modelo mais adequado para a tarefa de prever a vazão dos rios em Manaus;

- A análise de resíduos ajudou a validar que os erros estavam sob controle e sem viés;
- A curva de aprendizado indicou que o modelo era estável e poderia ser alimentado com mais dados no futuro;
- A relação clara entre predito e observado mostrou que o modelo aprendeu bem os padrões subjacentes aos dados ambientais da região.

Portanto, os resultados não apenas comprovaram a viabilidade da previsão da vazão como também direcionaram com segurança a escolha da arquitetura final do modelo, que poderá ser utilizado como base para aplicações futuras voltadas ao monitoramento hidrológico e apoio à infraestrutura energética da região amazônica.

Os resultados obtidos ao longo deste projeto respondem diretamente à questão de pesquisa:

Como a previsão da vazão dos rios de Manaus pode contribuir para o planejamento mais eficaz da infraestrutura de energia renovável, ajudando a prevenir danos a instalações e orientar a expansão sustentável das fontes energéticas na região amazônica?

Respondendo à pergunta a partir dos resultados obtidos ao longo do projeto, a previsão da vazão dos rios de Manaus contribui de forma decisiva para o planejamento mais eficaz da infraestrutura de energia renovável na região amazônica ao fornecer um indicador antecipado de riscos hidrológicos, possibilitando respostas preventivas por parte de gestores públicos e operadores do setor energético. Ao identificar padrões de aumento anormal na vazão com base em dados climáticos, ambientais e históricos, o modelo preditivo desenvolvido permite antecipar eventos de cheia, que frequentemente colocam em risco instalações como centrais hidrelétricas, turbinas flutuantes, painéis solares e redes de distribuição localizadas em áreas ribeirinhas.

A experimentação e a análise detalhada dos modelos demonstraram que a previsão da vazão é não apenas tecnicamente viável, mas também altamente informativa para a tomada de decisão estratégica em contextos de planejamento energético. A seleção do modelo XGBoost, fundamentada em sua superioridade nas métricas de erro (menor RMSE), estabilidade entre os folds e comportamento estatístico dos resíduos, indica que a modelagem proposta consegue prever com confiabilidade as variações nos níveis dos rios de Manaus, mesmo diante da alta variabilidade climática e hidrológica da região.

Além disso, os insights extraídos como a relevância das variáveis de precipitação acumulada em janelas móveis, o efeito indireto do desmatamento na amplificação da vazão, e a resposta não imediata das bacias à chuva, permitem elaborar modelos que antecipam com antecedência útil os picos de vazão, o que é essencial para evitar danos a infraestruturas de energia renovável e ajustar planos de operação e expansão em áreas suscetíveis a cheias.

Essa capacidade preditiva apoia a tomada de decisões operacionais e estruturais, como o

redirecionamento do fluxo de energia, o desligamento temporário de componentes vulneráveis ou a adaptação de cronogramas de expansão para evitar áreas de alto risco. Além disso, ao considerar variáveis como chuva acumulada, desmatamento e temperatura, o modelo oferece uma compreensão mais completa das condições que antecedem variações extremas de vazão, tornando possível um planejamento territorial mais resiliente.

Por fim, a previsão de vazão também orienta a expansão sustentável das fontes energéticas ao identificar zonas de menor vulnerabilidade hídrica, permitindo a instalação de novas infraestruturas com menor risco de interrupção. Dessa forma, a modelagem preditiva apresentada no projeto fortalece a capacidade da cidade de Manaus e, por extensão, da Amazônia, de consolidar uma matriz energética renovável mais segura, eficiente e adaptada às mudanças climáticas.

Dessa forma, os achados do projeto mostram que a previsão da vazão fluvial, ao traduzir dados ambientais em alertas quantitativos de risco hidrológico, fornece uma base técnica robusta para orientar políticas públicas, ações de contingência e estratégias de desenvolvimento sustentável na Amazônia. Isso reforça o papel da ciência de dados como ferramenta crítica no planejamento de infraestruturas resilientes e na promoção de uma matriz energética mais segura e adaptada à realidade climática regional.

6.2 Implicações dos Resultados

Os resultados obtidos neste projeto possuem implicações práticas significativas tanto para os clientes diretos, como os órgãos públicos de planejamento e defesa civil de Manaus (SEMMAS, CEMIG/Semdec), quanto para o setor de energia renovável como um todo, especialmente no contexto da Amazônia Legal. A capacidade comprovada de prever a vazão dos rios de Manaus com base em dados climáticos, hidrológicos e ambientais representa um avanço estratégico na gestão de riscos ambientais e no planejamento energético sustentável.

Em primeiro lugar, a principal contribuição prática recai sobre a possibilidade de antecipar eventos de cheia com base em sinais hidrológicos confiáveis. A previsão da vazão permite identificar com antecedência períodos de maior risco, possibilitando que órgãos de defesa civil atuem preventivamente, deslocando equipamentos, ajustando planos de contingência e protegendo comunidades vulneráveis. Isso é particularmente relevante em uma cidade como Manaus, onde cheias históricas têm causado impactos severos à infraestrutura urbana, à logística fluvial e ao abastecimento energético.

No setor energético, os modelos preditivos desenvolvidos oferecem suporte direto para aumentar a resiliência das infraestruturas de energia renovável. Ao prever aumentos significativos na vazão dos rios, é possível ajustar operações de centrais hidrelétricas, adiar a instalação de turbinas ou painéis solares em áreas críticas, e planejar rotas alternativas de distribuição. Esse tipo de monitoramento ativo, baseado em dados e inteligência artificial, reduz o risco de perdas operacionais, melhora a eficiência na gestão dos recursos hídricos e diminui a dependência de fontes fósseis, ainda predominantes em muitos sistemas isolados da região Norte.

Além disso, os resultados do projeto fornecem insumos técnicos que podem orientar políticas públicas de adaptação climática e expansão energética sustentável. Ao identificar os fatores que mais influenciam a vazão (como chuvas acumuladas e cobertura vegetal), o modelo permite priorizar investimentos em regiões de menor vulnerabilidade hídrica e planejar infraestruturas com maior consciência ambiental. Essa abordagem baseada em dados é essencial para compatibilizar crescimento energético com conservação ambiental e justiça climática.

Outro aspecto importante é a replicabilidade e escalabilidade da metodologia. O modelo desenvolvido pode ser adaptado para outros municípios da Amazônia Legal, desde que haja disponibilidade mínima de dados hidrometeorológicos locais. Isso amplia o impacto potencial do projeto, tornando-o uma ferramenta de apoio regional para planejamento energético, monitoramento ambiental e resposta a desastres naturais.

Por fim, os resultados contribuem para fortalecer a proposta de “Amazonizar” o desenvolvimento, ao integrar saberes ambientais e tecnologia de dados em prol de soluções adaptadas à realidade amazônica. A previsão da vazão, como solução intermediária entre dados de enchentes e decisões operacionais, representa um elo fundamental entre ciência, território e ação concreta. Dessa forma, o projeto se alinha às metas de sustentabilidade, transição energética e resiliência climática tanto em escala local quanto nacional.

6.3 Limitações do Estudo

Embora os resultados obtidos neste projeto tenham demonstrado o potencial da modelagem preditiva para antecipar a vazão dos rios de Manaus, é importante reconhecer as limitações que influenciaram o desempenho, a abrangência e a confiabilidade dos modelos desenvolvidos. Essas restrições envolvem principalmente questões relacionadas aos dados, à metodologia aplicada e à complexidade inerente ao sistema hidrológico amazônico.

A primeira e mais evidente limitação diz respeito à disponibilidade e qualidade dos dados utilizados. Embora tenha sido possível reunir séries temporais consistentes para as variáveis de interesse (chuva, vazão, desmatamento, clima), muitos desses dados apresentavam lacunas, descontinuidades ou granularidades distintas, exigindo técnicas de interpolação e imputação. Isso foi especialmente notável nos períodos mais antigos da base, como os anos 1990, nos quais os registros de precipitação em Manaus estavam ausentes e foram preenchidos com médias mensais. Essa estratégia, ainda que metodologicamente válida, pode ter reduzido a variabilidade natural dos dados e, portanto, impactado a acurácia da modelagem em determinados intervalos temporais.

Além disso, o dado de desmatamento, por ser originalmente anual, teve que ser interpolado para uma média diária constante ao longo de cada ano. Essa transformação suaviza variações reais de curto prazo e pode subestimar o impacto de episódios críticos de degradação florestal, reduzindo o poder explicativo dessa variável em análises de vazão diária. Apesar de sua importância estrutural, o desmatamento se comporta como uma variável quase estática na granularidade adotada, o que limita sua contribuição direta ao modelo.

Outra limitação relevante envolve a ausência de variáveis espaciais de contexto, como dados meteorológicos de municípios vizinhos, regime hídrico de afluentes a montante e características geográficas da bacia hidrográfica (como tipo de solo, relevo ou uso do solo em escala mais fina). A resposta hidrológica de uma bacia fluvial raramente é localizada: ela depende de eventos ocorridos em toda a sua extensão. Como o modelo foi alimentado exclusivamente com variáveis associadas ao próprio município de Manaus, potenciais efeitos espaciais foram ignorados, o que pode limitar a capacidade do modelo de capturar corretamente os picos de vazão originados fora dos limites municipais. Essa ausência pode ter levado à subestimação de eventos de cheia causados por afluentes a montante ou por dinâmicas intermunicipais, reduzindo a precisão de algumas previsões de pico.

Do ponto de vista metodológico, embora o uso de algoritmos robustos como Random Forest e XGBoost tenha se mostrado eficaz, a abordagem adotada permanece centrada em modelos de aprendizado supervisionado baseados em regressão estática. Ainda que janelas móveis e variáveis derivadas tenham sido utilizadas para incorporar aspectos temporais, modelos mais sofisticados de séries temporais (como LSTM, ARIMA ou modelos híbridos) não foram explorados. Isso limita a modelagem de padrões de longo prazo e da autocorrelação entre períodos sucessivos, o que pode ser relevante para prever períodos prolongados de cheia ou seca.

Adicionalmente, o próprio processo de seleção e combinação de variáveis no plano de experimentação seguiu um modelo fatorial fixo, o que implicou um grande número de pipelines testados, porém sem refinamentos posteriores baseados em tuning profundo de hiperparâmetros ou análises bayesianas de incerteza. Isso pode ter restringido o alcance da performance máxima de alguns modelos.

Por fim, como o estudo se concentrou exclusivamente no município de Manaus, seus resultados não podem ser generalizados automaticamente para outras cidades da Amazônia Legal, dado que a relação entre precipitação, desmatamento e vazão varia significativamente de acordo com a geomorfologia e a ocupação do território.

O último ponto a ser mencionado é que inicialmente, o projeto tinha como objetivo principal a previsão direta de enchentes na cidade de Manaus. No entanto, durante a fase de exploração dos dados, identificou-se uma grave limitação na disponibilidade de registros sistemáticos, rotulados e georreferenciados sobre eventos de inundação. Especificamente, não foram encontrados dados públicos que definissem com precisão os *thresholds* de vazão a partir dos quais ocorrem alagamentos na cidade (informação essencial para treinar e validar modelos de classificação de enchentes). Diante dessa restrição, optou-se por redirecionar o escopo do projeto para a previsão da vazão dos rios, uma variável contínua, mensurável e historicamente bem documentada, que funciona como indicador antecedente de risco hidrológico. Essa decisão metodológica permitiu preservar a relevância prática do estudo, mantendo sua utilidade para a gestão de riscos, planejamento energético e antecipação de cenários críticos, mesmo sem prever explicitamente os eventos de enchentes.

Apesar dessas limitações, os modelos desenvolvidos cumpriram sua função de prever variações relevantes da vazão fluvial com razoável precisão, fornecendo uma base sólida para futuras melhorias. Superar essas restrições em etapas posteriores, por meio da inclusão de dados espaciais, uso de modelos temporais e aumento da resolução das variáveis, pode ampliar

consideravelmente a aplicabilidade e o impacto das soluções propostas.

6.4 Direções para Trabalhos Futuros

A conclusão deste projeto abre espaço para uma série de oportunidades de aprofundamento e expansão, tanto no campo técnico da modelagem preditiva quanto na aplicação prática dos resultados para a gestão de riscos e o planejamento energético na região amazônica. A seguir, são discutidas possíveis direções para futuros trabalhos que podem aprimorar os achados atuais e ampliar sua aplicabilidade.

Uma das principais direções envolve o retorno ao objetivo inicial de previsão de enchentes, agora com o aprendizado acumulado na modelagem de vazão. Para que isso se concretize, será fundamental viabilizar parcerias com órgãos públicos e institutos de pesquisa locais (como CPRM, ANA ou Defesa Civil de Manaus), a fim de obter ou construir bases de dados confiáveis contendo registros rotulados de eventos de alagamento, inclusive com os limiares de vazão e nível do rio que caracterizam tecnicamente uma enchente em diferentes regiões urbanas. O desenvolvimento desses thresholds permitiria treinar modelos de classificação que antecipem o risco de inundação com base na previsão da vazão, transformando o modelo atual em uma ferramenta mais precisa e diretamente aplicável à prevenção de desastres.

Outra frente promissora é a incorporação de variáveis espaciais e geográficas, como dados de precipitação e vazão de municípios vizinhos, características geomorfológicas da bacia hidrográfica (incluindo tipo de solo, relevo, uso e cobertura do solo), e dados de escoamento superficial. Essas informações poderiam ser obtidas por meio de sensoriamento remoto, imagens de satélite ou modelagem hidrológica distribuída, permitindo que o modelo preditivo seja territorialmente mais sensível e consiga capturar o efeito de chuvas em áreas a montante, que muitas vezes são a verdadeira causa de picos de vazão em Manaus.

No campo metodológico, futuros trabalhos poderiam testar o uso de modelos temporais mais avançados, como redes neurais recorrentes (RNNs), modelos LSTM (Long Short-Term Memory) ou Transformer-based models, que são capazes de lidar com séries temporais com defasagens complexas e memória de longo prazo. Isso seria particularmente útil para prever padrões sazonais e eventos extremos com maior antecedência. Além disso, a adoção de abordagens híbridas que combinam modelos estatísticos (ex: ARIMA) com aprendizado de máquina pode fornecer ganhos adicionais em robustez e interpretabilidade.

Do ponto de vista da avaliação do modelo, futuras pesquisas podem aplicar técnicas de tuning mais refinadas, como otimização bayesiana, busca em rede adaptativa ou validação cruzada neste, de modo a encontrar configurações de hiperparâmetros mais eficientes. Além disso, a inclusão de métricas específicas para eventos extremos, como o erro médio ponderado por picos de vazão, poderia melhorar a sensibilidade do modelo em cenários críticos.

Quanto à coleta de dados, é recomendável ampliar a rede de fontes e automatizar rotinas de extração e atualização contínua de dados por meio de APIs, especialmente para variáveis meteorológicas em tempo real. A construção de sistemas de atualização automática de dados e

reentrenamento periódico do modelo tornaria a solução mais dinâmica e aplicável em tempo real, aumentando seu valor para gestores públicos e operadoras de infraestrutura energética.

Por fim, os resultados do projeto levantaram novas questões de pesquisa que merecem investigação, tais como:

- *Como diferentes graus de desmatamento modulam a resposta hidrológica da bacia para a mesma intensidade de chuva?*
- *É possível integrar previsão meteorológica futura com modelos de previsão de vazão para gerar alertas antecipados?*
- *Como a previsão de vazão pode ser traduzida em decisões operacionais para diferentes tipos de infraestrutura energética?*

Explorar essas questões e implementar as melhorias sugeridas permitirá não apenas refinar a modelagem atual, mas também transformar a previsão de vazão em uma ferramenta estratégica robusta para gestão ambiental, energética e climática, alinhada aos princípios da sustentabilidade e da resiliência que o projeto "Amazonizar" busca promover.

Referências Bibliográficas

ANUSHA, N.; VEDHA, G.; LAVANYA, V. Weather prediction using multi linear regression algorithm. In: *IOP Conference Series: Materials Science and Engineering*, v. 590, p. 012034, 2019.

CHEN, T.; GUESTRIN, C. *XGBoost: A scalable tree boosting system*. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, San Francisco. Anais [...]. New York: ACM, 2016. p. 785–794.

EPE – EMPRESA DE PESQUISA ENERGÉTICA. *Balanco Energético Nacional 2024: ano base 2023*. Rio de Janeiro: EPE, 2024. Disponível em: <https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/Balanco-Energetico-Nacional-BEN>. Acesso em: 5 jul. 2025.

INFOAMAZONIA. Desastres hidrológicos são os mais recorrentes na Amazônia Legal nos últimos 28 anos. 2025. Disponível em: <https://infoamazonia.org/2025/04/24/desastres-hidrologicos-sao-os-mais-recorrentes-na-amazonia-legal-nos-ultimos-28-anos/>. Acesso em: 29 abr. 2025.

KALINIC, M.; DJORDJEVIC, S.; PETROVIC, D. XGBoost-based method for flash flood risk assessment. *Journal of Hydrology*, v. 603, p. 126984, 2021.

MOSAVI, A.; OZTURK, P.; CHAMARSKI, J. Flood prediction using machine learning models: Literature review. *Water*, v. 10, n. 11, p. 1536, 2018.

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO. *Amazonizar*. Instituto ECOA – PUC-Rio, 2023. Disponível em: <https://instituto.ecoa.puc-rio.br/amazonizar/#sobre>. Acesso em: 1 maio 2025.

SCOFIELD, Gabriela. Modelo-preditivo-enchentes. 2024. Disponível em: <https://github.com/GabiScof/modelo-previsao-enchentes>. Acesso em: 29 abr. 2025.

SCOFIELD, Gabriela. Modelo-preditivo-enchentes. 2024. Disponível em: <https://github.com/GabiScof/modelo-previsao-enchente>. Acesso em: 29 abr. 2025.

SILVA, J. L. Impactos do desmatamento progressivo da Amazônia na precipitação do Brasil. *Revista Brasileira de Climatologia*, v. 22, p. 1-15, 2018

ZHANG, Y.; WANG, S.; JI, G. *Data partition strategies for machine learning model evaluation: A review*. *Information Sciences*, v. 562, p. 90–109, 2021. Disponível em: <https://doi.org/10.1016/j.ins.2021.01.079>. Acesso em: 23 maio 2025.

ZHOU, Y.; CHEN, X.; WANG, W.; CHENG, Q.; ZHANG, H. *XGBoost-based method for flash flood risk assessment: A case study of Yunnan province, China*. *Journal of Hydrology*, [S. l.], v. 603, 126996, 2021. DOI: <https://doi.org/10.1016/j.jhydrol.2021.126996>.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep learning*. Cambridge, MA: MIT Press, 2016. Disponível em: https://www.deeplearningbook.org/front_matter.pdf. Acesso em: 17 maio 2025